

UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ

IGOR ARAUJO DE MATTOS

**ALETHEIA: DETECÇÃO DE FAKE NEWS COM MODELOS DE LINGUAGEM E
ESTRATÉGIAS DE RACIOCÍNIO**

CORNÉLIO PROCÓPIO

2026

IGOR ARAUJO DE MATTOS

**ALETHEIA: DETECÇÃO DE FAKE NEWS COM MODELOS DE LINGUAGEM E
ESTRATÉGIAS DE RACIOCÍNIO**

**Aletheia: Detecting Fake News With Language Models And Reasoning
Strategies**

Trabalho de Conclusão de Curso de Graduação
apresentado como requisito para obtenção
do título de Bacharel em Engenharia da
Computação do Curso de Bacharelado em
Engenharia da Computação da Universidade
Tecnológica Federal do Paraná.

Orientador(a): Prof. Dr. Robson Parmezan
Bonidia

CORNÉLIO PROCÓPIO

2026



[4.0 Internacional](https://creativecommons.org/licenses/by/4.0/)

Esta licença permite compartilhamento, remixe, adaptação e criação a partir do trabalho, mesmo para fins comerciais, desde que sejam atribuídos créditos ao(s) autor(es). Conteúdos elaborados por terceiros, citados e referenciados nesta obra não são cobertos pela licença.

IGOR ARAUJO DE MATTOS

**ALETHEIA: DETECÇÃO DE FAKE NEWS COM MODELOS DE LINGUAGEM E
ESTRATÉGIAS DE RACIOCÍNIO**

Trabalho de Conclusão de Curso de Graduação
apresentado como requisito para obtenção
do título de Bacharel em Engenharia da
Computação do Curso de Bacharelado em
Engenharia da Computação da Universidade
Tecnológica Federal do Paraná.

Data de aprovação: dia / mês por extenso / ano

Nome completo e por extenso do Membro 1 (de acordo com o Currículo Lattes)

Titulação (Especialização, Mestrado, Doutorado)

Nome completo e por extenso da instituição a qual possui vínculo

Nome completo e por extenso do Membro 2 (de acordo com o Currículo Lattes)

Titulação (Especialização, Mestrado, Doutorado)

Nome completo e por extenso da instituição a qual possui vínculo

Nome completo e por extenso do Membro 3 (de acordo com o Currículo Lattes)

Título (Titulação (Especialização, Mestrado, Doutorado)

Nome completo e por extenso da instituição a qual possui vínculo

CORNÉLIO PROCÓPIO

2026

Dedico este TCC com amor à minha família,
pelo apoio incondicional em todos os
momentos, e a todos que caminharam comigo
nesta jornada de aprendizado, superação e
crescimento.

AGRADECIMENTOS

Agradeço primeiramente a Deus, por ter me dado força, sabedoria e perseverança para concluir esta jornada acadêmica, iluminando meu caminho nos momentos de dificuldade e incerteza.

À minha família, pelo amor incondicional, apoio nos momentos mais difíceis e incentivo constante para seguir em frente, acreditando sempre no meu potencial. Sem vocês, nada disso seria possível.

Aos amigos que fiz ao longo da graduação, que tornaram essa caminhada mais leve, compartilhando desafios, aprendizados e conquistas. A parceria e o companheirismo de vocês foram essenciais para tornar esta experiência ainda mais enriquecedora.

Aos meus professores e orientadores, que dedicam suas vidas ao ensino e à pesquisa, transmitindo conhecimento de qualidade e guiando os alunos com comprometimento e paciência. Minha gratidão especial àqueles que, direta ou indiretamente, contribuíram para a realização deste trabalho.

À Universidade Tecnológica Federal do Paraná (UTFPR), que me acolheu e proporcionou uma formação acadêmica de excelência, capacitando-me para enfrentar os desafios do mundo profissional.

A todos que, de alguma forma, fizeram parte desta trajetória, o meu mais sincero muito obrigado!

“A ferramenta básica para a manipulação da realidade é a manipulação das palavras. Se você puder controlar o significado das palavras, poderá controlar as pessoas que devem usá-las.” (Dick, 1978).

USO DE IA GENERATIVA

Durante o desenvolvimento deste TCC, ferramentas de inteligência artificial generativa foram utilizadas com critério e ética, com o objetivo de suporte em determinadas fases da pesquisa e redação. A aplicação principal foi a busca e filtragem de artigos científicos importantes para os tópicos abordados nas seções de Introdução e Revisão da Literatura, agilizando a descoberta de materiais atualizados e alinhados à temática proposta. Além disso, essas ferramentas foram aplicadas para aprimorar a pontuação e a fluidez textual em partes específicas do trabalho, sempre com uma análise crítica por parte dos autores.

É importante destacar, porém, que todos os passos cruciais do projeto, incluindo a escolha do tema, o estabelecimento dos objetivos, a análise dos dados, a construção da argumentação teórica e a redação final do texto, foram executados unicamente por pessoas, fundamentados na leitura, compreensão e síntese dos artigos que foram de fato consultados. A inteligência artificial generativa serviu como um recurso de busca aprimorada e um assistente de revisão textual, sem substituir o esforço intelectual e analítico que a pesquisa acadêmica exige.

RESUMO

A rápida propagação da desinformação na *internet*, sobretudo pelas redes sociais e aplicativos de mensagens, tem intensificado a necessidade de tecnologias que auxiliem na verificação da veracidade de conteúdos compartilhados. O presente trabalho propõe elaborar uma aplicação baseada em modelos de linguagem de última geração, integrada à abordagem de raciocínio automatizado e à de explicabilidade, de acordo com a realidade linguística e sociocultural do Brasil. Nomeada *Aletheia* (que em grego se refere à revelação da verdade), a aplicação pretende funcionar como um sistema transparente e acessível à detecção de *fake news*, priorizando a interpretabilidade das decisões tomadas pelo modelo. A abordagem utiliza um conjunto robusto de dados rotulados em português, oriundos de diversas fontes jornalísticas e repositórios de *fact-checking*, que passa pelos processos de tratamento e pela análise exploratória. Diferentes técnicas de *prompting* serão utilizadas para avaliar a capacidade de raciocínio dos LLMs frente a sentenças complexas. Como aplicação final, será desenvolvido um protótipo funcional em forma de *bot* para plataformas como Telegram ou WhatsApp, possibilitando a solução a um público abrangente e contribuindo para a mitigação da desinformação no Brasil. Este trabalho não visa apenas implementar um classificador eficiente como também promover a confiança e o engajamento crítico do usuário para com os resultados apresentados, reforçando a importância de ferramentas responsáveis e interpretáveis no combate às *fake news*.

Palavras-chave: fake news; modelos de linguagem; inteligência artificial explicável; interpretabilidade; detecção de desinformação.

ABSTRACT

The rapid spread of misinformation on the internet, particularly through social media and messaging apps, has intensified the need for technologies that help verify the veracity of shared content. This paper proposes the development of an application based on state-of-the-art language models, integrated with the automated reasoning approach and explainability, in accordance with the linguistic and sociocultural context of Brazil. Named *Aletheia* (which in Greek refers to the revelation of truth), the application aims to function as a transparent and accessible system for detecting fake news, prioritizing the interpretability of the decisions made by the model. The approach uses a robust set of labeled data in Portuguese, originating from various journalistic sources and fact-checking repositories, which undergo pre-processing and exploratory analysis. Different prompting techniques will be employed to assess the reasoning capacity of LLMs when confronted with complex sentences. As a final application, a functional prototype will be developed in the form of a bot for platforms such as Telegram or WhatsApp, making the solution accessible to a broader audience and contributing to the mitigation of disinformation in Brazil. This work aims not only to build an efficient classifier but also to promote user trust and critical engagement with the results presented, reinforcing the importance of responsible and interpretable tools in the fight against fake news.

Keywords: fake news; language models; explainable artificial intelligence; interpretability; misinformation detection.

LISTA DE FIGURAS

Figura 1 – Subcampos da Inteligência Artificial	30
Figura 2 – Visão geral das etapas da metodologia da <i>Aletheia</i>	50
Figura 3 – Arquitetura geral da aplicação <i>Aletheia</i>	79
Figura 4 – Interface de conversação do <i>bot Aletheia</i>	81
Figura 5 – Comparação do <i>F1-score</i> médio por estratégia de <i>prompting</i>	88
Figura 6 – <i>F1-score</i> por modelo e por estratégia de <i>prompting</i>	91
Figura 7 – Comparação de <i>faithfulness</i> e <i>answer relevancy</i> (RAGAS) por modelo nas estratégias de <i>prompting</i>	96
Figura 8 – Protótipo do <i>Bot</i> no Telegram.	98
Figura 9 – Protótipo do <i>Bot</i> no WhatsApp.	99
Figura 10 – Respostas dos <i>bots</i> para notícias de fora da distribuição.	100

LISTA DE TABELAS

Tabela 1 – Classificação de <i>fake news</i> com base em Wardle e Derakhshan (2017) (Wardle; Derakhshan, 2017), Shu et al. (2017) (Shu et al., 2017), Tandoc et al. (2017) (Tandoc; Lim; Ling, 2017).	27
Tabela 2 – Comparação de LLMs populares com base em MindsDB, 2025 (Slawinska; Mardini, 2025) e Sapling, 2025 (Ai, 2025).	33
Tabela 3 – Evolução das métricas de <i>F1-score</i> por modelo ao longo das rodadas de refinamento de <i>prompt</i> e parâmetros (versão inicial vs. versão final).	85
Tabela 4 – Desempenho médio dos modelos por estratégia de <i>prompting</i> — <i>Acurácia</i> , <i>Precisão</i> , <i>Recall</i> , <i>F1-score macro</i> , <i>Kappa</i> e <i>MCC</i> (médias sobre os 7 modelos, 100 instâncias).	87
Tabela 5 – Desempenho individual dos modelos — melhor estratégia de cada modelo.	89
Tabela 6 – Taxa de abstenção (%) e cobertura por modelo e por estratégia de <i>prompting</i> .	91
Tabela 7 – Métricas probabilísticas dos modelos na melhor estratégia de <i>prompting</i> .	93
Tabela 8 – Métricas qualitativas por modelo na melhor estratégia de <i>prompting</i> .	94
Tabela 9 – Métricas RAGAS por modelo na melhor estratégia de <i>prompting</i> .	95
Tabela 10 – Desempenho do modelo Phi-4 com a estratégia <i>cot-in</i> sobre o <i>dataset</i> completo do <i>FakeTrue.Br</i> .	97

LISTA DE ABREVIATURAS E SIGLAS

ACC	Precisão, do inglês <i>Accuracy</i>
API	Interface de Programação de Aplicações, do inglês <i>Application Programming Interface</i>
ARG	Orientação Adaptativa de Raciocínio, do inglês <i>Adaptive Rationale Guidance</i>
AUC	Área sob a Curva, do inglês <i>Area Under the Curve</i>
AUC-ROC	Área sob a Curva - Característica de Operação do Receptor, do inglês <i>Area Under the Curve - Receiver Operating Characteristic</i>
BBC	Corporação Britânica de Radiodifusão, do inglês <i>British Broadcasting Corporation</i>
CNN	Rede Neural Convolucional, do inglês <i>Convolutional Neural Network</i>
CONIC	Congresso Nacional de Iniciação Científica
COVID-19	Doença por Coronavírus 2019, do inglês <i>Coronavirus Disease 2019</i>
CPU	Unidade Central de Processamento, do inglês <i>Central Processing Unit</i>
DACOM	Departamento Acadêmico de Computação
DL	Aprendizado Profundo, do inglês <i>Deep Learning</i>
ECE	Erro de Calibração Esperado, do inglês <i>Expected Calibration Error</i>
EER	Taxa de Erro Igual, do inglês <i>Equal Error Rate</i>
ENIAC	Encontro Nacional de Inteligência Artificial e Computacional
EUA	Estados Unidos da América
FAISS	Busca por Similaridade com IA do Facebook, do inglês <i>Facebook AI Similarity Search</i>
GCN	Rede Neural Convolucional em Grafos, do inglês <i>Graph Convolutional Network</i>
GPU	Unidade de Processamento Gráfico, do inglês <i>Graphics Processing Unit</i>
IA	Inteligência Artificial
ICL	Aprendizado em Contexto, do inglês <i>In-Context Learning</i>
IEEE S&P	Simpósio de Segurança e Privacidade do Instituto de Engenheiros Elétricos e Eletrônicos, do inglês <i>IEEE Symposium on Security and Privacy</i>
LLM	Modelo de Linguagem de Grande Escala, do inglês <i>Large Language Model</i>
LUN	Notícias Rotuladas como Não Confiáveis, do inglês <i>Labeled Unreliable News</i>
LVLM	Modelo Multimodal de Visão e Linguagem, do inglês <i>Large Vision-Language Model</i>
MFND	Conjunto de Dados Multimodal de Notícias Falsas, do inglês <i>Multimodal Fake News Dataset</i>
ML	Aprendizado de Máquina, do inglês <i>Machine Learning</i>
MLP	Perceptron de Múltiplas Camadas, do inglês <i>Multilayer Perceptron</i>
NDSS	Simpósio de Segurança de Sistemas em Rede e Distribuídos, do inglês <i>Network and Distributed System Security Symposium</i>

NLP	Processamento de Linguagem Natural, do inglês <i>Natural Language Processing</i>
OEA	Organização dos Estados Americanos
PLM	Modelo de Linguagem Pré-treinado, do inglês <i>Pre-trained Language Model</i>
PR-AUC	Área sob a Curva Precisão-Revocação, do inglês <i>Precision–Recall AUC</i>
PWS	Estratégia de Escrita Persuasiva, do inglês <i>Persuasive Writing Strategy</i>
RAG	Geração com Recuperação, do inglês <i>Retrieval-Augmented Generation</i>
RNN	Rede Neural Recorrente, do inglês <i>Recurrent Neural Network</i>
ROUGE	Avaliação de Resumo Orientada à Recuperação, do inglês <i>Recall-Oriented Understudy for Gisting Evaluation</i>
SEMESP	Sindicato das Mantenedoras de Ensino Superior
SLM	Modelo de Linguagem Pequeno, do inglês <i>Small Language Model</i>
SVM	Máquina de Vetores de Suporte, do inglês <i>Support Vector Machine</i>
TCC	Trabalho de Conclusão de Curso
Twiml	Linguagem de Marcação Twilio, do inglês <i>Twilio Markup Language</i>
UOL	Universo Online
UTFPR	Universidade Tecnológica Federal do Paraná
VNR	Liberação de Vídeo para a Imprensa, do inglês <i>Video News Release</i>
XAI	Inteligência Artificial Explicável, do inglês <i>Explainable Artificial Intelligence</i>

Acrônimos

ABNT	Associação Brasileira de Normas Técnicas
BERT	Representações Bidirecionais Codificadoras de Transformadores, do inglês <i>Bidirectional Encoder Representations from Transformers</i>
BiLSTM	Memória de Longo e Curto Prazo Bidirecional, do inglês <i>Bidirectional Long Short-Term Memory</i>
CLIP	Pré-treinamento Contrastivo de Linguagem e Imagem, do inglês <i>Contrastive Language-Image Pretraining</i>
CORS	Compartilhamento de Recursos entre Origens, do inglês <i>Cross-Origin Resource Sharing</i>
CoT	Cadeia de Pensamento, do inglês <i>Chain-of-Thought</i>
DELL	Avaliação de Desinformação com Aprendizado em Camadas, do inglês <i>Disinformation Evaluation with Layered Learning</i>
EAViT	<i>Extended Autocoded ViT</i> (ViT Autocodificado Estendido)
FFRR	Reforço com Feedback Fino e Recuperação, do inglês <i>Fine-grained Feedback with Reinforcement Retrieval</i>
FKA-Owl	Coruja Aprimorada com Conhecimento sobre Fake News, do inglês <i>Fake News Knowledge-Augmented Owl</i>
FND-LLM	Deteção de Fake News com Modelos de Linguagem de Grande Escala, do inglês <i>Fake News Detection with Large Language Models</i>
GenAI	Inteligência Artificial Generativa, do inglês <i>Generative Artificial Intelligence</i>
GPT	Transformador Generativo Pré-Treinado, do inglês <i>Generative Pre-trained Transformer</i>
GPTQ	Quantização de Transformadores Pré-treinados Generativos, do inglês <i>Generative Pre-trained Transformer Quantization</i>

HiSS	Passo-a-Passo Hierárquico, do inglês <i>Hierarchical Step-by-Step</i>
LLaMa	Modelo de Linguagem de Grande Escala da Meta AI, do inglês <i>Large Language Model Meta AI</i>
LSTM	Memória de Longo e Curto Prazo, do inglês <i>Long Short-Term Memory</i>
MMoE	Mistura de Especialistas com Múltiplas Portas, do inglês <i>Multi-gate Mixture-of-Experts</i>
PaLM	Modelo de Linguagem Pathways, do inglês <i>Pathways Language Model</i>
ReAct	Raciocínio + Ação, do inglês <i>Reasoning + Acting</i>
RoBERTa	Abordagem BERT Otimizada de Forma Robusta, do inglês <i>Robustly Optimized BERT Approach</i>
REST	Transferência de Estado Representacional, do inglês <i>Representational State Transfer</i>
T5	Transformador de Transferência Texto-para-Texto, do inglês <i>Text-to-Text Transfer Transformer</i>
ViT	Transformador de Visão, do inglês <i>Vision Transformer</i>

SUMÁRIO

1	INTRODUÇÃO	17
1.1	O Termo Fake News	17
1.2	A IA na Era da Desinformação	18
1.3	O Estado da Arte	19
1.4	O Desafio de Usar IA.....	20
1.5	Proposta, Objetivo Geral e Específicos	21
1.6	Questões de Pesquisa e Hipótese	22
1.7	Justificativa.....	22
1.8	Organização do Trabalho	24
2	REVISÃO DE LITERATURA	26
2.1	Compreendendo <i>Fake News</i> e seus Tipos.....	26
2.2	Fundamentos de Inteligência Artificial e Subcampos Relevantes	29
2.3	Aprendizado de Máquina (<i>Machine Learning</i> — ML)	30
2.4	Aprendizado Profundo (<i>Deep Learning</i> — DL).....	31
2.5	Modelos de Linguagem de Grande Escala (<i>Large Language Models</i> — LLMs).....	32
3	TRABALHOS RELACIONADOS	35
3.1	Classificação Textual com LLMs	35
3.1.1	ChatGPT e Gemini na Classificação de Desinformação	35
3.1.2	Fake News em Árabe: <i>AraBERT</i> com Mecanismo de Atenção.....	36
3.1.3	Desinformação em Saúde: <i>BERT</i> Integrando Conteúdo e Contexto Social.....	37
3.2	Verificação e Checagem de Fatos com LLMs	38
3.2.1	Recuperação por Reforço com <i>Feedback</i> para Checagem de Fatos ...	38
3.2.2	Checagem de Fatos com Decomposição Hierárquica e LLMs	39
3.2.3	Checagem de Desinformação com LLMs e Supervisão Fraca	40
3.3	Análise Contextual e Estratégias Avançadas	40
3.3.1	Combinação de LLMs e SLMs para Detecção de <i>Fake News</i> com Justificativas	41
3.3.2	Separação Estilo-Conteúdo para Detecção Robusta de Desinformação	41
3.3.3	Uso de Reações e Tarefas <i>Proxy</i> com LLMs na Detecção de Desinformação	42
3.4	Abordagens Multimodais para Detecção de <i>Fake News</i>	43
3.4.1	Detecção Multimodal de <i>Fake News</i> com LVLMs e Conhecimento de Falsificação	44
3.4.2	FND-LLM: Detecção Multimodal de <i>Fake News</i> com Múltiplos Ramos e LLMs	45
3.5	Detecção de <i>Fake News</i> em Contextos Específicos: Caso Brasileiro ..	46
3.5.1	Arquiteturas Avaliadas e Estratégias de <i>Prompting</i>	46

3.5.2	Conjunto de Dados: Construção e Relevância Contextual	47
3.5.3	Resultados: Desempenho, Explicabilidade e Representação	47
3.5.4	Limitações e Comparação com o Estado da Arte	47
3.6	Desafios Atuais: Interpretabilidade e Reasoning na Detecção de Fake News	48
4	METODOLOGIA	49
4.1	Aquisição de Dados	49
4.2	Engenharia de Prompting	52
4.2.1	Conhecimento Interno para Verificação Factual	52
4.2.2	Conhecimento Externo para Verificação Factual	59
4.3	Aletheia: Configuração Experimental	69
4.3.1	Estrutura Geral do Pipeline Experimental	70
4.3.2	Métricas Quantitativas de Classificação	72
4.3.3	Métricas de Cobertura e Abstenção	74
4.3.4	Métricas Probabilísticas e de Calibração	75
4.3.5	Avaliação Qualitativa e Explicabilidade	76
4.4	Desenvolvimento da Aplicação para o Usuário Final	77
4.4.1	Arquitetura Geral da Aplicação	78
4.4.2	Integração com Telegram e WhatsApp	79
4.4.3	Gerenciamento do Protótipo	79
5	RESULTADOS E DISCUSSÃO	82
5.1	Introdução e Escopo dos Experimentos	82
5.2	Configuração Experimental	82
5.3	Desafios Técnicos e Soluções Adotadas	83
5.3.1	Geração de Respostas em Língua Inglesa	83
5.3.2	Esgotamento de Memória em Modelos de Grande Porte	83
5.3.3	Recuperação de Contexto Fora do Escopo Temporal	83
5.3.4	Avaliação Qualitativa sem Modelos Proprietários (RAGAS com Ollama)	84
5.3.5	Extração Estruturada de Classes e Probabilidades	84
5.4	Refinamento Iterativo dos Modelos	85
5.5	Resultados da Fase de Testes Controlados	87
5.5.1	Métricas Quantitativas por Estratégia de Prompting	87
5.5.2	Métricas Quantitativas por Modelo de Linguagem	89
5.5.3	Métricas de Cobertura e Abstenção	90
5.5.4	Métricas Probabilísticas e de Calibração	93
5.5.5	Avaliação Qualitativa das Justificativas	94
5.5.6	Avaliação com RAGAS	95
5.6	Resultados sobre o Dataset Completo	97
5.7	Análise de Generalização: Notícias Fora da Distribuição	98
5.8	Discussão Geral	99
6	CONSIDERAÇÕES FINAIS	102
6.1	Síntese dos Resultados e Objetivos da Pesquisa	102

6.2	Contribuições do Trabalho	103
6.3	Limitações e Trabalhos Futuros	104
6.3.1	Limitações	104
6.3.2	Trabalhos Futuros	105
	REFERÊNCIAS	107

1 INTRODUÇÃO

As tecnologias midiáticas utilizadas para a disseminação de notícias passaram por grandes transformações ao longo dos últimos três séculos (Allcott; Gentzkow, 2017). O jornal impresso de baixo custo, em seguida, o rádio, depois a televisão, marcaram o período em que a informação era exclusivamente distribuída por organizações que seguiam um padrão de ética muito rigoroso (Bengtsson; Johansson, 2021). Contudo, a situação mudou radicalmente com o advento das plataformas de mídia social, por meio das quais o conteúdo pode ser disseminado amplamente entre usuários, sem a intervenção de terceiros, sem verificação de fatos ou curadoria editorial (Cage; Herve; Mazoyer, 2020). Em alguns casos, um único usuário pode alcançar uma audiência tão vasta quanto os veículos tradicionais, por exemplo, Fox News, CNN ou *The New York Times* (Flamino et al., 2023).

Inicialmente, é necessário distinguir os termos desinformação e informação errada. A desinformação diz respeito a informações falsas ou imprecisas, elaboradas intencionalmente para enganar, pressionar opiniões e manipular decisões (Bayer et al., 2019). Já a informação errônea diz respeito a conteúdos incorretos, enganosos ou equivocados, porém sem a intenção consciente de enganar (Broda; Strömbäck, 2024). Em outras palavras, enquanto a informação errada pode decorrer de equívocos não intencionais, a desinformação está associada a uma motivação deliberada. Todavia, como não é sempre possível discernir a intenção por trás da elaboração de falsidades que circulam na *internet*, o termo "informação errada" tem sido comumente usado em contextos internacionais como sinônimo de *misinformation* (Pennycook; Rand, 2021).

Juntamente com a ascensão das redes sociais, aumentam também as preocupações relacionadas aos efeitos da desinformação e da privacidade dos dados (Fotopoulos, 2023). A facilidade com que as informações podem ser trocadas nessas plataformas favorece a disseminação de conteúdos enganosos, que geram riscos reais à opinião pública, aos processos democráticos e à coesão social (Aïmeur; Brassard, 2023). Isso pode distorcer a percepção da realidade, com consequências para as decisões individuais e coletivas, além de contribuir para o aumento das falácias (Keller et al., 2020).

1.1 O Termo Fake News

Nos últimos anos, o uso do termo *fake news* (notícias falsas, em português) tornou-se bastante recorrente na mídia para designar conteúdos que, publicados pela internet, parecem à primeira vista notícias verdadeiras, mas que, na realidade, são inventados ou extremamente imprecisos (Miró-Illinares; Aguerri, 2021). A difusão dessas notícias falsas elevou os riscos tanto para as pessoas quanto para as organizações, aumentando os impactos negativos da desinformação (Dhiman, 2023). Muitas vezes, conteúdos legítimos são distorcidos ou, ainda, notícias totalmente fabricadas são apresentadas como se fossem verdadeiras nas plataformas digitais (Beisecker; Hein, 2022).

Em 2017, Tim Berners-Lee, o criador da *World Wide Web*, alertava que a desinformação é uma das maiores ameaças da internet e requer ações urgentes para combatê-la (Swartz, 2017). Esse problema não se limita ao nível individual. Dentro de uma organização, a disseminação de informações falsas pode prejudicar o valor de reputação de marcas, o que pode afetar o consumo de produtos e serviços (Gross, 2017). Além do mais, o uso de *bots* tem automatizado a disseminação de desinformação, o que não apenas a intensificou nas redes, mas a torna ainda mais difícil de controlar (Ruffo *et al.*, 2023).

A detecção de notícias falsas representa um desafio complexo que envolve avaliar diversos fatores, tal como a autenticidade do conteúdo, a intenção do autor e o estilo de escrita (Capuano *et al.*, 2023). Diferentes abordagens podem ser utilizadas nesse sentido. A abordagem baseada em conhecimento, por exemplo, compara o texto das notícias com bases de dados de fatos verificados; a abordagem estilística examina padrões de linguagem que distinguem notícias falsas de verdadeiras; e a abordagem de credibilidade considera a confiabilidade das fontes e suas ligações com entidades jornalísticas (Zhou *et al.*, 2019). Além disso, métodos baseados na propagação da informação analisam o comportamento de disseminação das notícias nas redes sociais (Zhu *et al.*, 2024a).

1.2 A IA na Era da Desinformação

Nesse contexto, os recentes avanços em Inteligência Artificial (IA) Generativa oferecem tanto oportunidades quanto novos obstáculos para a detecção de desinformação. Os sistemas de Inteligência Artificial Generativa (*Generative AI* – GenAI) são capazes de criar novos conjuntos de dados a partir do aprendizado de máquina aplicado em grandes quantidades de dados de treinamento (*training data*) (Banh; Strobel, 2023). Esses dados podem incluir texto (como o Bard, do Google; o LLaMa, da Meta; ou o ChatGPT, da OpenAI), imagens (como o *Stable Diffusion* ou o DALL·E, da OpenAI) e áudio (como o VALL-E, da Microsoft) (Gozalo-brizuela; Garrido-merchán, 2023). O conteúdo gerado por esses sistemas é produzido em uma velocidade e acessibilidade para a maioria dos usuários, podendo ter um nível de sofisticação tal a partir das instruções fornecidas para diferenciar o conteúdo gerado por IA de conteúdo gerado por humanos (Groh *et al.*, 2024).

Diante desse cenário, tecnologias baseadas em GenAI e Modelos de Linguagem de Grande Escala (*Large Language Models* – LLMs) despontam como ferramentas de grande impacto, mas também de enorme desafio (Loth; Kappes; Pahl, 2024). Essas tecnologias apresentam uma espécie de paradoxo: se, de um lado, podem gerar conteúdos extremamente realistas, mas falsos, aumentando a dificuldade de detecção da desinformação (Sun *et al.*, 2024); por outro, disponibilizam técnicas avançadas para a detecção, a identificação e a mitigação do avanço das *fake news*, convertendo-se em parte da solução para o próprio problema que contribuem para produzir (Kareem; Abbas, 2023).

Antes do advento dos LLMs, a produção de notícias falsas dependia exclusivamente do resultado da manipulação humana (Vykopal *et al.*, 2024b). Nesse período, a pesquisa em

detecção de desinformações geradas por IA se concentrava nos Modelos de Linguagem de Pequena Escala (*Small Language Models* – SLMs) (Jiang *et al.*, 2023a), tais como BERT (Devlin *et al.*, 2019), GPT-2 (Brown *et al.*, 2020) e T5 (Raffel *et al.*, 2023). Com o surgimento dos LLMs, tanto a geração quanto a detecção de notícias falsas passaram a ser automatizadas (Vykopal *et al.*, 2024b). Deste modo, a sofisticação desses modelos, que operam com bilhões de parâmetros (Jiang *et al.*, 2023a), tornou o desafio da identificação de desinformação ainda mais complexo. Paralelamente, a popularização da internet e das redes sociais nos últimos anos tem agido como um acelerador da disseminação de notícias falsas, gerando impactos significativos em diversas esferas, como saúde pública, política e economia (Aïmeur; Brassard, 2023; Sun *et al.*, 2024). O potencial dos LLMs para gerar textos altamente persuasivos representa uma grande ameaça, com um dos principais riscos associados ao desenvolvimento dessas tecnologias (Goldstein *et al.*, 2023). Diante desse cenário, se faz necessário aprimorar os sistemas de detecção, incorporando métodos capazes de identificar notícias falsas geradas por LLMs (Chen; Shu, 2024).

Propostas para a taxonomia da desinformação gerada por LLMs estão sendo organizadas em cinco dimensões principais (Chen; Shu, 2024): (1) **Tipo de Desinformação**, incluindo categorias como notícias falsas, rumores, teorias da conspiração, *clickbait*, alegações enganosas e escolha seletiva de informações (Chen *et al.*, 2022; Zhou; Zafarani, 2020; Zubiaga *et al.*, 2018; Shu *et al.*, 2017); (2) **Domínio do Conteúdo**, que abrange áreas como saúde, política, ciência, finanças, direito, educação, mídia social e meio ambiente (Wang *et al.*, 2023); (3) **Fonte da Desinformação**, podendo ser: (i) geração alucinatória por falta de dados atualizados, (ii) geração parcial ou totalmente arbitrária inventando detalhes sem base factual, e (iii) geração controlável por meio de paráfrases para ocultar a autoria original, reescritas para alterar significados, sugestões enganosas em finais ambíguos ou manipulação de fatos (Chen; Shu, 2024); (4) **Intenção**, distinguindo entre geração intencional (com propósito de enganar) e não intencional (alucinação sem intenção maliciosa) (Aïmeur; Brassard, 2023); e (5) **Tipos de Erro**, incluindo conteúdo infundado, fabricação total, dados desatualizados, ambiguidade na descrição, fatos incompletos e contexto falso (Fung *et al.*, 2022; Wu *et al.*, 2019; Kumar; Shah, 2018).

1.3 O Estado da Arte

Diversos métodos foram propostos para detecção da desinformação, especialmente antes do surgimento dos LLMs. As abordagens tradicionais costumam depender de dados auxiliares, como metadados (autor, editor e data de publicação), utilizados por modelos como o *Grover* para validar a autenticidade das notícias (Zellers *et al.*, 2020), ou informações extraídas de artigos recuperados da web para a verificação da credibilidade de declarações (Popat *et al.*, 2018). Outras estratégias examinam características emocionais e semânticas do texto (Zhang *et al.*, 2021), ou ainda exploram as interações em redes sociais, como reações e respostas dos usuários (Shu *et al.*, 2019).

Apesar de seu potencial, essas abordagens enfrentam limitações práticas, como a indisponibilidade de dados complementares e a ineficácia dos serviços externos de checagem de fatos — como PolitiFact e Snopes — em função do volume e da velocidade de produção e disseminação de conteúdos falsos (Zhang; Gao, 2023). Nesse cenário, estudos recentes mostram que modelos de linguagem pré-treinados (*Pre-trained Language Models* — PLMs), como o BERT, e LLMs mais avançados, como o GPT-3.5, têm obtido resultados expressivos na detecção de fake news, mesmo sem depender fortemente de informações externas (Sun *et al.*, 2024; Su; Cardie; Nakov, 2023; Wang *et al.*, 2023; Sun *et al.*, 2023), concentrando-se, principalmente, em estratégias de classificação textual, checagem de fatos e análise contextual (Papageorgiou *et al.*, 2024).

A **classificação textual** com LLMs tem demonstrado alto desempenho na identificação de informações incorretas, como evidenciado em estudos de Boissonneault *et al.* (Boissonneault; Hensen, 2024), Al Esawi *et al.* (Alesawi; Al-tai, 2024), Zhang *et al.* (Upadhyay; Pasi; Viviani, 2023) e Liu *et al.* (Liu *et al.*, 2024), além de aplicações híbridas como o FND-LLM (Wang *et al.*, 2024) e investigações voltadas ao português, como o trabalho de Golo *et al.* (Gôlo *et al.*, 2024). Já na **verificação e checagem de fatos**, métodos como *Feedback Refinado com Recuperação por Reforço* (FFRR) (Zhang; Gao, 2024), *Solicitação Hierárquica Passo-a-Passo* (HiSS) (Zhang; Gao, 2023) e rotulagem fraca com *prompting* (Leite *et al.*, 2023) aprimoram a identificação de evidências e subalegações. Por fim, a **análise contextual** tem se beneficiado de arquiteturas como *Adaptive Rationale Guidance* (ARG) (Hu *et al.*, 2024), *SheepDog* (Wu; Guo; Hooi, 2024) e *DELL* (Wan *et al.*, 2024), que incorporam elementos discursivos, reformulações estilísticas e interações simuladas para refinar a detecção. Essas abordagens ilustram o potencial dos LLMs na compreensão profunda da linguagem e no suporte à explicabilidade, ampliando sua aplicabilidade frente à complexidade das narrativas desinformativas.

1.4 O Desafio de Usar IA

Algoritmos de Aprendizado de Máquinas (*Machine Learning* – ML) e Aprendizado Profundo (*Deep Learning* – DL) passaram a desempenhar um papel fundamental em decisões críticas e de alto risco (Sharifani; Amini, 2023). Esses modelos, no entanto, podem apresentar opacidade, viés e falta de justiça em suas previsões (Mohseni; Zarei; Ragan, 2020; Guidotti *et al.*, 2018; Rudin, 2019). Outro desafio é que muitos algoritmos resultam na criação de "modelos de caixa-preta", cujas decisões são difíceis de interpretar (Rudin, 2019). Tais modelos utilizam funções matemáticas complexas, o que os torna incompreensíveis para humanos, tanto em termos de processo de aprendizado quanto de suas representações internas (Hassija vinay chamola, 2024). Essa falta de transparência tem causado danos severos em áreas como justiça criminal, medicina, confiabilidade energética, finanças e veículos autônomos (Hassija vinay chamola, 2024). Por exemplo, no caso do setor saúde, os diagnósticos produzidos por esses modelos podem impossibilitar os médicos de entender como as decisões foram tomadas (Petch; Di; Nelson, 2022).

Consequentemente, modelos de ML treinados em grandes volumes de dados textuais ou visuais podem reproduzir e amplificar estereótipos de preconceito (Zou; Schiebinger, 2018). Somado a isso, a complexidade dos modelos DL e o aumento dos requisitos de poder computacional dificultam a sua aplicação em ambientes de recursos limitados, como dispositivos móveis e assistentes robóticos (Samek; Müller, 2019). Assim, ainda que os algoritmos de ML mais modernos proporcionem um aumento da exatidão, a sua crescente complexidade, refletida em um número exponencialmente maior de parâmetros, reduz a sua explicabilidade e torna necessário o desenvolvimento de abordagens que visem aumentar a sua interpretabilidade (Mohseni; Zarei; Ragan, 2020; Guidotti *et al.*, 2018; Rudin, 2019).

Nesse sentido, a utilização de técnicas de IA Explicável (*Explainable AI* – XAI) proporciona um entendimento mais profundo das decisões inferidas por esses modelos, reduzindo o desafio da caixa-preta e aumentando sua interpretabilidade (Hassija vinay chamola, 2024). Isso não apenas aumenta a eficiência e a confiabilidade desses sistemas, mas também fortalece a transparência na validação da veracidade das informações (Papageorgiou *et al.*, 2024). A explicabilidade desempenha um papel essencial na validação e confiança dos algoritmos de ML e DL, sendo um fator crítico em diversas aplicações (Samek; Müller, 2019). Por exemplo, algoritmos usados para detectar discurso de ódio em plataformas sociais digitais têm demonstrado tendências discriminatórias contra determinados grupos sociais, como gênero, idade, religião e etnia (Hou; Tseng; Yuan, 2024). A transparência nos modelos possibilita a identificação e correção de vieses e distorções, tornando o processo de decisão mais justo (Alvarez *et al.*, 2024).

Além disso, a explicabilidade torna possível a identificação de características potencialmente enviesadas nos textos (Mishima; Yamana, 2022). Isso significa que é viável entender quais aspectos específicos de uma frase influenciam uma classificação particular feita pelo algoritmo, possibilitando moderar comportamentos enviesados. Outro aspecto importante é que a explicabilidade permite auditar e validar as decisões geradas pelos modelos de IA (Ahmad *et al.*, 2024). Em sistemas críticos, como veículos autônomos, entender o motivo de uma decisão pode permitir aos engenheiros localizar defeitos antes mesmo da implementação no mundo real (Samek; Müller, 2019; Hassija vinay chamola, 2024).

Esse mesmo princípio se aplica a sistemas de recomendação, diagnósticos médicos apoiados pela IA e análise de risco financeiro, em que essa transparência é indispensável para garantir confiabilidade e segurança (Ahmad *et al.*, 2024). No caso da detecção de notícias falsas nas redes sociais, os algoritmos utilizam fatores sociais e temporais para o treinamento de redes neurais profundas (Gongane; Munot; Anuse, 2024). A explicabilidade permite quantificar a importância de cada um desses fatores na tomada de decisão, fornecendo uma visão mais clara sobre o funcionamento interno do modelo (Mishima; Yamana, 2022).

1.5 Proposta, Objetivo Geral e Específicos

Este projeto tem como principal objetivo implementar o Processamento de Linguagem Natural (*Natural Language Processing* – NLP) para classificar notícias como falsas ou reais.

Para isso, serão analisados os principais LLMs em combinação com técnicas de XAI/*reasoning*, visando avaliar a porcentagem de veracidade de uma determinada afirmação ou artigo. Além disso, busca-se incentivar a disseminação responsável de informações, contribuindo para a redução da propagação de notícias falsas e para o aumento da confiabilidade das análises. Para alcançar o objetivo geral, este projeto estabelece cinco objetivos específicos:

- Analisar os principais modelos de LLMs aplicados à detecção de notícias falsas, avaliando sua eficácia na classificação de informações.
- Investigar o impacto do *reasoning* para aprimorar a explicabilidade das previsões realizadas pelos LLMs.
- Testar e validar a precisão do modelo em um conjunto de dados de notícias reais e falsas, utilizando primeiro dados internos e, posteriormente, dados externos dos modelos.

1.6 Questões de Pesquisa e Hipótese

Propõe-se explorar estratégias para desenvolver um modelo de conhecimento aprimorado que auxilie o público a identificar e evitar armadilhas associadas a notícias falsas, como desinformação, conteúdos enganosos, rumores e avaliações manipuladas intencionalmente para distorcer a percepção pública. Adicionalmente, esta não é uma pesquisa para aferir uma verdade absoluta, mas sim para fornecer ferramentas que possibilitem que as pessoas avaliem a confiabilidade das fontes informativas e ajam de acordo com decisões mais embasadas. Portanto, o foco deste estudo é responder à seguinte questão de pesquisa:

1. Qual é a eficácia e o potencial dos principais modelos de LLMs na classificação de notícias falsas?

Portanto, a hipótese deste estudo é: a integração de LLMs com técnicas de *reasoning* pode aumentar significativamente a precisão na identificação de notícias falsas, tornando os processos de verificação mais transparentes e interpretáveis para os usuários.

1.7 Justificativa

A fabricação de notícias falsas não é um fenômeno recente. Estudos indicam que, antes mesmo da criação da internet, já circulavam informações manipuladas com o intuito de enganar a população (Aldwairi; Alwahedi, 2018; Mahara *et al.*, 2023). Um exemplo clássico ocorreu em 1835, quando o jornal *The Sun*, de Nova York, publicou uma série de seis artigos sobre a suposta existência de vida na Lua, um evento que ficou conhecido como a "Grande Fraude da Lua" (Vida, 2012). No cenário contemporâneo, em 2016, narrativas políticas falsas ou altamente enganosas, amplificadas principalmente por meio das redes sociais, foram disseminadas com o

objetivo de influenciar indiretamente a eleição presidencial dos EUA e o referendo do Brexit no Reino Unido (Lazer *et al.*, 2018).

A desinformação também teve um impacto significativo durante a pandemia de COVID-19, representando um grande desafio tanto para os profissionais de saúde, que estavam atuando na contenção da doença, quanto para a credibilidade das instituições públicas (Zhao *et al.*, 2023b). Essas organizações enfrentaram dificuldades para corrigir a ampla disseminação de informações falsas veiculadas nas redes sociais, o que comprometeu a confiança da população nas diretrizes científicas (Loomba *et al.*, 2020).

Além disso, conteúdos hiperpartidários enganosos, assim como manchetes sensacionalistas publicadas por jornais, revistas e portais de baixa credibilidade, têm sido amplamente utilizados para manipular a opinião pública (Miró-Illinares; Aguerri, 2021). As chamadas notícias hiperpartidárias não são necessariamente fabricadas, mas tratam de acontecimentos reais com um viés político acentuado, distorcendo os fatos para favorecer determinadas narrativas (Pennycook; Rand, 2021). Esses conteúdos, que muitas vezes visam a maximização das vendas ou gerar engajamento digital — um fenômeno semelhante ao jornalismo de tabloide —, são apontados como potenciais catalisadores da polarização política (Faris *et al.*, 2017).

Outro fato importante é que a proliferação de *fake news* representa um desafio crítico para o bem-estar social, a confiança pública e os processos democráticos (Allcott; Gentzkow, 2017). Essas notícias falsas possuem o potencial de incitar o medo, manipular a opinião pública e influenciar decisões cruciais (Naeem; Bhatti, 2020). Para mitigar os impactos negativos da disseminação de *fake news*, torna-se imprescindível detectá-las, especialmente em seus estágios iniciais, antes que se tornem virais nas plataformas digitais (Aïmeur; Brassard, 2023).

Embora sites de verificação de fatos, como PolitiFact e Snopes, utilizem profissionais especializados para realizar a checagem manual das informações, a rápida propagação da desinformação na era digital torna esse processo extremamente trabalhoso, demorado e pouco escalável (Graves; Amazeen, 2019). Como resposta a esse desafio, nos últimos anos, foram desenvolvidos modelos baseados em IA para automatizar a verificação de fatos e aprimorar a detecção de notícias falsas (Liao *et al.*, 2023; Popat *et al.*, 2018).

A noção de explicabilidade também tem sido debatida por cientistas sociais, especialistas em ética e pesquisadores da área técnica, que já propuseram diversas soluções aplicadas a diferentes domínios, como o processamento de imagens e métodos que lidam com a incerteza (Bobek; Nalepa, 2021). As discussões acerca da explicabilidade da IA, frequentemente referida como XAI, evidenciam a crescente conscientização sobre sua importância como um aspecto fundamental para o desenvolvimento de sistemas de IA (Hassija vinay chamola, 2024; Saeed; Omlin, 2023; Liao; Vaughan, 2023). Essa capacidade é considerada tão essencial que se tornou um dos principais requisitos para o projeto e implementação de soluções baseadas em IA, ao lado de outros princípios como justiça, transparência e segurança (Kula *et al.*, 2020; Cortese *et al.*, 2023).

Nesse contexto, o presente trabalho se justifica pela necessidade de aprimorar os métodos de verificação de fatos, combinando LLMs com técnicas *reasoning*, a fim de aumentar

a transparência e a interpretabilidade dos modelos de detecção (Wu *et al.*, 2024). A pesquisa pretende contribuir tanto com o progresso acadêmico quanto com o desenvolvimento de soluções práticas que possam ser aplicadas por jornalistas, pesquisadores e cidadãos comuns no combate à desinformação. Além disso, este estudo busca oferecer um sistema que auxilie na escolha de fontes confiáveis, promovendo um ambiente digital mais seguro e informativo.

1.8 Organização do Trabalho

A presente proposta está estruturada em seis capítulos principais, conforme descrito a seguir:

- O **Capítulo 1 – Introdução** apresenta o contexto geral da pesquisa, seus objetivos gerais e específicos, a justificativa para a realização do estudo, a hipótese norteadora e as questões de pesquisa que se busca responder.
- O **Capítulo 2 – Revisão de Literatura** fornece uma base teórica sólida sobre os conceitos centrais da pesquisa. São abordados os principais tipos de *fake news*, os fundamentos de IA e seus subcampos relevantes, com destaque para aprendizado de máquina, aprendizado profundo e os Modelos de Linguagem de Grande Escala.
- O **Capítulo 3 – Trabalhos Relacionados** apresenta um mapeamento crítico das pesquisas mais recentes voltadas à detecção de *fake news* com o uso de LLMs. A seção é estruturada em subseções temáticas, explorando desde abordagens baseadas em classificação textual até estratégias multimodais e estudos específicos sobre o cenário brasileiro.
- O **Capítulo 4 – Metodologia** detalha as etapas práticas que serão adotadas para a execução do trabalho, incluindo a aquisição e preparação do conjunto de dados em português, a seleção e avaliação dos LLMs mais promissores, a construção de estratégias de *prompting* e a aplicação de técnicas de XAI.
- O **Capítulo 5 – Resultados e Discussão** apresenta os resultados obtidos da aplicação da metodologia proposta, focando principalmente no desempenho dos modelos de linguagem em diferentes técnicas de *prompting*. São consideradas tanto métricas quantitativas de classificação, que englobam Acurácia, Precisão, *Recall* e *F1-Score*, quanto aspectos qualitativos referentes à interpretação das respostas geradas. Além disso, o capítulo também discute o impacto na tomada de decisão dos modelos proveniente do uso de conhecimento externo e raciocínio estruturado, fazendo uma comparação das performances individuais das arquiteturas, assim como a qualidade das justificativas produzidas sob a ótica da XAI.
- O **Capítulo 6 – Conclusão** sintetiza as conclusões mais significativas da pesquisa, reiterando os objetivos propostos e as questões levantadas a partir dos resultados ob-

tidos. São destacadas as contribuições do trabalho para a área de detecção de *fake news* e para o uso de modelos de linguagem com estratégias de raciocínio e explicabilidade. O capítulo também aborda as limitações identificadas ao longo do desenvolvimento da aplicação *Aletheia*, como custos computacionais e restrições metodológicas, além de apontar caminhos para pesquisas futuras.

2 REVISÃO DE LITERATURA

É essencial, para o desenvolvimento de métodos automáticos de detecção de *fake news*, dispor de um entendimento teórico do fenômeno da desinformação e de sua relação com os avanços das tecnologias de IA. Portanto, neste capítulo, são apresentados os principais conceitos relacionados ao fenômeno da desinformação, com ênfase nas definições e tipologias de *fake news*, incluindo classificações baseadas em intenção e estilo textual. Em seguida, são explorados os fundamentos da IA e seus subcampos relevantes para este trabalho: aprendizado de máquina, aprendizado profundo e, especialmente, os LLMs.

2.1 Compreendendo *Fake News* e seus Tipos

A expressão *fake news* ganhou notoriedade mundial a partir da segunda metade da década de 2010, tornando-se um fenômeno central no debate sobre os efeitos das tecnologias digitais na esfera pública. Diversos episódios ao redor do mundo evidenciaram o papel estratégico da desinformação em contextos políticos e sociais. No Brasil, a campanha presidencial de 2018 também foi profundamente marcada pela circulação massiva de notícias falsas, a ponto de a missão observadora da Organização dos Estados Americanos (OEA) qualificar o fenômeno como “sem precedentes” ([Galhardo, 2018](#)).

Contudo, as consequências da desinformação não se restringem somente aos processos deliberativos formais. Em certos contextos, como na Índia, mensagens falsas que circulavam pelo WhatsApp alimentaram tensões étnicas e religiosas, o que contribuiu diretamente para episódios de violência e homicídios ([News, 2018](#)). Esses acontecimentos demonstram que a disseminação de conteúdo enganoso não apenas compromete a integridade de sistemas democráticos, mas também pode gerar consequências sociais graves e irreversíveis.

Allcott e Gentzkow ([Allcott; Gentzkow, 2017](#)) caracterizam “fake news” como “artigos de notícias que são falsos intencionalmente ou passíveis de verificação e que podem enganar os leitores”. Autoridades internacionais e a comunidade acadêmica têm gradualmente abandonado o uso do termo *fake news*, considerando que o mesmo foi banalizado e muitas vezes utilizado como ferramenta retórica por grupos políticos para deslegitimar opiniões divergentes ou desconfortáveis, rotulando-as indiscriminadamente como *fake news* ([Valente, 2019](#)).

Segundo o pesquisador Zuckerman ([Zuckerman, 2017](#)) *fake news* “é um termo vago e ambíguo que abrange tudo, desde o falso equilíbrio (notícias reais que não merecem nossa atenção), propaganda (discurso projetado para apoiar um partido em detrimento do outro) e *disinformatzya* (informações para gerar dúvidas e aumentar a desconfiança nas instituições)”. *Fake news* são uma forma específica de desinformação, caracterizada pela disseminação de conteúdos enganosos em formatos que imitam notícias ou documentários, seja por veículos tradicionais ou por meios ilegítimos que reproduzem a estética do jornalismo sem adotar suas boas práticas ([Ruiz, 2025](#)).

De acordo com Tandoc et al. (Tandoc; Lim; Ling, 2017), *fake news* pode ser interpretada como conteúdo jornalístico fabricado com a intenção deliberada de enganar, geralmente motivado por interesses políticos, financeiros ou ideológicos. Com o tempo, o termo passou a incluir diversos tipos de informação — tal como sátira, paródia, propaganda e manipulação — até se consolidar como uma expressão popular de múltiplos sentidos. Apesar do fato de que as notícias falsas são um modo de desinformação (Wardle, 2017), pesquisas acadêmicas que tem o termo *fake news* como objeto de interesse, tentaram mapear o uso e as interpretações diferentes do termo. Nesse contexto, Tandoc et al. propuseram uma tipologia que classifica *fake news* em seis categorias principais: sátira, paródia, fabricação, manipulação, propaganda e publicidade.

Wardle e Derakhshan (Wardle; Derakhshan, 2017) desenvolveram uma taxonomia abrangente da desinformação, que consiste de três categorias principais: *misinformation* (informação falsa que é compartilhada sem a intenção de causar dano — por exemplo, os rumores sobre um segundo oficial da polícia morto no ataque aos *Champs-Élysées*, em 2017), *disinformation* (informação deliberadamente enganadora e com a intenção de causar dano — por exemplo, a falsificação do jornal *Le Soir* acusando Macron de financiamento saudita ou os *bots* no *Twitter* espalhando *hashtags* caluniosas) (News, 2017; Saeed, 2017) e *malinformation* (informação verdadeira e utilizada de forma maliciosa, como o vazamento estratégico dos e-mails de Macron antes do segundo turno das eleições presidenciais francesas de 2017) (Donadio, 2017).

Dependendo do grau de intencionalidade e do contexto, as *fake news* podem se enquadrar em mais de uma dessas categorias. Além disso, Wardle (Wardle, 2017) identifica sete tipos de informação falsa e desinformação, revelando a diversidade de conteúdos problemáticos no ambiente *online* — desde sátiras e paródias (formas de expressão artística que podem ser mal interpretadas) até conteúdos completamente fabricados. Esses sete tipos são: sátira ou paródia, conteúdo tendencioso, conteúdo impostor, conteúdo fabricado, conexão falsa, contexto falso e conteúdo manipulado. Diversos tipos de *fake news* têm sido catalogados na literatura. A Tabela 1 resume as principais tipologias encontradas:

Tabela 1 – Classificação de *fake news* com base em Wardle e Derakhshan (2017) (Wardle; Derakhshan, 2017), Shu et al. (2017) (Shu et al., 2017), Tandoc et al. (2017) (Tandoc; Lim; Ling, 2017).

(continua)

Tipo de <i>Fake News</i>	Descrição	Exemplo
Sátira ou Paródia	Conteúdo humorístico baseado em eventos reais ou inventados, sem intenção de causar dano, mas pode enganar	Programas como <i>The Daily Show</i> ; artigos do <i>The Onion</i>
Conteúdo Fabricado	Conteúdo totalmente falso criado para enganar ou gerar lucro/poder	"Papa apoia candidato político" (sem nenhum fato real)
Conteúdo Manipulado	Conteúdo genuíno alterado de maneira enganosa, especialmente imagens e vídeos	Foto da Estátua da Liberdade durante o furacão Sandy manipulada

Classificação de *fake news* com base em Wardle e Derakhshan (2017) (Wardle; Derakhshan, 2017), Shu et al. (2017) (Shu et al., 2017), Tandoc et al. (2017) (Tandoc; Lim; Ling, 2017).

(continuação)

Tipo de <i>Fake News</i>		Descrição	Exemplo
Contexto Falso		Conteúdo verdadeiro compartilhado com informações falsas ou retirado de contexto	Vídeos antigos de protestos divulgados como se fossem atuais
Conexão Falsa		Títulos, legendas ou imagens não correspondem ao conteúdo	Manchete sensacionalista que não reflete o conteúdo da matéria
Conteúdo Im-postor		Fontes legítimas são falsificadas ou imitadas	Site falso imitando visualmente o <i>The Guardian</i>
Conteúdo Tendencioso		Informações apresentadas de maneira distorcida para favorecer um lado	Notícia omitindo fatos para beneficiar um partido político
Teorias da Conspiração		Explicações fantasiosas para eventos complexos, sugerindo agentes ocultos	"Vacinas contêm chips de rastreamento"
<i>Clickbait</i>		Títulos exagerados ou enganosos usados para atrair cliques	"Você não vai acreditar no que ela fez!"
Publicidade disfarçada		Conteúdo promocional apresentado como notícia legítima	VNRs (Vídeos de imprensa) usados em telejornais sem identificação clara
Propaganda		Conteúdo criado para promover uma agenda política, muitas vezes usando informações falsas ou distorcidas	Notícias manipuladas transmitidas em canais estatais para moldar a opinião pública

Fonte: Wardle e Derakhshan (2017), Shu et al. (2017), Tandoc, Lim e Ling (2017)

O que essas definições têm em comum é a forma como as *fake news* se apropriam da estética e dos códigos do jornalismo legítimo: desde a diagramação de *sites* que imitam veículos tradicionais até a redação de artigos com linguagem supostamente factual e o uso de imagens com atribuições enganosas. Além disso, não se limitam a simular a aparência de um conteúdo jornalístico: com o auxílio de *bots* e redes de *sites* falsos interligados, reproduzem a ubiquidade e a viralidade típicas do ecossistema midiático digital. Essa tática revela um paradoxo: ao mesmo tempo que reconhecem (e instrumentalizam) o papel central do jornalismo na sociedade, as *fake news* corroem sua legitimidade, especialmente em ambientes como as redes sociais, onde a fonte da informação é frequentemente obscurecida ou diluída pela dinâmica de compartilhamento (Shu et al., 2017).

As definições acadêmicas de *fake news* podem ser agrupadas em dois eixos principais: facticidade (em que grau o conteúdo é factual) e intencionalidade (se o objetivo é enganar) (Tandoc; Lim; Ling, 2017). A sátira, por exemplo, utiliza fatos para fins de humor, e as notícias fabricadas fabricam informações que não têm sustentação no mundo real. A outra dimensão é a intenção, que pode variar de um divertimento (como a paródia) até a intenção de manipular

(como em conteúdos fabricados para lucros ou para desinformar). Essas dimensões permitem distinguir *fake news* de outras formas de conteúdos, como artigos de opinião, que não são falsos só por expressarem visões críticas. Além disso, o impacto das fake news depende da audiência: elas só funcionam se forem percebidas como reais, especialmente em redes sociais, onde a viralidade pode substituir a verificação. Assim, o ponto de vista do problema não diz respeito somente ao conteúdo, mas à compreensão e ao compartilhamento do mesmo.

2.2 Fundamentos de Inteligência Artificial e Subcampos Relevantes

A IA é uma disciplina multidisciplinar que trabalha no desenvolvimento de sistemas que se propõem a realizar tarefas que tipicamente envolvem inteligência humana, como a percepção, o raciocínio, o aprendizado e a tomada de decisão (Bhuyan *et al.*, 2024). Sua evolução histórica registra várias concepções sobre a natureza da IA, que variou entre duas visões elementares: a fidelidade ao comportamento humano e a racionalidade formal. Esta última entendida como a capacidade de selecionar ações ótimas para alcançar determinados objetivos (Russell; Norvig, 2021). Por exemplo:

1. Abordagens Humanas:

- Agir humanamente (Teste de Turing): Foca em simular comportamentos humanos, como linguagem e aprendizado, para enganar um observador.
- Pensar humanamente (Modelagem Cognitiva): Busca replicar processos mentais humanos, usando psicologia e neurociência.

2. Abordagens Racionais:

- Pensar racionalmente (Lógica): Baseia-se em regras formais (como lógica e probabilidade) para inferências corretas, mas ignora ações práticas.
- Agir racionalmente (Agente Racional): Prioriza ações autônomas que maximizam resultados, mesmo sob incerteza — a abordagem mais adotada hoje, aplicada em áreas como robótica e aprendizado de máquina.

A evolução contemporânea da IA consolida-se na abordagem do agente racional, que integra três pilares fundamentais: (1) representação estruturada de conhecimento, (2) mecanismos de raciocínio automatizado e (3) capacidade de aprendizado contínuo (Macedo, 2025). Essa tríade permite que sistemas funcionem em ambientes incertos e complexos, tomando decisões ótimas dentro de limites computacionais práticos. Aplicações em controle automático e sistemas econômicos demonstram como essa abordagem supera as limitações dos paradigmas anteriores, equilibrando fundamentação teórica (com técnicas de probabilidade e otimização) e eficácia operacional.

Ademais, a era do *Big Data* catalisou o potencial dessas abordagens. A disponibilidade de grandes volumes de dados heterogêneos - desde textos e imagens até registros genômicos e

transacionais - permitiu treinar modelos cada vez mais complexos (Yu *et al.*, 2019). Dois *insights* fundamentais emergiram: (1) em muitos casos, a quantidade de dados superava em importância o refinamento algorítmico (Banko; Brill, 2001), e (2) até mesmo dados não rotulados poderiam ser aproveitados por meio de técnicas de aprendizado semi-supervisionado. Acervos de dados como *ImageNet* (com 14 milhões de imagens categorizadas) e marcos como a vitória do *Watson* no *Jeopardy!* (2011) demonstraram o poder dessa sinergia entre dados massivos e algoritmos adaptativos (You *et al.*, 2018).

Essa convergência histórica preparou o terreno para os três elementos fundamentais da IA moderna que serão examinados nesta seção: (1) os algoritmos de aprendizado de máquina que extraem conhecimento de dados empíricos; (2) as arquiteturas de aprendizado profundo que permitem representações hierárquicas complexas; e (3) os modelos de linguagem em grande escala que estão redefinindo a fronteira entre sistemas computacionais e capacidades cognitivas humanas. A Figura 1 apresenta a organização hierárquica das principais subáreas da IA.




Figura 1 – Subcampos da Inteligência Artificial
Fonte: Autoria própria (2026).

2.3 Aprendizado de Máquina (*Machine Learning* — ML)

A IA passou por uma transformação significativa com a ascensão do aprendizado de máquina, que se consolidou como o paradigma dominante, marcando uma transição histórica dos sistemas baseados em regras para métodos orientados por dados (Russell; Norvig, 2021). Essa mudança foi catalisada por três fatores principais: (1) a limitação dos sistemas especialistas em lidar com a ambiguidade e a complexidade do mundo real; (2) avanços teóricos significativos nos campos da estatística e da probabilidade; e (3) o crescimento exponencial na disponibilidade de dados computáveis. Na prática, o ML se organiza em três paradigmas fundamentais (Goodfellow; Bengio; Courville, 2016):

1. **Aprendizado supervisionado:** Modelos treinados com dados rotulados (ex: classificação de imagens)
2. **Aprendizado não supervisionado:** Descoberta de padrões em dados não rotulados (ex: agrupamento de clientes)
3. **Aprendizado por reforço:** Sistemas que aprendem por meio da interação e *feedback* (ex: jogos estratégicos)

Técnicas como Máquinas de Vetores de Suporte (*Support Vector Machine* – SVM), florestas aleatórias e regressão logística tornaram-se ferramentas aplicáveis desde diagnósticos médicos até sistemas de recomendação. No entanto, aplicações em domínios complexos como Processamento de Linguagem Natural (*Natural Language Processing* – NLP) e Visão Computacional ainda enfrentavam um gargalo crítico: a necessidade de engenharia de recursos manual (Bommasani *et al.*, 2022). Especialistas dedicavam esforços consideráveis para transformar dados brutos (*pixels* ou palavras) em representações matemáticas adequadas, como os descritores SIFT para imagens ou *features* linguísticas para textos.

Essa limitação fundamental preparou o cenário para o surgimento do aprendizado profundo, que prometia automatizar não apenas o aprendizado de padrões, mas também a própria extração de características relevantes dos dados. A convergência entre modelos neurais profundos, poder computacional massivo e conjuntos de dados em larga escala (como ImageNet) permitiria superar essa barreira histórica, como será abordado na próxima seção.

2.4 Aprendizado Profundo (*Deep Learning* — DL)

O DL possibilita que os algoritmos construam representações hierárquicas diretamente de dados brutos, eliminando a necessidade de engenharia manual de características (Bommasani *et al.*, 2022). Seu surgimento foi possibilitado por três fatores convergentes (Lecun; Bengio; Hinton, 2015): (1) a existência de grandes volumes de dados (como o ImageNet, com seus 14 milhões de imagens classificadas), (2) a evolução de equipamentos específicos (principalmente as GPUs) e (3) inovações arquitetônicas em redes neurais.

O marco decisivo ocorreu em 2012, quando a AlexNet (Krizhevsky; Sutskever; Hinton, 2017), desenvolvida pela equipe de Geoffrey Hinton, diminuiu pela metade a taxa de erro na competição ImageNet, superando radicalmente os métodos tradicionais de visão computacional. Essa conquista evidenciou a capacidade das redes neurais convolucionais (CNNs) de identificar automaticamente características hierárquicas - de bordas simples a formas complexas - diretamente de *pixels*. Rapidamente, o DL passou a dominar *benchmarks* em diversas áreas:

- **Processamento de Linguagem Natural:** Redes recorrentes (RNNs) e mecanismos de atenção superaram métodos estatísticos tradicionais;
- **Jogos Estratégicos:** O AlphaGo da DeepMind (2016) derrotou campeões mundiais de Go aprendendo diretamente de partidas;

- **Diagnóstico Médico:** Sistemas como DeepMind Health alcançaram alta *performance* em detecção de anomalias em imagens médicas.

Embora a neurociência tenha sido a faísca inicial, os modelos atuais de DL evoluíram para além de simples analogias biológicas. O termo "profundo" refere-se à capacidade desses sistemas de aprender representações em múltiplos níveis de abstração - desde características primitivas até conceitos complexos (Goodfellow; Bengio; Courville, 2016). Essa propriedade permite que uma única arquitetura, como os Transformers (Vaswani *et al.*, 2023), seja aplicada a domínios diversos, desde visão até linguagem. Contudo, o DL ainda enfrenta desafios fundamentais:

1. **Dependência de dados rotulados:** A maioria das arquiteturas requer conjuntos de treinamento massivos e anotados
2. **Fragilidade em generalização:** Sensibilidade a variações não vistas durante o treinamento
3. **Opacidade interpretativa:** Dificuldade em entender o processo decisório interno (o "problema da caixa-preta")

2.5 Modelos de Linguagem de Grande Escala (*Large Language Models — LLMs*)

Um tipo de modelo de linguagem que se destaca é o LLM, que utiliza uma quantidade enorme de parâmetros, variando de bilhões a trilhões, que é treinado com tarefas de pré-treinamento como a modelagem de linguagem mascarada e a predição autorregressiva. O objetivo é compreender, processar e gerar linguagem humana de maneira contextualizada e semântica, aprendendo com uma vasta quantidade de dados textuais. Segundo Yang et al. (2023) (Yang yuchen wei, 2023), um LLM competente deve apresentar quatro características essenciais: (i) compreensão profunda da linguagem natural, captando nuances contextuais; (ii) geração de textos que soem naturais e fluentes como se fossem escritos por pessoas; (iii) consciência contextual, especialmente em áreas que demandam um conhecimento específico; e (iv) forte capacidade de seguir instruções, fundamental para a resolução de problemas e processos decisórios.

Em 2023, vários LLMs importantes foram disponibilizados, marcando um crescimento expressivo na popularização dessa tecnologia. Entre os exemplos mais conhecidos, estão o ChatGPT da OpenAI (Openai *et al.*, 2024), o LLaMA da Meta AI (Ai, 2023) e o Dolly 2.0 da Databricks (Databricks, 2023). O ChatGPT, por exemplo, atingiu mais de 180 milhões de usuários em novembro de 2023 (Duarte, 2023). Esses modelos oferecem uma ampla gama de aplicações práticas, não apenas em tarefas tradicionais de NLP como a pesquisa de dados, a tradução e o suporte ao cliente, mas também em campos como geração de código, assistência médica, análise financeira e educação. Essa versatilidade demonstra o papel crescente dos LLMs como impulsionadores de progresso em diferentes segmentos da economia e da sociedade.

Os Grandes Modelos de Linguagem representam um avanço considerável se comparados aos primórdios da modelagem estatística em NLP. Com a introdução da arquitetura Transformer (Vaswani *et al.*, 2023), tornou-se possível ampliar a capacidade dos modelos de forma sem precedentes. Atualmente, os LLMs são treinados em conjuntos de dados extensivos e contam com centenas de bilhões de parâmetros, gerando avanços notáveis no campo do NLP (Feng *et al.*, 2021) e impactando setores como avaliação de risco, detecção de vulnerabilidades, medicina de precisão e otimização de mecanismos de busca.

Segundo Yang et al. (2023) (Yang yuchen wei, 2023), um LLM ideal deve demonstrar: (i) profunda compreensão e interpretação de textos, permitindo ações complexas como tradução e sumarização automática; (ii) capacidade de geração textual natural e coesa; (iii) forte consciência contextual e expertise em domínios específicos (modelos *knowledge-intensive*); e (iv) habilidade para resolver problemas e tomar decisões baseadas em dados textual. A Tabela 2 (adaptada do MindsDB, 2025 (Slawinska; Mardini, 2025) e Sapling, 2025 (Ai, 2025)) apresenta um panorama comparativo dos principais LLMs, destacando provedores como OpenAI, Google, Meta AI, Anthropic e Cohere. Observa-se que, enquanto modelos como o GPT-4 e o Claude (Anthropic) são de código fechado, iniciativas como BERT, T5, PaLM e LLaMA mantêm-se abertas, impulsionando o desenvolvimento colaborativo e personalizado.

Tabela 2 – Comparação de LLMs populares com base em MindsDB, 2025 (Slawinska; Mardini, 2025) e Sapling, 2025 (Ai, 2025)

(continua)					
Modelo	Lançamento Inicial	Provedor	Open-Source	Parâmetros	Ajustável (Fine-tuned)
BERT (Devlin <i>et al.</i> , 2019)	08-2018	Google	Sim	340 milhões	Sim
Command R+	08-2024	Cohere	Não	14 bilhões	Sim
Command R	08-2024	Cohere	Não	14 bilhões	Sim
ChatGPT-4o	13-05-2024	OpenAI	Não	~1 trilhão (estimado)	Não
ChatGPT-4	14-03-2023	OpenAI	Não	~1 trilhão (estimado)	Não
Claude 3.5 Sonnet	04-2024	Anthropic	Não	Desconhecido	Sim
Claude 3.5 Haiku	04-2024	Anthropic	Não	Desconhecido	Sim
Claude 3 Opus	03-2024	Anthropic	Não	Desconhecido	Sim
DeepSeek V3	06-2024	DeepSeek	Não	+ de 100 bilhões	Sim
DeepSeek-Coder V2	05-2024	DeepSeek	Sim	33 bilhões	Sim
Dolly2.0 (Databricks, 2023)	04-2023	Databricks	Sim	12 bilhões	Sim
Gemini 2.0 Flash	05-02-2025	Google	Não	+ de 540 bilhões	Sim

Comparação de LLMs populares com base em MindsDB, 2025 (Slawinska; Mardini, 2025) e Sapling, 2025 (AI, 2025)

(continuação)

Modelo	Lançamento Inicial	Provedor	Open-Source	Parâmetros	Ajustável (Fine-tuned)
Gemini 1.5 Flash	23-05-2024	Google	Não	Desconhecido	Sim
Gemini 1.5 Pro	23-05-2024	Google	Não	Desconhecido	Sim
Gemma 2	27-06-2024	Google	Sim	27 bilhões	Sim
GPT-3.5-turbo	30-11-2022	OpenAI	Não	175 bilhões	Não
Grok-3	02-2025	xAI	Não	Desconhecido	Sim
Grok-2	13-07-2024	xAI	Não	Desconhecido	Desconhecido
Grok-1	05-11-2023	xAI	Sim	314 bilhões	Sim
Llama 3	09-2024	Meta AI	Sim	90 bilhões	Sim
Llama 2	2023	Meta AI	Sim	70 bilhões	Sim
LLaMA	2022	Meta AI	Sim	65 bilhões	Sim
PaLM (Narang; Chowdhery, 2022)	04-2022	Google	Sim	540 bilhões	Sim
Phi-3	23-04-2024	Microsoft	Não	14 bilhões	Sim
Qwen 2	06-2024	Alibaba Cloud	Parcialmente	72 bilhões	Sim
Qwen 1	09-2023	Alibaba Cloud	Parcialmente	32 bilhões	Sim

Fonte: Slawinska e Mardini (2025), AI (2025)

Um ponto de destaque é a dimensão desses modelos: o PaLM, para ilustrar, possui 540 bilhões de parâmetros, o que aponta para seu alto desempenho, mas também para uma grande necessidade de poder computacional. A propriedade de ajustabilidade (*fine-tuning*) é igualmente essencial, possibilitando adequar modelos genéricos para tarefas específicas, como análise de sentimentos em resenhas de filmes ou detecção de fraudes financeiras. O rápido avanço dos LLMs, aliado à sua ampla aplicabilidade, evidencia que esses modelos não apenas redefiniram os limites técnicos do NLP, mas também abriram novas fronteiras para a inovação em áreas críticas como segurança da informação, programação assistida e raciocínio automatizado.

3 TRABALHOS RELACIONADOS

A evolução dos LLMs transformou as estratégias de detecção de notícias falsas, substituindo gradualmente abordagens tradicionais que dependiam bastante de dados auxiliares e recursos externos. Atualmente, os métodos mais eficientes se concentram em três áreas centrais: a **classificação textual**, que visa identificar automaticamente padrões linguísticos e semânticos indicativos de desinformação; a **verificação e checagem de fatos**, que explora o potencial dos LLMs para buscar, correlacionar e avaliar evidências textuais; e a **análise contextual**, que leva em conta os elementos discursivos, sociais e situacionais que cercam uma notícia (Papageorgiou *et al.*, 2024). Cada uma dessas abordagens tem se mostrado promissora no aumento da precisão e da interpretabilidade dos sistemas de detecção, sendo alvo de muito estudo por parte da comunidade científica. As subseções a seguir analisam os principais trabalhos que representam o estado da arte nessas três linhas, com foco especial na aplicabilidade e desempenho dos LLMs no cenário contemporâneo de combate à desinformação.

3.1 Classificação Textual com LLMs

Essa abordagem se apoia na modelagem supervisionada de grandes conjuntos de dados linguísticos previamente treinados, que são ajustados por meio de técnicas de *fine-tuning* para distinguir entre conteúdos verídicos e enganosos (Roumeliotis; Tselikas; Nasiopoulos, 2025). A robustez dos LLMs faz com que eles sejam bons para identificar padrões linguísticos sutis e recorrências discursivas típicas da desinformação (Zellers *et al.*, 2020; Boissonneault; Hensen, 2024). Em contrapartida às abordagens tradicionais baseadas em *features* manuais e classificadores simples, os LLMs oferecem ganhos expressivos em métricas como precisão, *F1-score* e acurácia, mesmo em cenários de dados ruidosos ou desbalanceados (Upadhyay; Pasi; Viviani, 2023; Alesawi; Al-tai, 2024). Além disso, esses modelos demonstram capacidade de generalização para domínios diversos, como política, saúde pública e desinformação em diferentes idiomas, destacando sua versatilidade e aplicabilidade em escala global.

3.1.1 ChatGPT e Gemini na Classificação de Desinformação

O estudo *On the Opportunities and Risks of Foundation Models* (Boissonneault; Hensen, 2024) propõe uma abordagem baseada no ajuste fino de LLMs de última geração, como o ChatGPT e o Google Gemini, para a tarefa de detecção de notícias falsas. Os modelos, previamente treinados com muitos dados textuais, foram refinados especificamente no conjunto de dados *LIAR*, com o objetivo de adaptar sua compreensão geral da linguagem à identificação de declarações enganosas (Buchholz, 2023; Aslan; Ptaszynski; Jauhiainen, 2024). O processo de ajuste envolveu a otimização dos parâmetros dos modelos para maximizar sua capacidade de distinguir entre afirmações verdadeiras e falsas, ao mesmo tempo em que explora indícios linguísticos e contextuais sutis presentes nos textos.

O conjunto de dados *LIAR*, amplamente utilizado na literatura, reúne declarações políticas rotuladas com diferentes graus de veracidade (como verdadeiro, falso, parcialmente verdadeiro, entre outros), além de fornecer metadados relevantes, como o nome do orador, a afiliação partidária e o contexto da fala (Wang, 2017). Essa variedade de informações ajuda a treinar modelos mais sensíveis aos elementos linguísticos e pragmáticos que caracterizam a desinformação. Os resultados experimentais indicaram que tanto o ChatGPT quanto o Google Gemini alcançaram desempenho superior em métricas padrão de classificação, como acurácia, precisão, *recall*, *F1-score* e *AUC-ROC* (do inglês *Area Under the Curve - Receiver Operating Characteristic*). Ainda assim, os autores observaram que algumas falhas de classificação ocorreram diante de padrões linguísticos ambíguos ou afirmações altamente contextuais, revelando limitações dos modelos frente a casos mais sutis de desinformação.

3.1.2 Fake News em Árabe: *AraBERT* com Mecanismo de Atenção

O estudo *Detecting Arabic Misinformation Using an Attention Mechanism-Based Model* (Alesawi; Al-tai, 2024) apresenta uma abordagem baseada em aprendizado profundo para a detecção de desinformação em textos árabes, área ainda pouco explorada quando comparada ao volume de pesquisas em inglês (Fouad; Sabbeh; Medhat, 2022; Alyoubi; Kalkatawi; Abukhodair, 2023). A arquitetura desenvolvida combina representações contextuais geradas pelo modelo *AraBERT* — um LLM pré-treinado voltado para o idioma árabe, baseado na arquitetura *BERT* — com uma rede Memória de Curto e Longo Prazo Bidirecional (*Bidirectional Long Short-Term Memory* – BiLSTM) e um mecanismo de atenção (Devlin et al., 2019; Antoun; Baly; Hajj, 2021; Karim et al., 2018; Shahid; Zameer; Muneeb, 2020). Essa combinação possibilita a captura de dependências linguísticas bidirecionais e destaca as partes mais relevantes do texto, aprimorando significativamente a distinção entre notícias verídicas e enganosas.

Para treinar e avaliar o modelo, foram utilizadas duas bases de dados específicas: o *AraNews*, que compreende 87.637 amostras de artigos rotulados como reais ou falsos, e o *ArCOV19-Rumors*, focado em rumores sobre *COVID-19*, contendo 3.584 exemplos (Nagoudi et al., 2020; Haouari et al., 2021). As duas bases são anotadas e estão disponíveis publicamente, facilitando o uso em tarefas supervisionadas de identificação de desinformação. A metodologia inclui um rigoroso processo de pré-processamento, extração de características usando o *AraBERT*, modelagem sequencial com BiLSTM e aplicação de uma camada de atenção. Além disso, os hiperparâmetros do modelo foram ajustados por meio de Otimização Bayesiana utilizando o *Keras Tuner*, com modificações nas unidades LSTM, taxas de *dropout*, quantidade de camadas densas e taxa de aprendizado, o que resultou em uma configuração mais eficiente e robusta. Os resultados indicam que a abordagem proposta superou significativamente modelos tradicionais e outras arquiteturas neurais utilizadas anteriormente. O modelo alcançou 96% de acurácia no *ArCOV19-Rumors* e 90% no *AraNews*, valores maiores do que os obtidos por técnicas como *Random Forest*, *Naive Bayes*, CNNs e classificadores baseados em regras. A in-

clusão do mecanismo de atenção foi fundamental, como demonstrado por estudos de ablação, que apontaram ganhos claros de desempenho em comparação a variantes sem essa camada.

3.1.3 Desinformação em Saúde: *BERT* Integrando Conteúdo e Contexto Social

A abordagem *Leveraging Socio-Contextual Information in BERT for Fake Health News Detection in Social Media* (Upadhyay; Pasi; Viviani, 2023) propõe um modelo inovador para descobrir informações de saúde enganosas nas mídias sociais, alavancando o poder dos LLMs, com ênfase especial na arquitetura *BERT*. A ideia central está na incorporação de informações sociocontextuais — como características do autor do *tweet* e métricas de engajamento — diretamente na entrada do modelo *BERT* (Bodnar *et al.*, 2014; Ito *et al.*, 2015). Essa modificação visa capturar nuances contextuais que textos isolados não conseguem mostrar totalmente, aumentando substancialmente a precisão da classificação.

Para a construção do modelo, os autores adaptaram três variantes do *BERT*: *BERT-base*, *BioBERT* e *BERTweet-Covid*, sendo esta última treinada especificamente com dados do *Twitter* durante o período da pandemia (Keya *et al.*, 2022; Pavlov; Mirceva, 2022; Rai *et al.*, 2022). A metodologia incluiu um *pipeline* de pré-processamento, no qual *emojis* foram convertidos em descrições textuais e ruídos como URLs e símbolos irrelevantes foram retirados. Em seguida, os dados textuais foram integrados com atributos sociocontextuais, tais como número de seguidores, *status* de verificação da conta e volume de *retuïtes*. Esses atributos foram normalizados (usando *z-score*, por exemplo) e fundidos com a entrada textual, permitindo ao modelo considerar ao mesmo tempo conteúdo e contexto.

A avaliação experimental foi conduzida em três conjuntos de dados utilizados no estudo de desinformação em saúde: *CMU-MisCOV19*, *CoAID* e *FakeHealth* (Memon; Carley, 2020; Cui; Lee, 2020; Dai; Sun; Wang, 2020). Esses datasets apresentam *tweets* rotulados como verdadeiros ou falsos e incluem metadados sociocontextuais extraídos de perfis de usuários e interações nas plataformas. Os resultados obtidos foram positivos: o modelo baseado em *BERT* com integração de informações sociocontextuais superou consistentemente todas as abordagens baseadas apenas em texto, exibindo os melhores desempenhos em termos de acurácia, *F1-score*, *recall* e precisão. A análise interpretativa com valores SHAP demonstrou que características como a credibilidade do autor e os padrões de engajamento social tiveram papel crucial nas decisões do modelo, conferindo maior transparência ao processo de classificação (Lundberg; Lee, 2017).

No entanto, a utilização de atributos sociocontextuais também traz desafios importantes: esses recursos podem introduzir vieses indesejados, favorecendo certos perfis de usuários e comprometendo a imparcialidade da detecção. Além disso, há limitações quanto à generalização do modelo para outros contextos, como diferentes plataformas de mídia social ou outras categorias de desinformação, exigindo mais estudos quanto à sua robustez e adaptabilidade.

3.2 Verificação e Checagem de Fatos com LLMs

A verificação e checagem de fatos se tornou crucial para enfrentar a disseminação de desinformação, principalmente em áreas sensíveis como política, saúde e ciência. Com o avanço dos LLMs, essa atividade melhorou com métodos que unem raciocínio estruturado, recuperação de evidências e geração natural de linguagem (Papageorgiou *et al.*, 2024). Os LLMs facilitam a identificação de inconsistências factuais, além de possibilitar automatizar partes do trabalho que antes eram feitas por pessoas (Vykopal *et al.*, 2024a). Estudos novos têm investigado formas de usar os LLMs ao máximo nessa função, com técnicas como dividir as informações em pedaços menores, usar instruções específicas por meio de *prompts* para guiar a geração de conteúdo e checar os dados de vários pontos de vista (Cheung; Lam, 2023).

3.2.1 Recuperação por Reforço com *Feedback* para Checagem de Fatos

O método chamado *Feedback Refinado com Recuperação por Reforço* (FFRR) é apresentado no estudo *Reinforcement Retrieval Leveraging Fine-Grained Feedback for Fact Checking News Claims with Black-Box LLM* (Zhang; Gao, 2024) com o objetivo de aprimorar a verificação de fatos em notícias jornalísticas utilizando LLMs de caixa-preta. A proposta se baseia em uma arquitetura de dois níveis de *feedback* (nível de documento e nível de pergunta), ajuda a encontrar evidências mais precisas e contextualizadas. Ao contrário dos métodos comuns de recuperação, o FFRR não utiliza apenas o LLM como componente final de inferência, mas o integra no processo de aprendizado por meio da avaliação da utilidade dos documentos recuperados, o que serve como uma métrica de recompensa para aperfeiçoar a política de recuperação.

O sistema foi construído em torno de um modelo de recuperação densa baseado em codificadores RoBERTa com uma arquitetura de codificador duplo (Liu *et al.*, 2019). Para agilizar a busca por vetores similares, utiliza-se o FAISS (Johnson; Douze; Jégou, 2019). O fluxo de trabalho começa ao decompor a alegação em múltiplas perguntas intermediárias, o que possibilita examiná-la sob perspectivas variadas. Cada pergunta guia a recuperação de documentos relevantes, e o LLM avalia individualmente esses documentos com base em sua utilidade factual — fornecendo recompensas em dois níveis: no nível do documento, pela qualidade geral da evidência; e no nível da pergunta, pela sua contribuição específica para a resposta à subquestão formulada.

Os experimentos foram realizados nos conjuntos de dados RAWFC e LIAR-RAW, que contêm notícias jornalísticas rotuladas por verificadores de fatos (Yang *et al.*, 2022). Foi empregada a API GPT-3.5 (*text-davinci-003*) como o LLM de caixa-preta. Os resultados mostraram que o método FFRR teve um desempenho consideravelmente melhor do que outros métodos de base — tanto modelos LLM com *prompting* direto ou baseado em perguntas quanto técnicas mais sofisticadas como ReAct, REPLUG e Verificar-e-Editar (Zhao *et al.*, 2023a; Yao *et al.*, 2023). As versões combinadas do FFRR (que juntam estratégias de nível de documento e

pergunta) alcançaram os melhores resultados, aumentando a precisão na verificação e a abrangência das evidências. A pesquisa também apontou que coletar mais documentos (até um limite) melhora o resultado e que não ter recompensas ao longo do processo diminui a qualidade final da verificação.

3.2.2 Checagem de Fatos com Decomposição Hierárquica e LLMs

O estudo *Towards LLM-based Fact Verification on News Claims with a Hierarchical Step-by-Step Prompting Method* (Zhang; Gao, 2023) apresenta um método para confirmar informações em notícias, empregando LLMs com a técnica de aprendizado no contexto (ICL) (Brown et al., 2020). O método chamado *Solicitação Hierárquica Passo-a-Passo* (HiSS) é destacado, utilizando uma estrutura hierárquica para quebrar afirmações complexas em partes menores e verificáveis. Essa estrutura possibilita uma análise mais precisa e eficaz, diminuindo os problemas comuns de omissão de raciocínio e alucinação factual. O HiSS se baseia na habilidade dos LLMs de criar perguntas investigativas progressivas, ajustando-as com base nas respostas obtidas e buscando fontes externas para confirmar cada parte da alegação com dados concretos.

Em termos técnicos, a estrutura HiSS se divide em duas etapas cruciais: (1) a decomposição da afirmação inicial em partes menores, criadas com o auxílio de exemplos práticos via *K-shot learning*, (Ousidhoum; Yuan; Vlachos, 2022; Fan et al., 2020) e (2) a análise individual de cada parte com a formulação dinâmica de perguntas e a possibilidade de usar pesquisas na *web* (Yao et al., 2023; Jiang et al., 2023b). Essa análise gradual assegura a cobertura de detalhes explícitos e subentendidos das afirmações. O método foi testado com o modelo GPT-3.5 (*text-davinci-003*), usando *prompts* detalhados que guiam o pensamento do modelo, e se mostrou muito eficaz para diminuir erros de raciocínio e aumentar a segurança das respostas (Wei et al., 2022a).

Na avaliação prática, os autores usaram dois conjuntos de dados públicos: RAWFC (Yang et al., 2022), com afirmações reais rotuladas com explicações, e LIAR (Wang, 2017), um *benchmark* conhecido para checagem de fatos. O método HiSS teve resultados melhores do que as abordagens totalmente supervisionadas e as *baselines* ICL, como o *prompting* padrão, *Chain-of-Thought* (CoT) (Wei et al., 2022a) e *ReAct* (Yao et al., 2023). Em termos de desempenho, o HiSS superou essas alternativas em até 11,65% na *F1-score*, destacando-se na identificação precisa de afirmações complexas. Além disso, um estudo confirmou que tanto a decomposição da afirmação quanto a busca externa são importantes para melhorar o desempenho.

Mesmo com notáveis progressos, o estudo aponta certas restrições consideráveis. A performance global ainda se mostra razoável, refletindo obstáculos como a necessidade de provas externas existentes, limitações de cálculo ligadas ao uso de LLMs proprietários e problemas com afirmações muito intrincadas ou imprecisas. Além disso, a abordagem funciona somente com dados textuais, ignorando outros formatos como imagens e vídeos.

3.2.3 Checagem de Desinformação com LLMs e Supervisão Fraca

No estudo *Detecting Misinformation with LLM-Predicted Credibility Signals and Weak Supervision* (Leite *et al.*, 2023), propõe-se uma forma de identificar notícias falsas em textos jornalísticos extensos, combinando o poder de LLMs com uma supervisão fraca (Helmstetter; Paulheim, 2018; Shu *et al.*, 2019; Shu *et al.*, 2020; Wang *et al.*, 2020). A estrutura proposta tem três etapas principais: primeiro, são extraídos 18 indicadores de credibilidade – como o uso de sensacionalismo, a carga emocional presente e a reputação da fonte – por meio de instruções (*prompts*) bem elaboradas, aplicadas a LLMs como *GPT-3.5-Turbo* (Ouyang *et al.*, 2022), *Alpaca-LoRA-30B* (Taori *et al.*, 2023) e *OpenAssistant-LLaMA-30B* (Köpf *et al.*, 2023). Em seguida, esses indicadores, que podem ser um pouco imprecisos, são reunidos usando a estrutura *Snorkel*, que analisa como os indicadores se relacionam e quão confiáveis são, para gerar classificações probabilísticas sobre a veracidade (Ratner *et al.*, 2017). Por fim, é feita uma classificação em duas categorias (notícia falsa ou confiável) com base nesses indicadores reunidos, sem precisar de dados já classificados para o treinamento. Essa abordagem busca imitar o trabalho dos jornalistas na verificação de fatos, tornando o processo mais transparente e compreensível ao utilizar indicadores conhecidos.

Para avaliar essa metodologia, foram usados dois conjuntos de dados: o FA-KES (Salem *et al.*, 2019), com 804 artigos longos sobre a guerra na Síria, já classificados quanto à veracidade, e o EUvsDisinfo, com 497 artigos de diversas fontes, incluindo exemplos de propaganda pró-Kremlin. Ambos os conjuntos são bastante variados e realistas, o que testa a capacidade da técnica em situações desafiadoras. Os dados foram divididos em 80% para treinamento e 20% para teste, embora a proposta não utilize classificações de verdade no processo de aprendizado — apenas na avaliação. Essa escolha torna a abordagem mais escalável, pois permite trabalhar em cenários nos quais a classificação manual de grandes quantidades de texto seria inviável.

Os resultados mostraram melhorias em relação ao que era feito antes. A técnica que usa *prompts* com supervisão fraca (PWS) (Ratner *et al.*, 2016) se saiu melhor do que as abordagens *zero-shot* e os sistemas supervisionados ajustados com rótulos manuais. Para ilustrar, no FA-KES, o modelo alcançou 55,3% de *F1-Macro* e, no EUvsDisinfo, conseguiu um avanço de +92,1% se comparado ao *zero-shot*, evidenciando que indicadores de confiança extraídos por LLMs conseguem capturar detalhes de notícias falsas quando combinados de uma maneira probabilística.

3.3 Análise Contextual e Estratégias Avançadas

A identificação de notícias falsas tem progredido consideravelmente com a inclusão de métodos contextuais que transcendem a simples análise do texto, investigando aspectos do discurso, da interação e situacionais. As novas técnicas se sobressaem por empregar LLMs não só para classificar, mas para estruturar linhas de raciocínio, pontos de vista e adaptações

na linguagem que aprimoram o entendimento do significado das notícias (Liu *et al.*, 2025). Tais modelos conseguem imitar reações humanas, modificar interpretações e oferecer justificativas contextuais, sendo essenciais em processos complexos e multifacetados (Wang *et al.*, 2024).

3.3.1 Combinação de LLMs e SLMs para Detecção de *Fake News* com Justificativas

No estudo *Bad Actor, Good Advisor: Exploring the Role of Large Language Models in Fake News Detection* (Hu *et al.*, 2024), a arquitetura explorada examina como LLMs, como o GPT-3.5, auxiliam na detecção de notícias falsas, com foco na análise contextual e na inclusão de justificativas que explicam a decisão. Os pesquisadores notaram que, mesmo que os LLMs criem razões analíticas e com várias perspectivas – como textos descritivos, senso comum e fatos –, seu desempenho sozinho é pior do que o de SLMs ajustados, como o BERT (Devlin *et al.*, 2019). Essa dificuldade surge da ineficiência dos LLMs em juntar e usar bem as várias explicações que eles mesmos criam. Para resolver isso, os pesquisadores sugerem uma arquitetura combinada – a *Orientação Adaptativa por Justificativas* (ARG) – na qual os SLMs aproveitam as explicações criadas pelos LLMs, melhorando o sistema e tornando-o interpretável.

A estrutura ARG é formada por três partes principais: a codificação simultânea das notícias e justificativas usando modelos baseados em BERT (Wolf *et al.*, 2020); mecanismos de atenção cruzada que permitem conexões entre o conteúdo e as justificativas; e um sistema que avalia a utilidade das justificativas, pesando suas contribuições para a decisão final. Uma versão mais simples dessa estrutura, chamada ARG-D, é proposta para situações com limites de custo de computação, eliminando a necessidade de usar o LLM em tempo real, mas mantendo um bom desempenho ao transferir conhecimento (Hinton; Vinyals; Dean, 2015). Os testes foram feitos com dois conjuntos de dados reais: o Weibo21 (em chinês) (Nan *et al.*, 2021) e o GossipCop (em inglês) (Shu *et al.*, 2020), com um conjunto de justificativas geradas pelo GPT-3.5. Em todas as comparações, os modelos ARG e ARG-D foram melhores que as abordagens baseadas apenas em LLMs ou SLMs, mostrando superioridade em medidas como a *F1-macro*.

Os resultados mostram que a colaboração entre LLMs e SLMs – por meio de orientação racional – aumenta a precisão e a explicabilidade na detecção de notícias falsas. O modelo ARG não só melhora a detecção ao juntar razões contextualizadas, mas também oferece uma alternativa mais barata e que pode ser aumentada via ARG-D. No entanto, os pesquisadores reconhecem desafios como depender da qualidade das justificativas criadas pelo LLM, riscos de alucinação, viés e o custo de usar a inferência em tempo real. Além disso, a abordagem precisa de mais estudos sobre como ela se aplica a outros domínios e idiomas.

3.3.2 Separação Estilo-Conteúdo para Detecção Robusta de Desinformação

O *SheepDog* é um modelo para detecção de notícias falsas que supera as limitações dos detectores tradicionais diante das variações estilísticas geradas por LLMs. O ponto central da proposta no artigo *Fake News in Sheep's Clothing: Robust Fake News Detection Against LLM-*

Empowered Style Attacks (Wu; Guo; Hooi, 2024) é a separação entre conteúdo e estilo textual, com foco na veracidade do conteúdo como critério principal para a detecção de desinformação (Ajao; Bhowmik; Zargari, 2019; Zhang *et al.*, 2021). Para isso, o *SheepDog* emprega um paradigma de aprendizado multitarefa em que o modelo é treinado não apenas para classificar a autenticidade das notícias, mas também para identificar justificativas centradas no conteúdo, com auxílio de LLMs. Durante o treinamento, cada notícia é reformulada em múltiplos estilos (formal, sensacionalista, emocional etc.), permitindo que o modelo aprenda a ignorar traços estilísticos e se concentre nas alegações factuais presentes de forma consistente entre as versões.

Em relação à sua estrutura, o *SheepDog* é construído sobre modelos *Transformers* pré-treinados, como RoBERTa (Liu *et al.*, 2019), BERT (Devlin *et al.*, 2019) e DeBERTa (He *et al.*, 2020), aos quais são adicionadas partes de predição específicas para veracidade e para atribuições de conteúdo. A reformulação estilística das notícias é realizada por LLMs como GPT-3.5 e LLaMA2 (Touvron *et al.*, 2023), que seguem prompts específicos para simular estilos diversos.

As justificativas geradas pelos LLMs também servem como uma forma de supervisão fraca, reforçando o treinamento orientado ao conteúdo. O treinamento do *SheepDog* ocorre em pares de artigos originais e suas versões com estilos diferentes, de modo que o modelo aprenda a produzir previsões consistentes independentemente da aparência do texto. Esse *design* modular e adaptável permite o uso de diferentes *backbones* e LLMs para a geração de reformulações e atribuições explicativas.

A eficácia do *SheepDog* foi avaliada em três *benchmarks* amplamente utilizados: PoliFact (voltado para política), GossipCop (focos de celebridades) e LUN (notícias rotuladas como confiáveis ou não, categorizadas como sátira, boatos ou propaganda) (Shu *et al.*, 2020; Rashkin *et al.*, 2017). Os resultados mostram ganhos expressivos na *F1-score*, com o modelo superando detectores tradicionais por até 20 pontos percentuais em situações desafiadoras onde o estilo textual foi modificado intencionalmente. Estudos detalhados revelam que tanto a diversidade estilística quanto as atribuições de conteúdo são fundamentais para alcançar tais avanços.

3.3.3 Uso de Reações e Tarefas *Proxy* com LLMs na Detecção de Desinformação

A proposta *Avaliação de Desinformação com Aprendizado em Camadas* (DELL) apresentada no estudo *DELL: Generating Reactions and Explanations for LLM-Based Misinformation Detection* (Wan *et al.*, 2024) utiliza LLMs de forma integrada em três partes complementares. Inicialmente, a "Geração de Reações Diversas" emprega LLMs como o Mistral-7B (Jiang *et al.*, 2023a), LLaMA2-70B (Touvron *et al.*, 2023) e ChatGPT para simular reações de usuários a matérias de notícias com base em perfis variados (como gênero, faixa etária, orientação política e escolaridade) (Argyle *et al.*, 2023). Esses comentários gerados formam redes de interação usuário-notícia que refletem o discurso social e permitem ao modelo explorar múltiplas perspectivas (Sorensen *et al.*, 2024).

Em seguida, o módulo de "Tarefas de *Proxy* Explicáveis" usa os LLMs para realizar tarefas auxiliares — como análise de sentimentos, enquadramento de notícias, identificação de propaganda e recuperação de informações — gerando tanto previsões quanto explicações textuais (Zhang *et al.*, 2021; Kwak; An; Ahn, 2020; Mendelsohn; Budak; Jurgens, 2021; Piskorski *et al.*, 2023; Borgeaud *et al.*, 2022; Shi *et al.*, 2023; Asai *et al.*, 2023; Chen *et al.*, 2023). Por fim, no terceiro módulo, um "Conjunto de Especialistas Baseado em LLM" é construído com base nessas tarefas auxiliares, e as previsões geradas por cada "especialista" são combinadas por meio de estratégias como fusão vanilla, fusão ponderada por confiança ou ativação seletiva, resultando em uma decisão final mais confiável e interpretável (Feng *et al.*, 2023; Zhao *et al.*, 2023c).

Para testar essa estrutura, os autores utilizaram sete bases de dados em inglês voltados para diferentes aspectos da desinformação. Na tarefa de detecção direta de notícias falsas, destacam-se os datasets Pheme (Buntain; Golbeck, 2017) e LLM-Mis (Chen; Shu, 2024), este último derivado do textitFakeNewsNet e incrementado com desinformação gerada por máquinas. Para detecção de enquadramento, foram usados os conjuntos MFC (Card *et al.*, 2015) e SemEval-23F (Piskorski *et al.*, 2023), enquanto a detecção de táticas de propaganda contou com o SemEval-20 (Martino *et al.*, 2020), SemEval-23P e um conjunto gerado via ChatGPT. Esses *benchmarks* foram escolhidos para capturar desde nuances textuais até relações sociais simuladas, possibilitando uma avaliação mais completa da eficácia da abordagem. A variedade dos dados foi essencial para verificar a robustez da proposta, especialmente em cenários com ausência ou escassez de comentários reais de usuários.

Os resultados foram expressivos: o DELL superou as linhas de base em todos os sete *benchmarks*, com ganhos de até 16,8% na métrica *F1-macro*. Os maiores avanços ocorreram em conjuntos com linguagem complexa ou comentários sintéticos, reforçando a importância dos módulos contextuais. Além disso, o sistema mostrou-se robusto mesmo quando a quantidade de reações disponíveis foi reduzida em até 90%, e a diversidade simulada nos perfis dos usuários contribuiu para uma análise mais precisa das notícias. O conjunto de especialistas, orientado por LLMs, foi crucial para fornecer decisões mais bem calibradas, e o uso de explicações textuais aumentou a interpretabilidade do processo decisório.

No entanto, algumas limitações importantes persistem: a abordagem depende fortemente da qualidade e realismo das reações sintéticas geradas, que podem introduzir vieses ou ruídos se forem enviesadas ou estereotipadas; além disso, a capacidade dos LLMs de capturar plenamente a complexidade das interações sociais reais ainda é limitada. Há também riscos éticos relacionados ao uso indevido da geração de comentários artificiais, e o modelo pode ter dificuldade para se adaptar rapidamente às táticas de desinformação em constante evolução.

3.4 Abordagens Multimodais para Detecção de *Fake News*

Abordagens multimodais para detecção de notícias fraudulentas unem variadas fontes de informação — como conteúdo textual, imagens, vídeos e metadados — com a finalidade de

aumentar a precisão e a robustez na distinção de conteúdos enganosos (Abdali; Shaham; Krishnamachari, 2024; Xue *et al.*, 2021; Zidan *et al.*, 2025). Ao explorar múltiplas modalidades, esses métodos visam apreender detalhes contextuais que abordagens focadas em apenas um tipo de dado muitas vezes não conseguem perceber. Por exemplo, a combinação da análise textual com informações visuais pode ajudar a verificar a coerência da informação, detectar imagens manipuladas ou criadas artificialmente e proporcionar uma compreensão mais completa da narrativa veiculada (Zhao *et al.*, 2024; Xue *et al.*, 2021).

Em situações reais, a detecção multimodal é crucial em ambientes onde a desinformação se propaga por diferentes formatos e plataformas — como mídias sociais durante eleições, crises sanitárias ou desastres naturais (Shetty *et al.*, 2024; Alghamdi; Luo; Lin, 2024). As melhores práticas nesse campo enfatizam a importância da extração eficaz de características de cada modalidade, do uso de estratégias avançadas de fusão para integrar informações e do desenvolvimento de modelos resistentes a dados ruidosos, incompletos ou contraditórios (Zhu *et al.*, 2024b; Yan *et al.*, 2024). Os principais desafios e oportunidades giram em torno da construção de representações abrangentes das notícias, integrando dados semânticos, visuais e relacionais para permitir uma detecção mais rápida e exata de conteúdos falsos (Abdali; Shaham; Krishnamachari, 2024). Nesse contexto, as abordagens multimodais se consolidam como uma direção promissora no enfrentamento de campanhas sofisticadas de desinformação que exploram simultaneamente múltiplos canais e formatos.

3.4.1 Detecção Multimodal de *Fake News* com LVLMs e Conhecimento de Falsificação

A pesquisa *FKA-Owl: Advancing Multimodal Fake News Detection Through Knowledge-Augmented LVLMs* (Liu *et al.*, 2024) apresenta o *Fake News Knowledge-Augmented Owl* (FKA-Owl), uma estrutura inovadora para detecção de notícias falsas multimodais que une *Large Vision-Language Models* (LVLMs) com conhecimento específico de falsificação (Liu *et al.*, 2023; Zhu *et al.*, 2023). Essa estrutura combina um codificador visual (*ImageBind-Huge*) (Girdhar *et al.*, 2023), um componente de raciocínio intermodal com mecanismos de atenção cruzada dupla e um módulo de identificação de detalhes visuais, responsáveis por encontrar inconsistências semânticas e sinais visuais de manipulação em imagens. Os dados extraídos são convertidos em *embeddings* (representações vetoriais) específicas de falsificação e incorporados ao LVLM Vicuna (Chiang *et al.*, 2023), por meio de projetores dedicados. O julgamento final é orientado por *soft prompts* e heurísticas de resposta que alimentam o classificador de decisão, resultando em um processo robusto de inferência sobre a veracidade de pares imagem-texto.

A avaliação experimental foi conduzida em três grandes bases de dados: MFND (Qian *et al.*, 2021; Shao; Wu; Liu, 2023; Ying *et al.*, 2023), NewsCLIPpings (Luo; Darrell; Rohrbach, 2021) e coleções jornalísticas de múltiplos domínios como BBC, *The Guardian*, *USA TODAY* e *The Washington Post* (Shao; Wu; Liu, 2023). O MFND traz pares imagem-texto com manipulações explícitas, enquanto o NewsCLIPpings oferece um *benchmark* desafiador com inconsistências geradas automaticamente, simulando a desinformação do mundo real. Para avaliar a generali-

zação do modelo, os experimentos foram organizados em cenários dentro e fora dos domínios, com divisões específicas para validar a capacidade de adaptação a diferentes estilos narrativos e contextos culturais. As métricas utilizadas incluíram AUC, EER e ACC, refletindo tanto a precisão quanto a robustez do modelo diante da diversidade de manipulações (Nan *et al.*, 2022; Shao; Wu; Liu, 2023).

Os resultados obtidos revelaram que o FKA-Owl supera significativamente os modelos de última geração, como PandaGPT (Su *et al.*, 2023), PandaGPT+SPT (Lester; Al-rfou; Constant, 2021) e HAMMER (Shao; Wu; Liu, 2023). Principalmente, as melhorias na AUC chegaram a mais de 13% em cenários fora dos domínios, evidenciando sua capacidade aprimorada na detecção de notícias falsas em ambientes do mundo real. Estudos de ablação confirmaram a importância crítica dos componentes especializados — a remoção do raciocínio intermodal ou da identificação de detalhes visuais resultou em quedas perceptíveis no desempenho. Além disso, a integração de conhecimento específico de falsificação e estratégias de *prompting* revelou-se essencial para ativar o potencial latente dos LVLMS no raciocínio sobre manipulações visuais e semânticas.

Apesar desses progressos, a abordagem ainda enfrenta desafios importantes: sua eficácia depende fortemente da qualidade de conhecimento dos *embeddings* e da cobertura semântica das informações; o processo de raciocínio permanece em grande parte opaco, limitando a interpretabilidade; e o alto custo computacional pode dificultar sua adoção em larga escala. Além disso, é necessário verificar melhor se ela resiste a manipulações sofisticadas e se consegue se adaptar a contextos multilíngues ou culturalmente diferentes. Esses fatores destacam que pesquisas futuras precisam ser elaboradas para ampliar a transparência, a eficiência e a cobertura contextual dessa solução.

3.4.2 FND-LLM: Detecção Multimodal de *Fake News* com Múltiplos Ramos e LLMs

A estrutura *Detecção de Fake News com LLM* (FND-LLM) aproveita o melhor de SLMS e LLMs para detecção multimodal de notícias falsas. Essa arquitetura proposta no estudo *LLM-Enhanced Multimodal Detection of Fake News* (Wang *et al.*, 2024a) é formada por vários módulos especializados que extraem e processam informações textuais, visuais e intermodais (Wei *et al.*, 2022b; Chen *et al.*, 2022). Entre os principais componentes estão: (i) o uso do BERT para extração textual (Devlin *et al.*, 2019); (ii) o *Vision Transformer* (ViT) e o *Contrastive Language-Image Pretraining* (CLIP) para representação semântica e correspondência entre imagem e texto; (iii) o *Extended Autocoded ViT* (EAViT), para detecção de adulterações visuais (Horvath *et al.*, 2021); e (iv) um módulo de coatenção, que refina as relações entre modalidades. Além disso, LLMs são empregados para realizar inferências lógicas e validação de fatos externamente, gerando explicações e aumentando a clareza do sistema. Todas essas representações são combinadas por meio de uma rede *Multi-gate Mixture-of-Experts* (MMoE), seguida de um classificador final baseado em MLP (*perceptron* multicamada).

A validação experimental do FND-LLM foi conduzida em três conjuntos de dados: Weibo (Jin *et al.*, 2017), GossipCop e PolitiFact (Shu *et al.*, 2020), abrangendo diferentes idiomas, contextos e tipos de desinformação. Os resultados demonstraram que o modelo proposto superou abordagens unimodais e alguns modelos multimodais avançados em métricas como precisão, *F1-score*, *recall* e acurácia. Em particular, os ganhos foram de +0,7% em Weibo, +6,8% em GossipCop e +1,3% em PolitiFact. Isso indica forte capacidade de generalização, especialmente diante de diferentes domínios e contextos, e mostra que a fusão de modalidades, juntamente com módulos de validação e raciocínio, é eficaz para combater a desinformação em diversos cenários.

Mesmo com os avanços, a abordagem enfrenta obstáculos significativos. A complexidade computacional é elevada, devido à integração de múltiplos modelos pesados como BERT, ViT, CLIP e LLMs, o que dificulta a escalabilidade e uso em tempo real. Fora isso, a eficácia do sistema depende da qualidade e alinhamento dos dados multimodais, bem como da confiabilidade de fontes externas para validação dos fatos — o que pode introduzir viés ou latência. A detecção de adulterações visuais sofisticadas também permanece desafiadora, e mesmo com o uso de EAViT, algumas manipulações podem escapar. Por último, embora o uso de LLMs melhore a interpretabilidade por meio de justificativas, a complexidade da arquitetura como um todo ainda levanta questões quanto à transparência, checagem e potencial viés dos algoritmos, exigindo atenção em aplicações sensíveis.

3.5 Detecção de *Fake News* em Contextos Específicos: Caso Brasileiro

O estudo *On the use of Large Language Models to Detect Brazilian Politics Fake News* (Gôlo *et al.*, 2024) oferece uma contribuição relevante ao investigar o uso de LLMs na detecção de notícias falsas no contexto político brasileiro (Junkert, 2022). O artigo enfatiza a importância da adaptação linguística e contextual dos modelos ao português brasileiro e às particularidades sociopolíticas do país, propondo uma abordagem experimental que combina a classificação automatizada, a explicabilidade e a análise de representações vetoriais para medir a eficácia de diferentes arquiteturas de LLMs (Qu *et al.*, 2024; Hu *et al.*, 2024; Pelrine *et al.*, 2023).

3.5.1 Arquiteturas Avaliadas e Estratégias de *Prompting*

A pesquisa analisa sete LLMs de diferentes origens: OpenAI (GPT-3.5, GPT-4), Google (Gemma), Meta (LLaMA), Microsoft (Phi) e Alibaba (Qwen), com ênfase em modelos acessíveis que operam com menos de 24 GB de GPU. O modelo Gemma 2B da Google se destacou, superando os outros em desempenho geral, incluindo os modelos proprietários da OpenAI. A avaliação foi conduzida por meio de *prompts*, nos quais cada LLM deveria classificar uma notícia como “falsa” ou “real” e justificar sua decisão, refletindo o raciocínio humano de checagem de fatos. Além da classificação, os modelos geraram *embeddings* para análises não supervisiona-

das de separação entre notícias falsas e verdadeiras, usando *t-Distributed Stochastic Neighbor Embedding* (t-SNE) para projeção vetorial (Maaten; Hinton, 2008).

3.5.2 Conjunto de Dados: Construção e Relevância Contextual

O estudo sugere um novo conjunto de dados composto por 300 amostras (152 reais e 148 falsas), obtidas a partir de fontes confiáveis e representativas do ambiente de mídia brasileiro, como G1, UOL e Correio Braziliense. O corpus é diversificado e multimodal, incluindo textos jornalísticos, postagens em redes sociais, vídeos, imagens e áudios. A curadoria priorizou conteúdos compartilhados durante o ciclo das eleições presidenciais brasileiras, visando refletir os padrões reais de disseminação de desinformação no país. Esse conjunto de dados preenche uma lacuna importante na literatura, que frequentemente se concentra em contextos norte-americanos ou de língua inglesa, e carece de dados anotados e contextualizados para o português do Brasil (Souza; Jorge; Rezende, 2023; Gôlo *et al.*, 2023).

3.5.3 Resultados: Desempenho, Explicabilidade e Representação

Os experimentos revelaram que o modelo Gemma obteve a maior pontuação *F1-macro* (0,90), superando inclusive o GPT-4 em precisão geral e capacidade de discriminação. A análise dos *embeddings* mostrou que o Gemma e o Qwen foram mais eficazes em separar notícias falsas e reais no espaço vetorial, formando clusters mais distintos e coesos do que os modelos da OpenAI. Quanto à explicabilidade, os modelos conseguiram identificar padrões recorrentes de desinformação, como sensacionalismo, ausência de fontes confiáveis e uso de linguagem vaga, ao mesmo tempo em que reconheciam características de veracidade como detalhamento factual, consistência argumentativa e atribuição clara de fontes. Esse aspecto é crucial para a adoção de LLMs em cenários reais, pois a geração de justificativas plausíveis aumenta a confiança e a transparência nos sistemas automatizados.

3.5.4 Limitações e Comparação com o Estado da Arte

Apesar das contribuições relevantes, a abordagem apresenta limitações quando comparada a métodos mais recentes no estado da arte. Primeiramente, o escopo dos modelos e estratégias de *prompting* avaliados é restrito. O estudo não explora técnicas mais avançadas de engenharia de *prompts* (como *few-shot* ou *chain-of-thought prompting*) (Brown *et al.*, 2020; Wei *et al.*, 2022a). Além disso, mesmo que as explicações geradas pelos modelos sejam qualitativamente promissoras, não foi realizada uma avaliação rigorosa da veracidade factual dessas justificativas, o que pode levar a interpretações erradas de que os modelos entendem tudo e explica de forma coerente, sendo que eles podem alucinar (Wang *et al.*, 2024; Zhang *et al.*, 2021;

Kwak; An; Ahn, 2020; Mendelsohn; Budak; Jurgens, 2021; Piskorski *et al.*, 2023; Borgeaud *et al.*, 2022; Shi *et al.*, 2023; Asai *et al.*, 2023; Chen *et al.*, 2023).

Outro ponto crítico refere-se ao tamanho reduzido do conjunto de dados. A base de apenas 300 amostras limita a capacidade dos modelos de generalizar, especialmente em áreas muito variáveis como a da desinformação política (Upadhyay; Pasi; Viviani, 2023; Alesawi; Al-tai, 2024). Ademais, a ausência de comparação com detectores especializados ou métodos híbridos — como aqueles que integram grafos de conhecimento, classificadores supervisionados ou modelos de inferência lógica — limita a avaliação do real desempenho dos LLMs em relação a sistemas mais robustos (Gong *et al.*, 2023; Zhang; Gao, 2023; Zhang; Gao, 2024; Wang *et al.*, 2024a).

3.6 Desafios Atuais: Interpretabilidade e *Reasoning* na Detecção de *Fake News*

Apesar do notável progresso no uso de LLMs para a detecção de fake news, os estudos analisados mostram fragilidades, principalmente na capacidade de interpretabilidade das decisões dos modelos e na incorporação de mecanismos explícitos de raciocínio. Além disso, diversos trabalhos concentram-se em otimizar a acurácia da classificação, utilizando arquiteturas sofisticadas ou estratégias de recuperação de contexto (Zhang; Gao, 2024; Zhang; Gao, 2023; Leite *et al.*, 2023). No entanto, a maioria dessas abordagens limita-se a fornecer uma saída binária (verdadeiro/falso), sem explicar exatamente os critérios utilizados para a tomada de decisão.

Outro desafio recorrente é a superficialidade do raciocínio nos modelos atuais. Técnicas de *prompting* hierárquico ou passo a passo (Zhang; Gao, 2023) têm buscado simular o processo de verificação lógica, mas ainda de forma pouco eficiente. Faltam abordagens que incorporem raciocínio simbólico ou estruturado para justificar as decisões com base em evidências concretas. Nesse cenário, este trabalho sugere uma abordagem centrada na integração de LLMs e técnicas de *reasoning* para a detecção de *fake news* em português. A proposta visa preencher a lacuna identificada ao desenvolver um modelo que não apenas classifique, mas também raciocine explicitamente sobre os conteúdos analisados, fornecendo justificativas compreensíveis e transparentes para os usuários.

4 METODOLOGIA

Este capítulo detalha a metodologia adotada para o desenvolvimento da pesquisa, abrangendo desde a escolha e tratamento dos dados até a implementação e avaliação dos modelos de linguagem empregados. O propósito central é explicar o processo sistemático seguido para investigar a eficácia dos LLMs na detecção de notícias falsas em português. A Figura 2 apresenta uma visão geral da metodologia.

A metodologia está organizada em quatro etapas principais: (i) aquisição e preparação do conjunto de dados; (ii) elaboração de técnicas de *prompting* apropriadas à tarefa; (iii) avaliação comparativa entre diferentes LLMs, com foco em acurácia, interpretabilidade e capacidade de *reasoning*; e (iv) desenvolvimento de uma aplicação para o usuário final, que ilustra a aplicabilidade prática do modelo sugerido.

4.1 Aquisição de Dados

Nesta etapa, foram buscados diversos conjuntos de dados em língua portuguesa, contendo instâncias rotuladas como verdadeiras ou falsas, provenientes de fontes jornalísticas e plataformas de checagem de fatos, entre eles:

- **Fake.br Corpus** ([Monteiro et al., 2018](#); [Silva et al., 2020b](#)): Este acervo reúne notícias verdadeiras e falsas alinhadas, escritas em português brasileiro. Ele fornece uma base sólida para a detecção de *fake news*, permitindo a análise comparativa entre textos reais e falsos. O repositório de dados contém 7.200 notícias, sendo 3.600 verdadeiras e 3.600 falsas.
- **FakeRecogna** ([Garcia; Afonso; Papa, 2022](#)): Esta coletânea de dados engloba notícias reais e falsas coletadas entre os anos de 2019 e 2021 a partir de notícias verdadeiras de sites verificados e notícias falsas de agências de checagem. A diversidade de estilos de escrita e categorias fornece uma ampla gama de dados para análise de processamento de linguagem natural e algoritmos de aprendizado de máquina. O *dataset* contém 11.902 notícias.
- **Fakepedia Corpus** ([Charles; Ruback; Oliveira, 2022](#)): Este corpus é baseado em artigos da Wikipédia, contendo informações verdadeiras e falsas. Ele é útil para analisar como informações incorretas podem ser inseridas em fontes geralmente confiáveis. A base contém 12.398 notícias do Brasil entre os anos de 2013 e 2021, das quais metade são falsas e metade são verdadeiras.
- **FakeWhatsApp.Br** ([Cunha, 2021](#)): Esta compilação anotada de mensagens do WhatsApp em português brasileiro é voltada para a detecção automática de desinformação textual. Ele é relevante para entender como as *fake news* se propagam em aplicativos de mensagens instantâneas.




Figura 2 – Visão geral das etapas da metodologia da *Aletheia*.

Fonte: Autoria própria (2026).

- **FakeNewsSetGen** (Silva *et al.*, 2020a): Este projeto gera conjuntos de dados de *fake news* que contêm dados de propagação de notícias e suporte à comparação entre téc-

nicas de aprendizado de máquina. Ele é relevante para analisar como as *fake news* se espalham nas redes sociais. O arquivo contém 2.651 notícias, sendo 1.282 verdadeiras e 1.307 falsas.

- **Fake News Multilabel** (Morais *et al.*, 2019): Este conjunto de dados contém notícias rotuladas com múltiplas categorias, permitindo uma análise mais granular das *fake news*. Ele é útil para entender as diferentes dimensões que uma notícia falsa pode ter. A base de dados contém 268 notícias, com múltiplos rótulos por notícia.
- **FakeTrue.Br** (Chavarro *et al.*, 2023): Este corpus contém notícias verdadeiras e falsas em português brasileiro, coletadas de diversas fontes. Ele é relevante para treinar modelos que possam distinguir entre informações verídicas e enganosas. A fonte de dados final obtida consiste em 3.582 notícias em português, publicadas entre 2017 e 2023 (1.791 verdadeiras e 1.791 falsas), distribuídas em 5 categorias, que são: Brasil, política, entretenimento, saúde e mundo.
- **FACTCK.BR** (Moreno; Bressan, 2019): Este repositório de dados é composto por verificações de fatos realizadas por plataformas brasileiras. Ele é útil para treinar modelos que possam replicar o raciocínio de verificadores de fatos humanos. A coletânea contém 1.309 verificações.
- **FactNews** (Vargas *et al.*, 2023): Este acervo reúne notícias verificadas por plataformas de checagem de fatos, fornecendo uma fonte confiável de dados para análise. O *dataset* compreende 6.161 sentenças cuidadosamente anotadas, seguindo as definições de factualidade e viés da mídia propostas pela AllSides.
- **Central de Fatos** (Couto *et al.*, 2021): Esta compilação é formada por um conjunto de dados composto de checagens de fatos coletadas a partir de 6 diferentes agências brasileiras. Esses dados podem ser utilizados para o entendimento e a elaboração de estratégias para contenção da desinformação no cenário brasileiro. O corpus abrange 11.647 checagens de fatos conduzidas entre os anos de 2013 e 2021 no contexto brasileiro.
- **Dataset-Fake-news-and-True-news** (Rodrigues, 2025): Esta coleção de dados contém notícias verdadeiras e falsas, permitindo uma análise comparativa entre os dois tipos de conteúdo. O material contém 65.204 notícias, sendo 32.602 verdadeiras e 32.602 falsas.

Após reunir os principais conjuntos de dados relevantes para a área de pesquisa, a escolha das bases para este estudo priorizou a importância científica, a atualidade, a variedade de temas e a adequação a testes envolvendo raciocínio automatizado e técnicas de XAI. Na fase inicial de análise, optou-se pelo *FakeTrue.Br* (Chavarro *et al.*, 2023), um corpus recente e muito útil, com 3.582 notícias em português, divididas igualmente entre verdadeiras e falsas,

de 2017 a 2023. Seu tamanho moderado facilita iterações rápidas e o controle de variáveis nos testes iniciais com modelos de linguagem, sendo ideal para validações preliminares.

A base se sobressai pela forma como foi construída, unindo notícias falsas retiradas automaticamente do site Boatos.org com versões verdadeiras de veículos confiáveis como G1 e Folha de S.Paulo, garantindo a mesma temática entre os pares. Adicionalmente, sua relevância acadêmica é comprovada pela amplitude de temas em áreas como política, saúde, entretenimento e notícias atuais.

4.2 Engenharia de *Prompting*

Com o avanço dos LLMs, a engenharia de *prompts* tornou-se uma técnica essencial para guiar o comportamento dos modelos em tarefas específicas. Nesta etapa da pesquisa, são elaborados e testados diferentes estilos de *prompting*, incluindo abordagens *Zero-shot*, *Few-shot* e *Chain-of-Thought* (CoT), visando extrair raciocínios claros e justificativas interpretáveis por parte do modelo. A eficácia dessas técnicas é comprovada por meio de testes práticos, verificando a capacidade de gerar respostas coerentes, explicativas e relevantes no contexto da identificação de notícias falsas.

4.2.1 Conhecimento Interno para Verificação Factual

A primeira abordagem analisada neste estudo investiga a habilidade dos LLMs em realizar verificação factual utilizando apenas seu conhecimento interno, sem recorrer a fontes externas ou bases de dados atualizadas. Essa abordagem se fundamenta no saber obtido durante a fase de pré-treinamento dos modelos, englobando padrões linguísticos, dados históricos, eventos e informações gerais assimiladas a partir de extensos volumes de texto. Para possibilitar essa análise, foram empregadas três abordagens diferentes de *prompting* — *zero-shot*, *few-shot* e *chain-of-thought* — cada uma com particularidades específicas em relação ao grau de direcionamento oferecido ao modelo e à maneira como o raciocínio é organizado. A seguir, encontram-se descritas essas técnicas:

- **Zero-shot** (Rahman; Khan; Porikli, 2018): Essa técnica permite que os modelos de linguagem realizem tarefas sem terem sido treinados com exemplos específicos. A resposta é gerada com base nas instruções do *prompt* e no conhecimento que o modelo já possui. No contexto deste trabalho, o *zero-shot prompting* consiste em fornecer ao modelo uma instrução estruturada com formato de saída definido, sem exemplos prévios, exigindo que o modelo recorra exclusivamente ao conhecimento adquirido durante o pré-treinamento. Busca-se reduzir a dependência de supervisão explícita, utilizando mecanismos de compatibilidade semântica e inferência para realizar predições de maneira flexível e escalável. Um exemplo de *zero-shot prompting* pode ser visto no Exemplo 4.2.1.

Exemplo 4.2.1: *Template zero-shot prompting* para detecção de desinformação usando apenas o conhecimento interno do modelo.

Você é um verificador de fatos jornalístico. Sua tarefa é classificar a notícia abaixo como FAKE ou REAL.

DEFINIÇÃO DA TAREFA:

- **FAKE:** a notícia difunde desinformação — independentemente do formato. Inclui: afirmações falsas apresentadas como verdadeiras; *fact-checks* enganosos que usam fontes fabricadas, comprometidas ou inexistentes; verificações que chegam à conclusão errada; e conteúdo que distorce fatos reais para criar uma narrativa falsa.

- **REAL:** a notícia é jornalismo verdadeiro. Dois casos:

(a) Relato direto: descreve eventos reais com base em fatos verificáveis (exemplo: morte de uma pessoa pública, declaração oficial, incidente documentado).

(b) *Fact-check* legítimo: **RELATA** e **DESMENTE** uma alegação falsa usando fontes confiáveis — veículos jornalísticos estabelecidos, instituições acadêmicas, órgãos oficiais ou agências de fact-checking reconhecidas.

Você avalia a **QUALIDADE** do *fact-check*: as fontes sustentam o desmentido? A conclusão está correta? *Fact-check* mal fundamentado ou enganoso é FAKE.

- **INDETERMINADO:** evidências insuficientes, contraditórias ou seletivas (*cherry-picking*) que não permitem classificação com confiança acima de 60%. Use também quando fontes existem mas sua credibilidade é questionável.

INSTRUÇÕES:

- **NÃO** invente fatos.
- Seja conciso: máximo de 3 itens por seção.
- Use frases curtas.
- Toda a resposta deve caber em no máximo 200 palavras.
- **REGRA CRÍTICA:** identifique **PRIMEIRO** se a notícia é um *fact-check* ou relato jornalístico antes de analisar os fatos.
- A seção "Conclusão" é **OBRIGATÓRIA**.

ESCALA DE CONFIANÇA (use para a probabilidade):

- 50–60%: evidências ambíguas, insuficiente ou inconclusiva, poderia ser qualquer um.

- 61–75%: *indícios claros mas sem confirmação forte.*
- 76–89%: *evidências consistentes com a classificação.*
- 90–100%: *certeza elevada, múltiplos indicadores convergentes.*

NOTÍCIA:

[INSIRA AQUI O TEXTO DA NOTÍCIA]

ESTRUTURA:

1. Tipo de conteúdo: [*fact-check*/relato jornalístico/alegação sem fonte/outro]
 2. Personagens, locais, datas e eventos principais
 3. Análise: veracidade dos fatos e coerência contextual
 4. **Conclusão:** [FAKE ou REAL ou INDETERMINADO] - [probabilidade de que sua classificação esteja correta, 50-100%] - [justificativa em 1 ou 2 frases]
- Responda **APENAS** na estrutura solicitada, em português brasileiro.

Fonte: Autoria própria (2026).

- **Few-shot** (Rahman; Khan; Porikli, 2018): Trata-se de uma técnica que consiste em fornecer ao modelo alguns exemplos rotulados diretamente no *prompt*, permitindo que ele aprenda padrões com base em uma quantidade reduzida de dados antes da inferência. É uma versão aprimorada do *zero-shot prompting*, que oferece ao modelo uma pequena amostra representativa de classes ou tarefas específicas. Isso melhora significativamente sua capacidade de generalização, especialmente em cenários de escassez de dados rotulados. Uma variação ainda mais limitada, o *one-shot prompting*, utiliza apenas um exemplo por classe. Ambas as estratégias visam maximizar o desempenho com o mínimo de supervisão direta. Um exemplo de *few-shot prompting* pode ser visto no Exemplo 4.2.2.

Exemplo 4.2.2: Template few-shot prompting para detecção de desinformação usando apenas o conhecimento interno do modelo.

Você é um verificador de fatos jornalístico. Avalie a notícia seguindo os exemplos abaixo.

DEFINIÇÃO DA TAREFA:

- **FAKE:** a notícia difunde desinformação — independentemente do formato.
- Inclui: afirmações falsas apresentadas como verdadeiras; *fact-checks* enganosos que usam fontes fabricadas, comprometidas ou inexistentes; verificações que chegam à conclusão errada; e conteúdo que distorce fatos reais para criar uma narrativa falsa.

- **REAL:** a notícia é jornalismo verdadeiro. Dois casos:

(a) Relato direto: descreve eventos reais com base em fatos verificáveis (exemplo: morte de uma pessoa pública, declaração oficial, incidente documentado).

(b) *Fact-check* legítimo: **RELATA** e **DESMENTE** uma alegação falsa usando fontes confiáveis — veículos jornalísticos estabelecidos, instituições acadêmicas, órgãos oficiais ou agências de *fact-checking* reconhecidas.

Você avalia a **QUALIDADE** do *fact-check*: as fontes sustentam o desmentido? A conclusão está correta? *Fact-check* mal fundamentado ou enganoso é FAKE.

- **INDETERMINADO:** evidências insuficientes, contraditórias ou seletivas (*cherry-picking*) que não permitem classificação com confiança acima de 60%.

Use também quando fontes existem mas sua credibilidade é questionável.

EXEMPLOS:

CONTEÚDO: "A Prefeitura de Brasília anunciou que todas as bicicletas serão taxadas em R\$ 500 a partir de 1º de janeiro. A informação foi divulgada em um blog anônimo."

ANÁLISE:

1. Tipo: alegação sem fonte oficial
2. Imposto, bicicletas, Prefeitura de Brasília, 1º de janeiro, blog anônimo
3. Sem registros oficiais; fonte anônima não confiável; valor desproporcional sem justificativa
4. **Conclusão:** FAKE - 95% - Alegação sem qualquer respaldo oficial ou jornalístico

CONTEÚDO: "Circula nas redes sociais que a vacina contra COVID-19 causa infertilidade. A alegação é falsa: especialistas do Ministério da Saúde e pesquisadores independentes explicam que não há nenhuma evidência científica que comprove isso."

ANÁLISE:

1. Tipo: *fact-check* — notícia que **DESMENTE** um boato
2. Vacina COVID-19, infertilidade, Ministério da Saúde, especialistas
3. A notícia apresenta e refuta a alegação com fontes qualificadas; o boato é o objeto da reportagem, não a reportagem em si
4. **Conclusão:** REAL - 92% - Artigo jornalístico que desmonta boato com base científica e institucional

CONTEÚDO: *"Fotos mostram o presidente assinando decreto que proíbe carne vermelha no Brasil a partir de março. O decreto foi publicado no Diário Oficial e já tem data de vigência."*

ANÁLISE:

1. Tipo: alegação com referência institucional não verificável
2. Presidente, decreto, carne vermelha, Diário Oficial, março
3. Não há registro real deste decreto; menção ao Diário Oficial sem número ou link é sinal de fabricação
4. **Conclusão:** *FAKE* - 90% - Decreto inexistente; alegação fabricada com aparência institucional

Outros exemplos seguindo o mesmo formato.

INSTRUÇÕES:

- **NÃO** invente fatos.
- Seja conciso: máximo de 3 itens por seção.
- Use frases curtas.
- Toda a resposta deve caber em no máximo 200 palavras.
- **REGRA CRÍTICA:** identifique **PRIMEIRO** se é fact-check ou alegação direta.
- A seção "Conclusão" é **OBRIGATÓRIA**.

ESCALA DE CONFIANÇA (use para a probabilidade):

- 50–60%: evidências ambíguas, insuficiente ou inconclusiva.
- 61–75%: indícios claros mas sem confirmação forte.
- 76–89%: evidências consistentes.
- 90–100%: certeza elevada, múltiplos indicadores convergentes.

NOTÍCIA:

[INSIRA AQUI O TEXTO DA NOTÍCIA]

ESTRUTURA:

1. Tipo de conteúdo: [fact-check/relato jornalístico/alegação sem fonte/outro]
2. Personagens, locais, datas e eventos principais
3. Análise dos fatos e coerência

4. Conclusão: [FAKE ou REAL ou INDETERMINADO] - [probabilidade de que sua classificação esteja correta, 50–100%] - [justificativa curta]

Responda **APENAS** na estrutura solicitada, em português brasileiro.

Fonte: Autoria própria (2026).

- **Chain-of-Thought** (Wei et al., 2022a): É uma técnica que incentiva o modelo a resolver problemas passo a passo, gerando uma cadeia explícita de raciocínios intermediários em linguagem natural antes de apresentar a resposta final. Essa abordagem tem se mostrado útil em tarefas que exigem várias etapas de raciocínio, como problemas de matemática, lógica ou senso comum, aumentando tanto a performance quanto a interpretabilidade das respostas geradas. A técnica é ainda mais eficaz em LLMs de maior porte e pode ser aplicada com exemplos anotados que mostrem esse padrão de raciocínio. Um exemplo de *Chain-of-Thought prompting* pode ser visto no Exemplo 4.2.3.

Exemplo 4.2.3: Template Chain-of-Thought prompting para detecção de desinformação usando apenas o conhecimento interno do modelo.

Você é um verificador de fatos jornalístico. Avalie a notícia com raciocínio passo a passo.

DEFINIÇÃO DA TAREFA:

- **FAKE:** a notícia difunde desinformação — independentemente do formato.

Inclui: afirmações falsas apresentadas como verdadeiras; *fact-checks* enganosos que usam fontes fabricadas, comprometidas ou inexistentes; verificações que chegam à conclusão errada; e conteúdo que distorce fatos reais para criar uma narrativa falsa.

- **REAL:** a notícia é jornalismo verdadeiro. Dois casos:

(a) Relato direto: descreve eventos reais com base em fatos verificáveis (exemplo: morte de uma pessoa pública, declaração oficial, incidente documentado).

(b) *Fact-check* legítimo: **RELATA** e **DESMENTE** uma alegação falsa usando fontes confiáveis — veículos jornalísticos estabelecidos, instituições acadêmicas, órgãos oficiais ou agências de *fact-checking* reconhecidas.

Você avalia a **QUALIDADE** do *fact-check*: as fontes sustentam o desmentido? A conclusão está correta? *Fact-check* mal fundamentado ou enganoso é FAKE.

- **INDETERMINADO:** evidências insuficientes, contraditórias ou seletivas (*cherry-picking*) que não permitem classificação com confiança acima de 60%.

Use também quando fontes existem mas sua credibilidade é questionável.

INSTRUÇÕES:

- **NÃO** invente fatos.
- Seja conciso: máximo de 3 itens por etapa.
- Use frases curtas.
- Toda a resposta deve caber em no máximo 250 palavras.
- **REGRA CRÍTICA:** complete a **ETAPA 0** antes de qualquer outra — o tipo de conteúdo determina como as demais etapas devem ser interpretadas.
- A **ETAPA 4** (Conclusão) é **OBRIGATÓRIA**.

ESCALA DE CONFIANÇA (use para a probabilidade):

- 50–60%: evidências ambíguas, insuficiente ou inconclusiva.
- 61–75%: indícios claros mas sem confirmação forte.
- 76–89%: evidências consistentes.
- 90–100%: certeza elevada, múltiplos indicadores convergentes.

NOTÍCIA:

[INSIRA AQUI O TEXTO DA NOTÍCIA]

ETAPAS:

ETAPA 0 — Tipo de Conteúdo: [identifique: (a) *fact-check*/verificação de boato, (b) relato jornalístico direto, ou (c) alegação sem fonte. Se for (a), a notícia é candidata a REAL.]

ETAPA 1 — Elementos Chave: [liste personagens, locais, datas e eventos]

ETAPA 2 — Validação Factual: [analise a veracidade considerando o tipo identificado na **ETAPA 0** — se for *fact-check*, avalie se o desmentido é bem fundamentado, não se o boato é verdadeiro]

ETAPA 3 — Análise de Coerência: [identifique incoerências, contradições ou plausibilidade da narrativa da **NOTÍCIA**, não da alegação que ela examina]

ETAPA 4 — Conclusão: [FAKE ou REAL ou INDETERMINADO] - [probabilidade de que sua classificação esteja correta, 50–100%] - [síntese curta em 1 ou 2 frases]

Responda **APENAS** nas etapas solicitadas, em português brasileiro.

4.2.2 Conhecimento Externo para Verificação Factual

O paradigma de recuperação de conhecimento externo para utilização em contexto foi adotado como um componente fundamental nesta pesquisa para dar suporte ao raciocínio e à justificabilidade das decisões dos LLMs. Essa técnica foi implementada com o objetivo de construir, a cada instância de notícia analisada, um contexto externo consolidado — composto por notícias, verificações de fatos e documentos relevantes — que funcione como base factual atualizada e verificável. Esse contexto foi injetado nas estratégias de *prompting* (*zero-shot*, *few-shot* e CoT) para permitir que o LLM valide explicitamente os fatos presentes na notícia, gere explicações fundamentadas e minimize respostas alucinadas ou não verificadas.

O sistema implementado segue uma arquitetura modular composta por três componentes principais: (i) módulo de recuperação de informações, (ii) processamento e consolidação de evidências, e (iii) integração com os modelos de linguagem. O fluxo inicia-se com a análise da notícia-alvo, da qual são geradas consultas utilizando uma abordagem híbrida baseada em extração de entidades nomeadas, palavras-chave semânticas (*KeyBERT*) e ranqueamento por similaridade vetorial. A busca de evidências é executada por um módulo de busca multimétodo que combina três fontes principais, ponderadas para equilibrar cobertura e confiabilidade:

1. **DuckDuckGo** ([DuckDuckGo, 2024](#)): Atua como fonte principal para notícias locais e regionais, priorizando conteúdo em português brasileiro.
2. **GDELT** ([Leetaru; Schrodt, 2023](#)): Fornece cobertura global e multilíngue, diversificando as perspectivas e contextos recuperados.
3. **Google Fact Check API** ([Google LLC, 2024](#)): Oferece verificações formais de fatos, priorizando checagens realizadas por organizações especializadas.

As fontes estão configuradas para serem consultadas em paralelo, sem proporções fixas no mecanismo agregador, sendo sua distribuição posteriormente filtrada com base na relevância. Para cada URL recuperada, o sistema executa um *pipeline* de extração de conteúdo que prioriza métodos robustos de *web scraping* (técnica de extração de informações de *websites* diretamente do código HTML das páginas da internet), com mecanismos baseados em *requests* e *BeautifulSoup*, complementados por regras heurísticas. O processo inclui:

- Aplicação de filtros de qualidade baseados na extensão do conteúdo e relevância temática;
- Validação temporal com descarte de conteúdos fora do intervalo da base de notícias usada (2017-2023);
- Normalização textual e truncamento controlado para adequação aos limites de tokens dos LLMs;
- Identificação e remoção de conteúdos duplicados ou redundantes.

A consolidação final do contexto executa um processo sequencial de (i) deduplicação por URL e otimização computacional por meio de um mecanismo de *cache* de índices vetoriais, baseado em *hash* das fontes recuperadas; (ii) recuperação semântica baseada em medidas de similaridade vetorial, empregando *embeddings* e o *framework* FAISS para busca eficiente em espaços de alta dimensionalidade (Johnson; Douze; Jégou, 2019); e (iii) seleção das três fontes mais relevantes dentro do limite estabelecido por similaridade semântica com o conteúdo da notícia, garantindo alinhamento temático. O contexto resultante é formatado de maneira legível para inserção direta nos *prompts*, incluindo trechos das fontes e identificação da origem. A estrutura exemplificada abaixo (Exemplo 4.2.4) demonstra como as informações das fontes são organizadas pelo módulo de recuperação:

Exemplo 4.2.4: Exemplo de estrutura das fontes retornadas pelo módulo de recuperação (representação formatada a partir dos metadados).

Total de fontes recuperadas: 3

FONTE 1

Provider: Google Fact Check

Source: Aos Fatos

Type: fact_check

Date: 2023-10-15

Relevance Score: 0.92

Content Quality: 0.85

Content Length: 2875

Título: Vacina contra COVID-19 contém chip rastreável?

URL: <https://aosfatos.org/verificacoes/vacina-covid-chip-rastreavel/>

Snippet: Verificação: Falso | Verificador: Aos Fatos

Trecho extraído:
"Verificação realizada por Aos Fatos indica que não há evidências da presença de chips rastreáveis em vacinas contra COVID-19. Especialistas afirmam que a tecnologia seria incompatível com a composição das vacinas..."

FONTE 2

Provider: DuckDuckGo

Source: g1.globo.com

Type: news

Date: 2023-09-22

Relevance Score: 0.88

Content Quality: 0.78

Content Length: 4120

Título: Especialistas explicam composição das vacinas contra COVID-19

URL: <https://g1.globo.com/saude/vacina/noticia/2023/09/22/>

Snippet: Laboratórios detalham os componentes das vacinas utilizadas no Brasil

Trecho extraído:

"Fabricantes descrevem que as vacinas utilizam tecnologias como mRNA e vetores virais, sem qualquer evidência de dispositivos eletrônicos. Especialistas reforçam que alegações sobre chips não possuem base científica..."

FONTE 3

Provider: GDELT

Source: bbc.com

Type: news

Date: 2023-08-10

Relevance Score: 0.85

Content Quality: 0.82

Content Length: 3650

Título: Teoria sobre chips em vacinas é desmentida por especialistas

URL: <https://www.bbc.com/portuguese/brasil-12345678>

Snippet: Especialistas analisam origem de boatos sobre vacinação

Trecho extraído:

"Pesquisadores em farmacologia explicam que não há viabilidade técnica para inserção de chips em vacinas líquidas. O boato surgiu em redes sociais e foi posteriormente desmentido por autoridades de saúde..."

Fonte: Autoria própria (2026).

A integração do contexto com as estratégias de *prompting* deu origem a outras três modalidades principais:

- **Zero-shot com contexto externo:** Instrução direta para avaliação com base nas fontes externas, seguindo formato estruturado que explicita o uso das evidências como referência primária. O Exemplo 4.2.5 ilustra esta abordagem.

Exemplo 4.2.5: *Template zero-shot prompting* para detecção de desinformação usando o conhecimento externo.

Você é um verificador de fatos jornalístico. Avalie a notícia usando as fontes externas fornecidas.

DEFINIÇÃO DA TAREFA:

- **FAKE:** a notícia difunde desinformação — independentemente do formato. Inclui: afirmações falsas apresentadas como verdadeiras; *fact-checks* enganosos que usam fontes fabricadas, comprometidas ou inexistentes; verificações que chegam à conclusão errada; e conteúdo que distorce fatos reais para criar uma narrativa falsa.

- **REAL:** a notícia é jornalismo verdadeiro. Dois casos:

(a) Relato direto: descreve eventos reais com base em fatos verificáveis (exemplo: morte de uma pessoa pública, declaração oficial, incidente documentado).

(b) *Fact-check* legítimo: **RELATA** e **DESMENTE** uma alegação falsa usando fontes confiáveis — veículos jornalísticos estabelecidos, instituições acadêmicas, órgãos oficiais ou agências de *fact-checking* reconhecidas.

Você avalia a **QUALIDADE** do *fact-check*: as fontes sustentam o desmentido? A conclusão está correta? *Fact-check* mal fundamentado ou enganoso é FAKE.

- **INDETERMINADO:** evidências insuficientes, contraditórias ou seletivas (*cherry-picking*) que não permitem classificação com confiança acima de 60%. Use também quando fontes existem mas sua credibilidade é questionável.

INSTRUÇÕES:

- Ao afirmar um fato, **CITE** a fonte correspondente.

- **NÃO** invente fatos.

- Se não houver evidência nas fontes, responda: "Sem evidência nas fontes fornecidas."

- Seja conciso: máximo de 3 itens por seção.

- Use frases curtas.

- Toda a resposta deve caber em no máximo 200 palavras.

- **REGRA DE ANCORAGEM:** se a conclusão das fontes contradizem a alegação da notícia verificada, sua resposta **DEVE** refletir isso.
- **REGRA CRÍTICA:** identifique **PRIMEIRO** se a notícia é fact-check ou alegação direta.
- A seção "Conclusão" é **OBRIGATÓRIA**.

ESCALA DE CONFIANÇA (use para a probabilidade):

- 50–60%: fontes ausentes, insuficiente ou inconclusiva.
- 61–75%: fontes parcialmente confirmam a classificação.
- 76–89%: fontes confirmam claramente a classificação.
- 90–100%: múltiplas fontes convergentes, sem ambiguidade.

FONTES EXTERNAS:

[INSIRA AQUI O CONTEXTO EXTERNO]

NOTÍCIA:

[INSIRA AQUI O TEXTO DA NOTÍCIA]

ESTRUTURA:

1. Tipo de conteúdo: [*fact-check*/relato jornalístico/alegação sem fonte/outro]
2. Personagens, locais, datas e eventos principais
3. Validação com fontes: [confronte os fatos da notícia com as fontes — cite qual fonte confirma ou contradiz cada ponto]
4. **Conclusão:** [FAKE ou REAL ou INDETERMINADO] - [probabilidade de que sua classificação esteja correta, 50–100%] - [justificativa baseada nas fontes em 1 ou 2 frases]

Responda **APENAS** na estrutura solicitada, em português brasileiro.

Fonte: Autoria própria (2026).

- **Few-shot com contexto externo:** Combina o contexto recuperado com exemplos anotados que demonstram o formato de saída desejado e a metodologia de confrontação com as fontes externas. O Exemplo 4.2.6 apresenta esta abordagem.

Exemplo 4.2.6: *Template few-shot prompting* para detecção de desinformação usando o conhecimento externo.

Você é um verificador de fatos jornalístico. Avalie a notícia seguindo os exemplos e usando **EXCLUSIVAMENTE** as fontes fornecidas.

DEFINIÇÃO DA TAREFA:

- **FAKE:** a notícia difunde desinformação — independentemente do formato.

Inclui: afirmações falsas apresentadas como verdadeiras; *fact-checks* enganosos que usam fontes fabricadas, comprometidas ou inexistentes; verificações que chegam à conclusão errada; e conteúdo que distorce fatos reais para criar uma narrativa falsa.

- **REAL:** a notícia é jornalismo verdadeiro. Dois casos:

(a) Relato direto: descreve eventos reais com base em fatos verificáveis (exemplo: morte de uma pessoa pública, declaração oficial, incidente documentado).

(b) *Fact-check* legítimo: **RELATA** e **DESMENTE** uma alegação falsa usando fontes confiáveis — veículos jornalísticos estabelecidos, instituições acadêmicas, órgãos oficiais ou agências de *fact-checking* reconhecidas.

Você avalia a **QUALIDADE** do *fact-check*: as fontes sustentam o desmentido? A conclusão está correta? *Fact-check* mal fundamentado ou enganoso é FAKE.

- **INDETERMINADO:** evidências insuficientes, contraditórias ou seletivas (*cherry-picking*) que não permitem classificação com confiança acima de 60%.

Use também quando fontes existem mas sua credibilidade é questionável.

EXEMPLOS:

FONTES: "[Fonte] Prefeitura de SP] Prefeitura de São Paulo nega criação de novo feriado. Site oficial confirma calendário municipal sem alterações."

CONTEÚDO: "O prefeito de São Paulo decretou feriado no dia 25 de outubro para celebrar o 'Dia do Cachorro'."

ANÁLISE:

1. Tipo: alegação direta sem respaldo oficial
2. Prefeito, São Paulo, feriado, 25 de outubro, Dia do Cachorro
3. Fontes oficiais negam o decreto; feriado sem justificativa legal; calendário municipal não alterado
4. **Conclusão:** FAKE - 97% - Fontes oficiais contradizem diretamente a alegação

FONTES: "[Fonte] Ministério da Saúde] Ministério da Saúde confirma: vacina COVID-19 não tem relação com magnetismo. Pesquisa científica revisada por pares não encontra evidência."

CONTEÚDO: "Circula nas redes sociais a informação de que pessoas vacinadas contra COVID-19 estariam ficando magnéticas. No entanto, especialistas e o Ministério da Saúde afirmam que isso é completamente falso, sem nenhuma evidência científica."

ANÁLISE:

1. Tipo: *fact-check* — notícia que DESMENTE um boato com fontes oficiais
2. Vacina COVID-19, magnetismo, redes sociais, Ministério da Saúde, especialistas
3. Boato é o objeto da reportagem; notícia cita Ministério da Saúde e pesquisa revisada para desmentir; relato jornalístico bem fundamentado
4. **Conclusão:** *REAL* - 95% - *Fact-check* sólido: fontes externas e o conteúdo da notícia convergem para desmentir o boato

Outros exemplos seguindo o mesmo formato.

INSTRUÇÕES:

- Ao afirmar um fato, **CITE** a fonte.
- **NÃO** invente fatos.
- Seja conciso: máximo de 3 itens por seção.
- Use frases curtas.
- Toda a resposta deve caber em no máximo 200 palavras.
- **REGRA DE ANCORAGEM:** se a conclusão das fontes contradizem a alegação da notícia verificada, sua resposta **DEVE** refletir isso.
- A seção "Conclusão" é **OBRIGATÓRIA**.

ESCALA DE CONFIANÇA (use para a probabilidade):

- 50–60%: fontes ausentes, insuficiente ou inconclusiva.
- 61–75%: fontes parcialmente confirmam a classificação.
- 76–89%: fontes confirmam claramente.
- 90–100%: múltiplas fontes convergentes, sem ambiguidade.

FONTES EXTERNAS:

[INSIRA AQUI O CONTEXTO EXTERNO]
NOTÍCIA:
[INSIRA AQUI O TEXTO DA NOTÍCIA]
ESTRUTURA:
1. Tipo de conteúdo: [<i>fact-check</i>/relato jornalístico/alegação sem fonte/outro] 2. Personagens, locais, datas e eventos principais 3. Validação com fontes: [cite qual fonte confirma ou contradiz cada ponto relevante] 4. Conclusão: [FAKE ou REAL ou INDETERMINADO] - [probabilidade de que sua classificação esteja correta, 50–100%] - [justificativa curta baseada nas fontes] Responda APENAS na estrutura solicitada, em português brasileiro.

Fonte: Autoria própria (2026).

- **Chain-of-Thought com contexto externo:** Solicita um raciocínio sequencial onde cada fato é sistematicamente confrontado com as fontes externas antes da conclusão final. O Exemplo 4.2.7 exemplifica esta abordagem.

Exemplo 4.2.7: Template Chain-of-Thought prompting para detecção de desinformação usando o conhecimento externo.

Você é um verificador de fatos jornalístico. Avalie a notícia com raciocínio passo a passo, validando cada etapa com as fontes externas fornecidas.

DEFINIÇÃO DA TAREFA:

- **FAKE:** a notícia difunde desinformação — independentemente do formato. Inclui: afirmações falsas apresentadas como verdadeiras; *fact-checks* enganosos que usam fontes fabricadas, comprometidas ou inexistentes; verificações que chegam à conclusão errada; e conteúdo que distorce fatos reais para criar uma narrativa falsa.

- **REAL:** a notícia é jornalismo verdadeiro. Dois casos:

(a) Relato direto: descreve eventos reais com base em fatos verificáveis (exemplo: morte de uma pessoa pública, declaração oficial, incidente documentado).

(b) *Fact-check* legítimo: **RELATA** e **DESMENTE** uma alegação falsa usando fontes confiáveis — veículos jornalísticos estabelecidos, instituições acadêmicas, órgãos oficiais ou agências de *fact-checking* reconhecidas.

Você avalia a **QUALIDADE** do *fact-check*: as fontes sustentam o desmentido? A conclusão está correta? *Fact-check* mal fundamentado ou enganoso é FAKE.

- **INDETERMINADO:** evidências insuficientes, contraditórias ou seletivas (*cherry-picking*) que não permitem classificação com confiança acima de 60%. Use também quando fontes existem mas sua credibilidade é questionável.

INSTRUÇÕES:

- Ao afirmar um fato, **CITE** a fonte correspondente.
- **NÃO** invente fatos.
- Seja conciso: máximo de 3 itens por etapa.
- Use frases curtas.
- Toda a resposta deve caber em no máximo 250 palavras.
- **REGRA DE ANCORAGEM:** se a conclusão das fontes contradizem a alegação da notícia verificada, sua resposta **DEVE** refletir isso.
- **REGRA CRÍTICA:** complete a **ETAPA 0** antes de qualquer outra — o tipo de conteúdo determina como as demais etapas devem ser interpretadas.
- A **ETAPA 4** (Conclusão) é **OBRIGATÓRIA**.

ESCALA DE CONFIANÇA (use para a probabilidade):

- 50–60%: fontes ausentes, insuficiente ou inconclusiva.
- 61–75%: fontes parcialmente confirmam a classificação.
- 76–89%: fontes confirmam claramente.
- 90–100%: múltiplas fontes convergentes, sem ambiguidade.

FONTES EXTERNAS:

[INSIRA AQUI O CONTEXTO EXTERNO]

NOTÍCIA:

[INSIRA AQUI O TEXTO DA NOTÍCIA]

ETAPAS:

ETAPA 0 — Tipo de Conteúdo: [identifique: (a) *fact-check*/verificação de boato, (b) relato jornalístico direto, ou (c) alegação sem fonte. Se for (a), a notícia é candidata a REAL.]

ETAPA 1 — Elementos Chave: [liste personagens, locais, datas e eventos]

ETAPA 2 — Validação com Fontes: [confronte os fatos da **NOTÍCIA** com as fontes externas — cite qual fonte confirma ou contradiz; se for *fact-check* (ETAPA 0 = a), avalie se as fontes corroboram o desmentido apresentado pela notícia]

ETAPA 3 — Análise de Coerência: [identifique contradições entre a notícia e as fontes; avalie a narrativa da **NOTÍCIA**, não a do boato que ela examina]

ETAPA 4 — Conclusão: [FAKE ou REAL ou INDETERMINADO] - [probabilidade de que sua classificação esteja correta, 50–100%] - [síntese em 1 ou 2 frases citando a evidência decisiva]

Responda **APENAS** nas etapas solicitadas, em português brasileiro.

Fonte: Autoria própria (2026).

Apesar dos benefícios, a integração da recuperação de conhecimento externo apresenta limitações que foram identificadas e abordadas por meio de mecanismos específicos implementados na aplicação:

- **Latência operacional:** As buscas em múltiplas fontes e a extração de conteúdo introduzem sobrecarga temporal.
- **Qualidade variável das fontes:** Fontes jornalísticas heterogêneas ou páginas de baixa qualidade podem introduzir ruído no contexto. O *scoring* de qualidade torna-se uma forma simplificada para mitigar este cenário, atuando como um mecanismo auxiliar de filtragem e priorização inicial das fontes.
- **Risco de viés e circularidade informacional:** A recuperação de fontes tendenciosas pode reforçar vieses preexistentes, sendo imprescindível a diversificação estratégica de fontes e a transparência sobre as origens das evidências.
- **Desatualização temporal:** Conteúdos antigos podem conflitar com desenvolvimentos recentes. Dessa forma, foi adotada uma priorização indireta por recência, integrada ao cálculo de relevância das fontes recuperadas, bem como a construção dinâmica dos índices vetoriais a cada consulta, afim de refletir o conjunto das fontes no momento da análise.
- **Falhas na extração de conteúdo:** A heterogeneidade das páginas *web* pode resultar em extrações incompletas ou imprecisas, mesmo com múltiplos métodos de *scraping* e *fallback*.
- **Limitações da recuperação semântica:** O processo de recuperação baseado em *embeddings* pode omitir fontes potencialmente relevantes quando nuances contextuais ou relações semânticas complexas não são completamente capturadas pela representação vetorial.

A implementação do contexto externo neste estudo representa um avanço significativo na fundamentação factual das análises realizadas pelos LLMs, contribuindo para maior confiabilidade e transparência no processo de detecção de desinformação. Além das técnicas principais já mencionadas, foram utilizadas estratégias complementares de engenharia de *prompting*, observando a complexidade das tarefas e os resultados preliminares obtidos. Entre elas, destacam-se:

- **Instruções explícitas:** *Prompts* cuidadosamente elaborados que detalham de forma clara e direta o que se espera da resposta do modelo.
- **Geração Aumentada por Recuperação (RAG — *Retrieval-Augmented Generation*)** (Jiang et al., 2023b): Técnica que une a recuperação automática de documentos relevantes ao processo de geração de texto, possibilitando que o modelo produza respostas fundamentadas em informações mais atualizadas e contextualizadas, tendo os *embeddings* como componente essencial para o processo de recuperação dessas informações.

Uma outra alternativa considerada durante a pesquisa foi a aplicação do método de ReAct (*Reasoning + Acting*) proposto por Yao et al. (Yao et al., 2023), que combina raciocínio iterativo com ações concretas (como consultas externas), intercalando pensamentos e execuções para solucionar problemas que necessitam de interação com conhecimento externo ou múltiplos passos lógicos. Essas estratégias de engenharia de *prompting* foram avaliadas em relação à sua eficiência e aptidão para gerar explicações úteis e compreensíveis no processo de detecção de notícias falsas.

4.3 *Aletheia*: Configuração Experimental

A configuração experimental do sistema *Aletheia* foi elaborada com o objetivo de possibilitar uma avaliação sistemática e replicável do desempenho de LLMs na detecção de *fake news* em língua portuguesa, considerando tanto cenários restritos exclusivamente ao conteúdo textual da notícia quanto cenários incorporados com documentos externos recuperados por meio de técnicas de RAG.

Essa configuração foi projetada para execução em ambiente controlado, com o uso de modelos locais quantizados (*4-bit* e *8-bit*), execução sequencial dos modelos, controle de memória por meio de limpeza periódica e persistência de resultados intermediários. O objetivo dessas decisões é garantir a reprodutibilidade dos experimentos, viabilizar o uso dos recursos computacionais e assegurar a rastreabilidade completa dos resultados obtidos.

Os LLMs selecionados para a pesquisa foram avaliados segundo critérios que incluem desempenho preditivo (acurácia, precisão, *recall* e *F1-score*), compatibilidade com o idioma português, custo computacional e suporte a técnicas de explicabilidade. Entre os modelos considerados, elegeram-se as variantes *Falcon 3 10B Instruct* (TII Team, 2024), *Mistral 7B Instruct*

(Mistral AI Team, 2025), Qwen 2.5 14B Instruct (Qwen Team, 2024a), Llama 3.1 8B Instruct (Meta, 2024), Gemma 3 12B IT (Google, 2024), Phi 4 (Microsoft, 2024) e DeepSeek R1 Distill Qwen 2.5 32B (DeepSeek-AI, 2025). O experimento foi estruturado como um *pipeline* modular que segue as etapas sequenciais de carregamento de dados, geração de entradas, execução dos modelos, pós-processamento e avaliação dos resultados sob perspectivas quantitativa, probabilística e qualitativa.

4.3.1 Estrutura Geral do Pipeline Experimental

O fluxo experimental implementado é composto por cinco etapas principais:

1. **Carregamento e preparação dos dados:** O sistema inicia-se com a leitura do conjunto de dados estruturado *FakeTrue.Br* (Chavarro *et al.*, 2023), que contém notícias rotuladas em duas classes: *REAL* (verdadeiras) e *FAKE* (falsas). Em seguida, procede-se a filtragem automática de entradas válidas e à separação em subconjuntos balanceados. A configuração experimental define explicitamente o uso de 50 amostras de notícias falsas e 50 amostras de notícias verdadeiras, totalizando 100 instâncias por estratégia. Essa escolha visa à otimização do tempo de processamento e do custo computacional, ao mesmo tempo em que assegura o equilíbrio entre as classes, reduzindo o viés estatístico e permitindo uma interpretação mais confiável de métricas como precisão e *recall*.
2. **Geração dos *prompts*:** Para cada instância filtrada na etapa inicial, são geradas seis variações de *prompts*, correspondentes a diferentes estratégias de *prompting*. As abordagens avaliadas incluem: *zero-shot* com conhecimento interno (*zero-shot-in*), *few-shot* com conhecimento interno (*few-shot-in*), *chain-of-thought* com conhecimento interno (*cot-in*), juntamente com suas respectivas variantes enriquecidas com conhecimento externo (*zero-shot-ex*, *few-shot-ex* e *cot-ex*). Essa organização permite isolar de forma controlada os efeitos do fornecimento de exemplos, do raciocínio estruturado e da incorporação de informações externas na qualidade final da classificação. Cada entrada experimental contempla o conteúdo textual da notícia, o título (quando disponível), o contexto adicional recuperado por meio de RAG e o *prompt* final estruturado, possibilitando a análise da interação entre o modelo e a forma de entrada da informação.
3. **Execução dos modelos:** Os modelos são executados de forma sequencial, conforme definido na configuração experimental. Essa decisão decorre de limitações computacionais impostas pela execução local dos modelos, muitos deles com elevado número de parâmetros, além do uso de técnicas de quantização para viabilizar sua inferência em ambientes com restrições de memória GPU e CPU (Frantar *et al.*, 2023). A execução sequencial reduz a concorrência por recursos computacionais, minimiza fragmentação

de memória e aumenta a estabilidade do experimento, favorecendo a reprodutibilidade dos resultados. Durante a execução, cada *prompt* é processado individualmente, e as respostas geradas são armazenadas integralmente em arquivos CSV, assegurando rastreabilidade e auditoria posterior. Adicionalmente, são aplicados mecanismos periódicos de liberação de memória, especialmente relevantes para modelos de maior porte como *Qwen 2.5 14B Instruct* (Qwen Team, 2024a), *Gemma 3 12B IT* (Google, 2024) e *DeepSeek R1 Distill Qwen 2.5 32B* (DeepSeek-AI, 2025), reduzindo o risco de esgotamento de memória em execuções prolongadas.

4. Pós-processamento, classificação das respostas e extração de probabilidades:

As saídas textuais dos modelos não são interpretadas diretamente como rótulos finais. Em vez disso, o sistema executa um processo de extração estruturada que identifica a classe predita (*FAKE*, *REAL* ou *INDETERMINADO*) e, quando disponível, o nível de confiança associado à predição. A classe *INDETERMINADO* (*abstain*) é atribuída nos casos em que o modelo não apresenta evidências suficientes, produz respostas ambíguas ou não segue adequadamente o formato solicitado, evitando assim forçar classificações incorretas e reduzindo o impacto de alucinações. Esse processo utiliza um classificador auxiliar baseado em LLM, implementado com o modelo *Qwen 2.5 3B Instruct* (Qwen Team, 2024b; Yang et al., 2024), escolhido por apresentar bom equilíbrio entre capacidade de compreensão semântica, aderência a instruções e baixo custo computacional. Sua arquitetura compacta mostrou-se adequada para tarefas de extração e normalização de informação a partir das respostas dos modelos avaliados, sem sobrecarregar o *pipeline* principal. Complementarmente, padrões baseados em expressões regulares são empregados para validar e coletar os valores extraídos, que são posteriormente armazenados em arquivos CSV estruturados (Friedl, 2006). A inclusão explícita da classe *INDETERMINADO* é relevante, pois permite medir o impacto da abstenção na cobertura e no desempenho global do sistema, além de possibilitar a modelagem explícita da incerteza. Dessa forma, a avaliação ultrapassa o conceito binário de "acerto/erro", incorporando aspectos de calibração, seletividade e robustez do raciocínio produzido pelos modelos.

5. Avaliação dos resultados:

Por fim, os resultados são processados por um motor de avaliação responsável pelo cálculo de métricas quantitativas, probabilísticas e qualitativas, bem como por análises estratificadas segundo a abordagem de *prompting*. As métricas quantitativas incluem acurácia, precisão, *recall*, *F1-score*, Kappa de Cohen, Coeficiente de Correlação de Matthews, cobertura total e taxa de abstenção, distinguindo o desempenho com e sem respostas abtidas (Davis; Goadrich, 2006; Chicco; Jurman, 2020). A avaliação probabilística contempla métricas como AUC-ROC, PR-AUC (do inglês *Precision–Recall AUC*), *Brier Score*, ECE (do inglês *Expected Calibration Error*) e intervalos de confiança (Davis; Goadrich, 2006; Glenn et al., 1950; Guo et al., 2017; Geifman; El-yaniv, 2017). Por sua vez, a avaliação qualitativa incorpora indi-

cadadores de factualidade, nocividade, relevância e comprimento médio das justificativas (Manakul; Liusie; Gales, 2023; Liang *et al.*, 2022; Lin, 2004). Adicionalmente, utiliza-se o *framework* RAGAS para análise qualitativa das respostas, reforçando a avaliação não apenas do rótulo atribuído, mas também da qualidade explicativa e justificativa das conclusões dos modelos (Es *et al.*, 2024).

4.3.2 Métricas Quantitativas de Classificação

As métricas quantitativas são empregadas para avaliar o desempenho clássico de classificação supervisionada (Chicco; Jurman, 2020). As avaliações são conduzidas atendendo a dois cenários distintos: (i) com abstenção, no qual são incluídas previsões de classe *INDETERMINADO*; e (ii) sem abstenção, no qual são consideradas somente previsões válidas (*FAKE* ou *REAL*). Essa distinção permite analisar o impacto da abstenção tanto na cobertura quanto no desempenho preditivo dos modelos.

A matriz de confusão binária é uma das ferramentas mais utilizadas na medição do desempenho de modelos de classificação supervisionada (Kohavi, 1998). No caso de um problema binário, ela é formada por uma matriz 2 x 2, em que as linhas representam as classes reais e as colunas representam as classes preditas pelo modelo.

Essa matriz é composta por verdadeiros positivos (*TP*), que, nesta pesquisa, correspondem a notícias falsas corretamente classificadas; verdadeiros negativos (*TN*), referentes a notícias verdadeiras corretamente identificadas; falsos positivos (*FP*), que correspondem a notícias verdadeiras que são incorretamente classificadas como falsas; e falsos negativos (*FN*), em que notícias falsas não são detectadas pelo modelo (Kohavi, 1998). The main quantitative metrics used are described below according to the contributions outlined in the studies *The Relationship Between Precision-Recall and ROC Curves* (Davis; Goadrich, 2006) and *The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation* (Chicco; Jurman, 2020).

- **Acurácia (do inglês *Accuracy*)**

A acurácia refere-se à proporção geral de predições realizadas corretamente em relação ao número total de instâncias avaliadas, como apresentada na Equação (1):

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (1)$$

Essa métrica fornece uma visão global do desempenho do classificador. Entretanto, é afetada pelo desbalanceamento entre as classes e, sozinha, pode encobrir deficiências relevantes na tarefa de detecção de *fake news*, onde erros desiguais têm impacto diferente (Chicco; Jurman, 2020).

- **Precisão (do inglês *Precision*)**

A precisão quantifica a fração de instâncias classificadas como positivas que são, de fato, corretas, conforme definido na Equação (2):

$$Precision = \frac{TP}{TP + FP} \quad (2)$$

No contexto deste trabalho, a precisão torna-se essencial para medir a taxa de falsos positivos, ou seja, casos em que notícias verdadeiras são incorretamente rotuladas como falsas — erro que pode comprometer a credibilidade de sistemas automatizados de verificação.

- **Revocação (do inglês *Recall*)**

O *recall* mede a capacidade do modelo de identificar corretamente todas as instâncias positivas, sendo expresso na Equação (3):

$$Recall = \frac{TP}{TP + FN} \quad (3)$$

Essa métrica é fundamental na tarefa de detecção de *fake news*, pois representa o grau de eficiência com o qual o modelo reconhecerá as notícias falsas, minimizando falsos negativos, que correspondem a conteúdos enganosos não identificados.

- **Pontuação F1 (do inglês *F1 – score*)**

A *F1-score* é definida pela média harmônica entre a precisão e a *recall*, como mostra a Equação (4):

$$F1 - score = 2 * \frac{Precision * Recall}{Precision + Recall} \quad (4)$$

Essa métrica é especialmente adequada em cenários de classificação textual onde há um conflito entre os erros do tipo I (*FP*) — quando notícias verdadeiras são incorretamente classificadas como falsas — e erros do tipo II (*FN*) — quando notícias falsas não são detectadas pelo modelo. O *F1-score* equilibra esses dois tipos de erro por meio da combinação entre precisão e *recall* (Davis; Goadrich, 2006).

- **Kappa de Cohen (*k*)**

O Kappa de Cohen é um coeficiente que mede o nível de correspondência entre as previsões feitas pelo modelo e os rótulos de referência, ajustando essa correspondência pelo valor esperado no caso de previsão aleatória (Chicco; Jurman, 2020). Diferentemente da acurácia, o Kappa penaliza supostas classificações que podem ocorrer devido à distribuição das classes.

Neste estudo, a medida de Kappa de Cohen é utilizada para avaliar a consistência das predições do modelo além do que seria esperado por acaso, considerando princi-

palmente o balanceamento artificial das classes e a inclusão da classe *INDETERMINADO*, fornecendo, assim, uma medida mais conservadora e robusta da confiabilidade do sistema.

- **Coeficiente de Correlação de Matthews (*MCC*)**

O Coeficiente de Correlação de Matthews é reconhecido como uma das métricas mais confiáveis para avaliação de classificadores binários, uma vez que considera *TP*, *TN*, *FP* e *FN* ao mesmo tempo, oferecendo uma avaliação equilibrada em situações de desbalanceamento de classes (Chicco; Jurman, 2020).

No contexto da pesquisa, o *MCC* se destaca por representar de maneira simétrica o desempenho geral do modelo, castigando igualmente erros ao classificar notícias falsas e verdadeiras. Valores que se aproximam de 1 indicam uma forte correlação positiva entre as previsões e os rótulos reais, enquanto valores próximos a 0 sinalizam um desempenho que é quase aleatório (Chicco; Jurman, 2020).

Além das métricas globais, também são calculadas métricas estratificadas por classe (*FAKE* e *REAL*) e por estratégia de *prompting* (*zero-shot*, *few-shot* e *chain-of-thought*) para identificar quais estratégias produzem maior acurácia. Além disso, essa análise granular permite a identificação de padrões comportamentais dos modelos, evidenciando de que forma as diversas configurações de entrada impactam o desempenho e a sensibilidade do sistema em vários cenários experimentais.

4.3.3 Métricas de Cobertura e Abstenção

O sistema *Aletheia*, baseado na pesquisa *Learning with Rejection* (Cortes; Desalvo; Mohri, 2016), introduz explicitamente métricas associadas à incerteza do modelo, possibilitando a análise não apenas do desempenho preditivo, mas também do seu comportamento diante de decisões ambíguas.

- **Cobertura (do inglês *Coverage*)**

A cobertura mede a proporção de instâncias para as quais o modelo fornece uma decisão conclusiva, ou seja, classifica em rótulos válidos (*FAKE* ou *REAL*), excluindo respostas abstidas (*INDETERMINADO*), sendo definida de acordo com a Equação (5):

$$Coverage = 1 - \frac{n_{abstain}}{n_{total}} \quad (5)$$

- **Taxa de Abstenção (do inglês *Abstention Rate*)**

A Taxa de Abstenção indica a fração de instâncias nas quais o modelo opta por não emitir uma decisão definitiva, refletindo explicitamente sua incerteza com a classe *INDETERMINADO*, dada pela Equação (6):

$$Abstention Rate = \frac{n_{abstain}}{n_{total}} \quad (6)$$

Essas métricas são relevantes em aplicações críticas, como a detecção de *fake news*, nas quais conclusões incorretas podem acarretar consequências mais prejudiciais do que a ausência deliberada de uma predição. Dessa forma, a abstenção passa a ser tratada como um comportamento desejável em situações de baixa confiança.

4.3.4 Métricas Probabilísticas e de Calibração

Com o objetivo de avaliar não apenas a decisão final do modelo, mas também a qualidade e a confiabilidade de suas estimativas de confiança, este estudo emprega métricas probabilísticas e de calibração que permitem verificar se as probabilidades associadas às predições refletem adequadamente a incerteza do modelo.

- **Brier Score**

O *Brier Score* avalia o erro quadrático médio entre as probabilidades preditas pelo modelo e os rótulos reais das instâncias, conforme a Equação (7). Essa métrica penaliza previsões excessivamente confiantes quando incorretas e recompensa previsões bem calibradas, mesmo quando a decisão final não é perfeitamente precisa (Glenn *et al.*, 1950).

$$BS = \frac{1}{N} \sum (p_i - y_i)^2 \quad (7)$$

Essa pontuação é minimizada quando as probabilidades previstas correspondem às verdadeiras probabilidades observadas. Valores mais baixos indicam melhor desempenho probabilístico, combinando simultaneamente aspectos de calibração e discriminação (Glenn *et al.*, 1950). Esta avaliação é muito útil na comparação de modelos que apresentam níveis de acurácia semelhantes, mas diferem quanto à qualidade da confiança expressa em suas respostas.

- **Erro de Calibração Esperado (*Expected Calibration Error* — ECE)**

O Erro de Calibração Esperado avalia o grau de desalinhamento entre a confiança média prevista pelo modelo e a acurácia empírica observada, considerando diferentes intervalos de probabilidade. Para tanto, as predições são agrupadas de acordo com seus níveis de confiança, e compara-se, em cada grupo, a confiança média com a taxa real de acertos (Guo *et al.*, 2017).

Essa métrica fornece uma estimativa agregada do erro de calibração do modelo: valores baixos indicam que, em média, previsões com determinada confiança apresentam acurácia compatível. No contexto de sistemas com abstenção, como o *Aletheia*, o ECE

é essencial para avaliar se as decisões de abster-se estão coerentemente associadas a baixos níveis de confiança, evitando abstenções arbitrárias ou confiantes injustificadas.

- **Área sob a Curva ROC (*Area Under the Curve - ROC — ROC-AUC*)**

A Área sob a Curva ROC quantifica a capacidade discriminativa do modelo em distinguir o limiar de decisão entre as classes positiva e negativa. Essa métrica mede a probabilidade de o modelo atribuir uma pontuação mais alta a uma instância positiva (notícia falsa) do que a uma instância negativa (notícia verdadeira), sendo independente do limiar específico adotado (Davis; Goadrich, 2006).

Embora não capture diretamente informações de calibração, a ROC-AUC fornece uma visão global da separabilidade das classes. No contexto da pesquisa, ela é utilizada como métrica complementar para verificar se as estratégias de *prompting* ou a incorporação de evidências externas via RAG influenciam a capacidade discriminativa dos modelos.

- **Área sob a Curva Precisão–Recall (*Precision–Recall AUC — PR-AUC*)**

A Área sob a Curva Precisão–Recall avalia a relação entre precisão e *recall* ao longo de diferentes limiares de decisão, sendo mais informativa em cenários com classes desbalanceadas, pois enfatiza o desempenho do modelo na identificação da classe positiva (notícias falsas) (Davis; Goadrich, 2006).

Mesmo em um cenário experimental com balanceamento artificial, a PR-AUC permanece relevante por evidenciar como o modelo lida com o compromisso entre capturar notícias falsas (*recall*) e evitar alarmes falsos (*precision*), permitindo uma leitura mais realista do desempenho esperado em aplicações práticas.

Em conjunto, essas métricas adotadas permitem verificar se o modelo apresenta bom grau de calibração, isto é, se suas estimativas de confiança estão alinhadas com seu desempenho real. Dessa forma, o *Aletheia* não avalia apenas se o modelo acerta, mas também quão justificável e confiável é o grau de confiança associado às suas predições.

4.3.5 Avaliação Qualitativa e Explicabilidade

O sistema *Aletheia* inclui ainda um conjunto de métricas qualitativas que visam analisar a qualidade textual, semântica e explicativa das respostas geradas pelos modelos. Essa fase é crucial em tarefas de detecção de *fake news*, onde tanto o rótulo atribuído quanto a justificativa apresentada influenciam diretamente na confiança do usuário e na aceitação do sistema.

A avaliação qualitativa ocorre de forma automática a partir das respostas textuais produzidas pelos modelos, em situações em que há ou não recuperação de conhecimento externo. Para cada resposta gerada, são calculadas métricas individuais, que são posteriormente agregadas por modelo e por estratégia de *prompting*, possibilitando comparações detalhadas.

- **Factualidade**

A Factualidade mede o grau de aderência da explicação gerada aos fatos e evidências disponíveis (Manakul; Liusie; Gales, 2023). Essa métrica possibilita a identificação de respostas aparentemente plausíveis, mas semanticamente desconexas das fontes — fenómeno característico de alucinações em LLMs. No *ALETHEIA*, aplica-se essa medida por meio da similaridade semântica entre o texto da resposta e o contexto recuperado via RAG, utilizando *embeddings* e similaridade cosseno. Esse método permite estimar se a justificativa produzida está semanticamente alinhada às evidências fornecidas, servindo como um indicador da veracidade factual da argumentação.

- **Relevância**

A Relevância mensura o quanto a resposta se alinha à tarefa solicitada e à instrução expressa no *prompt* (Es et al., 2024). Essa análise é fundamental para detectar respostas bem escritas, porém desalinhadas com a instrução enviada como entrada. No sistema, essa verificação é realizada com base na similaridade semântica entre o texto da resposta e o *prompt* original, o que permite verificar se a explicação permanece centrada no objetivo da classificação ou se desvia para outros assuntos não relacionados.

- **Framework RAGAS**

Nos cenários que utilizam recuperação de contexto, o *Aletheia* integra o *Framework RAGAS* para uma avaliação adicional da qualidade das respostas. O *RAGAS* é implementado para o cálculo de métricas como *faithfulness* (fidelidade à evidência recuperada) e *answer relevancy* (relevância da resposta em relação à pergunta), além de medidas auxiliares de fundamentação factual, sobreposição contextual e taxa de alucinação (Es et al., 2024). A integração do *framework* reforça a análise de explicabilidade ao verificar se as respostas geradas estão semanticamente ancoradas nas evidências recuperadas, se fazem uso correto do conteúdo fornecido e se minimizam inferências não suportadas pelas fontes.

Dessa forma, a avaliação qualitativa no *Aletheia* não se limita à correção do rótulo final, mas investiga, de maneira sistemática, a qualidade, segurança, coerência e explicabilidade do raciocínio produzido pelos modelos, em conformidade com princípios modernos de avaliação responsável de sistemas baseados em LLMs.

4.4 Desenvolvimento da Aplicação para o Usuário Final

Com base nos modelos e estratégias de *prompting* mais promissoras identificadas na etapa experimental, foi desenvolvido um protótipo funcional de aplicação voltado ao apoio à verificação de notícias pelo público geral. Diferentemente de um sistema plenamente estabilizado, esta etapa representa um processo de consolidação tecnológica, no qual os fluxos de uso real

são implementados, testados e progressivamente refinados a partir dos resultados experimentais obtidos.

A proposta desta aplicação é transformar o mecanismo analítico avaliado em uma ferramenta acessível, capaz de receber notícias dos usuários e devolver, como resposta, uma classificação final, acompanhada de uma estimativa de confiança e de uma justificativa textual interpretável. Essa abordagem é particularmente adequada ao cenário brasileiro, no qual plataformas de mensageria desempenham papel central na circulação de informações jornalísticas e conteúdos informativos. Relatórios da *We Are Social* em colaboração com a *Meltwater* (Social; Meltwater, 2025) e o Instituto Reuters para o Estudo do Jornalismo (Newman *et al.*, 2025) revelam que, no final de 2025, havia 185 milhões de pessoas conectadas e 150 milhões de identidades em redes sociais. Cerca de 40,8% dos adultos usuários de mídias sociais afirmam utilizar esses canais para encontrar conteúdos informativos e 33,8% dos usuários adultos afirmam se informar sobre assuntos recentes por meio das redes sociais.

4.4.1 Arquitetura Geral da Aplicação

Do ponto de vista arquitetural, a aplicação foi organizada em camadas bem definidas, priorizando a modularidade e a reutilização do núcleo analítico desenvolvido na fase experimental, como ilustrado na Figura 3. Na base da arquitetura, encontra-se uma API central implementada em *FastAPI* (Ramírez, 2026), responsável por concentrar toda a lógica de orquestração das análises, o gerenciamento de conversas e a exposição, para consumo externo, de serviços como interação conversacional (`/api/v1/chat`), análise estruturada de notícias (`/api/v1/analyze/news`), *webhooks* de integração com plataformas externas (Telegram e WhatsApp), bem como o monitoramento e a verificação de saúde do sistema (`/api/v1/health`).

Sobre a API principal, foram implementados *bots* de integração para Telegram e WhatsApp, ambos derivados de uma classe base abstrata. Essa estratégia padroniza o envio de mensagens à API central, o tratamento de respostas estruturadas e o controle de sessões e histórico, garantindo que novos canais — como aplicações *web* ou outros serviços de mensageria — possam ser incorporados sem a necessidade de alterações no núcleo analítico.

Independentemente do canal de entrada, todas as mensagens são encaminhadas ao *endpoint* conversacional da API (`/api/v1/chat`). Esse *endpoint* é responsável por criar ou recuperar a sessão do usuário, registrar o histórico da conversa, identificar comandos especiais ou saudações e encaminhar o conteúdo ao motor de produção para análise. O motor de produção retorna uma resposta estruturada contendo classificação, nível de confiança, justificativa e metadados, a qual é formatada pelo *bot* de acordo com o canal de origem (Telegram ou WhatsApp), preservando clareza e concisão para o usuário final.




Figura 3 – Arquitetura geral da aplicação Aletheia.

Fonte: Autoria própria (2026).

4.4.2 Integração com Telegram e WhatsApp

No Telegram, o *bot* utiliza o mecanismo de *handlers*, fornecido pela biblioteca *python-telegram-bot*, para associar cada mensagem recebida a um tipo específico de evento, como comandos (*/ajuda*, */limpar*, */sobre*) ou mensagens de texto livre, preservando o contexto da sessão. O Telegram oferece suporte tanto ao modelo de *polling* quanto ao de *webhooks*; no primeiro, o servidor consulta periodicamente a API do Telegram em busca de novas mensagens, enquanto, no segundo, a própria plataforma notifica a aplicação sempre que um evento ocorre.

No WhatsApp, a integração ocorre, de forma mandatória, por meio do mecanismo de *webhooks*, conforme definido pela plataforma Twilio (Inc., 2025). Nesse modelo, sempre que um usuário envia uma mensagem, a Twilio realiza uma requisição HTTP do tipo POST para o *endpoint* exposto pela aplicação (*/webhook/whatsapp*). O corpo da requisição é recebido no formato de formulário e processado pelo *bot*, que, em seguida, responde utilizando *Twiml* (*Twilio Markup Language*).

4.4.3 Gerenciamento do Protótipo

A inicialização do protótipo foi projetada visando automatizar o ciclo de vida dos serviços que compõem a aplicação. Um gerenciador central é responsável por inicializar a API *FastAPI*

e os *bots* de mensageria, atualizar automaticamente o *webhook* do WhatsApp com o endereço público exposto via *ngrok* e garantir a limpeza adequada de recursos em eventos de *shutdown* (Inc., 2025). Para a inicialização e o encerramento de recursos críticos — tais como o carregamento do motor de inferência e o fechamento de conexões externas — a API utiliza os eventos de *startup* e *shutdown* do *FastAPI*, reduzindo, assim, o risco de vazamentos de memória e assegurando maior previsibilidade operacional (Ramírez, 2026).

Foram definidos *middlewares* específicos para controle de CORS (*Cross-Origin Resource Sharing*), limitando as origens externas autorizadas a acessar a API, assim como para *Trusted Host*, restringindo os domínios habilitados a realizar requisições ao serviço (World Wide Web Consortium, 2020). Além disso, a aplicação expõe *endpoints* de monitoramento que verificam o estado do sistema e o uso de recursos computacionais, como CPU, memória e disco. Esses mecanismos são fundamentais para futuros cenários de escalonamento e observabilidade.

No núcleo da aplicação encontra-se o *ProductionEngine*, responsável por reutilizar os componentes analíticos definidos na fase experimental. Esse motor concentra a lógica de inferência e implementa a transição do ambiente experimental para o uso em produção. A configuração empregada nesta etapa define um modelo primário, correspondente àquele que obteve o melhor desempenho experimental em conjunto com sua estratégia de *prompting* associada, como também um modelo de *fallback*, que é acionado caso o modelo principal não atinja um limiar mínimo de confiança de 0,7 para aceitação automática da resposta. Esse desenho separa de maneira clara as fases do projeto, uma vez que os experimentos não apenas avaliam modelos, mas informam diretamente quais fluxos são promovidos ao ambiente de uso real.

Adicionalmente, o motor implementa mecanismos direcionados à eficiência operacional, como o uso de *cache* em Redis, com tempo de vida de 60 minutos, reduzindo o custo computacional em consultas repetidas (Carlson, 2013), o pré-carregamento do modelo principal com aquecimento de três *prompts* iniciais, com o objetivo de estabilizar a latência do serviço; e o controle explícito da limpeza de modelos e conexões ao final do processo de execução.

A resposta entregue ao usuário final é padronizada e orientada à interpretabilidade. A aplicação retorna a classificação final (*REAL*, *FAKE* ou *INDETERMINADO*), uma estimativa de confiança, uma justificativa textual resumida e, quando necessário, informações técnicas adicionais. A formatação da resposta utiliza elementos textuais de apoio visual, como ícones associados às classes e barras de confiança textual, facilitando a compreensão por usuários não especializados. Como ilustrado na Figura 4, as mensagens iniciais do *bot Aletheia* refletem a coerência dessa escolha com o propósito do sistema de não apenas emitir um veredito, mas também tornar a decisão compreensível e auditável, reduzindo opacidade algorítmica e promovendo confiança informada.

O sistema adota ainda um gerenciador de sessões em memória para manter um histórico mínimo das interações, com tempo de expiração de 30 minutos e limite de mensagens por sessão. Embora simples, essa abordagem é adequada ao estágio atual da aplicação e evita o consumo excessivo de memória. A arquitetura prevê a utilização do Redis como solução de




Figura 4 – Interface de conversação do bot Aletheia.

Fonte: Autoria própria (2026).

persistência temporária e *cache*, permitindo evolução futura para armazenamento distribuído e maior escalabilidade.

Em conjunto, essas decisões de projeto refletem a natureza do sistema como um protótipo funcional em consolidação, no qual robustez conceitual, reprodutibilidade e interpretabilidade são priorizadas em detrimento de otimizações prematuras. Em um sistema de verificação de notícias voltado ao uso cotidiano, estabilidade operacional, previsibilidade de resposta e clareza explicativa constituem requisitos fundamentais, princípios que orientaram a estrutura desta aplicação.

5 RESULTADOS E DISCUSSÃO

5.1 Introdução e Escopo dos Experimentos

Este capítulo apresenta e discute os resultados obtidos pela aplicação da metodologia descrita no Capítulo 4. O objetivo é verificar a hipótese de pesquisa e avaliar o desempenho dos LLMs na detecção de *fake news* em português, por meio da comparação de diferentes estratégias de *prompting* e arquiteturas de modelos. A estrutura experimental foi organizada em três etapas sequenciais. A primeira etapa envolveu testes controlados utilizando 50 notícias falsas e 50 notícias verdadeiras do corpus *FakeTrue.Br* (Chavarro *et al.*, 2023). Para cada instância, foram geradas seis variações de *prompt*, totalizando 600 *prompts* por modelo e 4.200 inferências, considerando os sete modelos avaliados.

Nesta fase, os parâmetros de geração e as instruções de cada estratégia foram refinados iterativamente com base nas saídas observadas, visando identificar as configurações de melhor desempenho para cada modelo. Na segunda etapa, o modelo de melhor desempenho, juntamente com sua estratégia de *prompting* otimizada, foi aplicado ao conjunto completo do *FakeTrue.Br*. Este procedimento forneceu estimativas de métricas sobre uma base representativa do corpus. Por fim, a terceira etapa consistiu na submissão de notícias mais recentes, que não pertenciam ao período de cobertura do *FakeTrue.Br*, ao sistema. O intuito foi avaliar a capacidade de generalização do modelo selecionado em cenários que se diferenciavam da distribuição de treinamento. Durante o processo experimental, desafios técnicos relevantes foram identificados e solucionados, conforme detalhado na Seção 5.3. Esses desafios influenciaram diretamente as decisões de projeto e os resultados obtidos.

5.2 Configuração Experimental

Os experimentos foram conduzidos em um ambiente controlado com aceleração GPU, empregando os sete modelos especificados na Seção 4.3. Para possibilitar a inferência local, todos os modelos foram quantizados para 4-bit (NF4) utilizando a biblioteca *BitsAndBytes*, com exceção do modelo Phi-4, que foi quantizado em 8-bit. Cada modelo foi avaliado com as seis estratégias de *prompting* definidas na Seção 4.2: *zero-shot-in*, *few-shot-in*, *cot-in*, *zero-shot-ex*, *few-shot-ex* e *cot-ex*. Para as estratégias com recuperação de conhecimento externo (*-ex), o contexto foi obtido via RAG a partir das fontes DuckDuckGo (DuckDuckGo, 2024), GDELT (Lee-taru; Schrodtt, 2023) e Google Fact Check API (Google LLC, 2024), processado e indexado com FAISS e *embeddings* do modelo *intfloat/multilingual-e5-large* (Johnson; Douze; Jégou, 2019; Wang *et al.*, 2024b).

As respostas textuais dos modelos foram processadas por um *pipeline* de pós-processamento, que incluiu um classificador auxiliar baseado no modelo *Qwen 2.5 3B Instruct* (Qwen Team, 2024b; Yang *et al.*, 2024) e expressões regulares. Este *pipeline* foi responsável pela extração estruturada da classe predita (*FAKE*, *REAL* ou *INDETERMINADO*) e da probabili-

dade de confiança associada. O processo de *fine-tuning* dos parâmetros, incluindo temperatura, *top-p*, *top-k* e *repetition penalty*, bem como o refinamento iterativo dos *templates* de *prompt*, foi realizado com base na análise qualitativa das respostas geradas em rodadas preliminares.

5.3 Desafios Técnicos e Soluções Adotadas

A execução da etapa experimental revelou desafios técnicos, cuja identificação e resolução representam contribuições metodológicas significativas deste trabalho.

5.3.1 Geração de Respostas em Língua Inglesa

Modelos como Phi-4 ([Microsoft, 2024](#)), DeepSeek R1 Distill Qwen 32B ([DeepSeek-AI, 2025](#)) e Qwen 2.5 14B ([Qwen Team, 2024a](#)), por terem sido predominantemente pré-treinados em corpora multilíngues com forte representação do inglês, tenderam a gerar respostas nesse idioma, mesmo quando o *prompt* estava integralmente em português. Esse comportamento comprometia tanto a extração das classes quanto a qualidade das justificativas para o público-alvo. A solução implementada consistiu na inclusão de uma instrução explícita e reforçada ao final de cada *template* de *prompt* – “Responda APENAS nas etapas solicitadas, em português brasileiro” – combinada com o ajuste do parâmetro de temperatura para valores menores, o que reduziu a variabilidade das respostas e aumentou a aderência ao idioma especificado.

5.3.2 Esgotamento de Memória em Modelos de Grande Porte

Modelos de maior porte, como Qwen 2.5 14B ([Qwen Team, 2024a](#)), Gemma 3 12B ([Google, 2024](#)) e DeepSeek R1 Distill Qwen 32B ([DeepSeek-AI, 2025](#)), apresentaram esgotamento progressivo de memória GPU e CPU durante execuções prolongadas. Este problema causava interrupções na aplicação e comprometia a reprodutibilidade dos experimentos. Para mitigar essa questão, foi desenvolvido um motor de limpeza de memória periódica, que opera entre inferências consecutivas. Esse motor combina a liberação explícita do cache CUDA (`torch.cuda.empty_cache()`), a coleta de lixo (`gc.collect()`) e a reinicialização controlada do modelo após lotes predefinidos de instâncias. Essa solução permitiu a execução estável dos modelos mais intensivos sem a necessidade de reinicialização manual do processo, aumentando a reprodutibilidade do experimento.

5.3.3 Recuperação de Contexto Fora do Escopo Temporal

A integração com fontes externas via RAG introduziu um desafio de relevância temporal: as buscas frequentemente retornavam documentos com datas fora do intervalo de cobertura do *FakeTrue.Br* (2017–2023), inserindo informações no contexto que poderiam gerar conflitos

anacrônicos com o conteúdo das notícias analisadas. Para abordar essa limitação, foi implementada uma lógica de filtragem temporal que descarta documentos com datas identificadas fora do intervalo estabelecido. Adicionalmente, a heterogeneidade das fontes *web* dificultava a identificação dos trechos mais informativos para compor o contexto. Para superar esse problema e aprimorar a qualidade do conteúdo recuperado, adotou-se uma técnica híbrida para a construção das consultas de busca, estruturada em três etapas: (i) extração de entidades nomeadas com *spaCy* (Honnibal *et al.*, 2020), para identificar elementos relevantes, como personagens, locais, datas e organizações presentes na notícia; (ii) extração de palavras-chave semânticas com *KeyBERT* (Issa *et al.*, 2023), priorizando termos com maior peso informacional com base em similaridade contextual; e (iii) ranqueamento por similaridade semântica com representações vetoriais (*embeddings*), para selecionar as consultas mais alinhadas ao conteúdo da notícia para a recuperação de evidências pertinentes.

A partir do contexto obtido nas fontes, aplicou-se um método adicional de seleção de evidências baseado em *embeddings* indexados com o *framework FAISS* (Johnson; Douze; Jégou, 2019), combinado a uma ferramenta de segmentação de texto em unidades menores e semanticamente coerentes. Este processo possibilitou a seleção dos trechos mais alinhados ao conteúdo da notícia dentro das restrições de *tokens* dos modelos utilizados. Como resultado, essa abordagem integrada aumentou a relevância e a consistência do contexto incorporado aos *prompts* no paradigma de RAG.

5.3.4 Avaliação Qualitativa sem Modelos Proprietários (RAGAS com Ollama)

O *framework RAGAS* (Es *et al.*, 2024) é comumente configurado com *LLMs* proprietários, em particular o GPT-4 (Achiam *et al.*, 2023), como modelo juiz para as métricas de *faithfulness* e *answer relevancy*. Considerando que este estudo adota deliberadamente modelos de código aberto executados localmente, foi necessário adaptar a integração do RAGAS para utilizar o modelo *Gemma3:12b* via Ollama como LLM avaliador (Marcondes *et al.*, 2025). Esta adaptação exigiu a configuração de um cliente Ollama compatível com a interface esperada pelo RAGAS e a adequação dos *prompts* juntamente com as métricas para o modelo local, assegurando que a avaliação qualitativa fosse conduzida integralmente sem dependência de APIs externas pagas, o que preservou a replicabilidade do experimento.

5.3.5 Extração Estruturada de Classes e Probabilidades

Os modelos avaliados não produzem saídas estruturadas por padrão: a classe predita e a probabilidade de confiança estão embutidas em respostas textuais livres, com variações de formatação entre modelos e estratégias. Para garantir a extração confiável dessas informações, foi implementado um módulo de pós-processamento de duas camadas. A primeira camada emprega o modelo *Qwen 2.5 3B Instruct* (Qwen Team, 2024b; Yang *et al.*, 2024) como classificador auxiliar, aproveitando sua capacidade de compreensão semântica para normalizar a saída de

forma consistente. A segunda camada aplica expressões regulares para identificar padrões de classificação ("*FAKE*", "*REAL*", "*INDETERMINADO*") e valores percentuais de confiança nas respostas. Esta abordagem em dois níveis reduziu a taxa de respostas classificadas como *INDETERMINADO* por falha de extração, aumentando a cobertura efetiva das avaliações.

5.4 Refinamento Iterativo dos Modelos

A fase experimental foi conduzida de forma iterativa, com ajustes progressivos nos *templates* de *prompt* e nos parâmetros de geração de cada modelo. Em rodadas iniciais, observou-se que instruções excessivamente abertas, sem limitar o número de itens por seção ou exigir explicitamente a seção de conclusão, resultavam em respostas prolixas, com conclusões omitidas ou inseridas em meio ao texto, prejudicando a extração estruturada. A incorporação de restrições explícitas ("*máximo de 3 itens por seção*", "*a seção Conclusão é OBRIGATÓRIA*") e de exemplos bem formulados nas estratégias de *few-shot* reduziu substancialmente a taxa de respostas mal formatadas.

No que diz respeito aos parâmetros de geração, a temperatura foi ajustada para valores no intervalo [0,1; 0,3] nos modelos com maior tendência a produzir respostas genéricas ou em inglês, enquanto o *repetition penalty* foi calibrado para evitar a repetição de trechos do *prompt* nas respostas, comportamento observado especialmente nos modelos Falcon3 e Mistral. Os ajustes iterativos e seus impactos nas métricas de classificação são sintetizados na Tabela 3.

Tabela 3 – Evolução das métricas de *F1-score* por modelo ao longo das rodadas de refinamento de *prompt* e parâmetros (versão inicial vs. versão final).

(continua)

Modelo	<i>F1_{vInicial}</i>	<i>F1_{vFinal}</i>	$\Delta F1$	Principais ajustes
Falcon 3 10B Instruct	0.54	0.87	+0.33	Refinamento de <i>prompt</i> , melhoria de contexto, ajuste do <i>chat_template</i> e <i>fine-tuning</i>
Mistral 7B Instruct	0.56	0.79	+0.23	Refinamento de <i>prompt</i> , melhoria de contexto, ajuste do <i>chat_template</i> e <i>fine-tuning</i>
Qwen 2.5 14B Instruct	–	0.88	–	Troca de versão do modelo, refinamento de <i>prompt</i> , melhoria de contexto, ajuste do <i>chat_template</i> e <i>fine-tuning</i>
Llama 3.1 8B Instruct	0.54	0.83	+0.29	Refinamento de <i>prompt</i> , melhoria de contexto, ajuste do <i>chat_template</i> e <i>fine-tuning</i>
Gemma 3 12B IT	0.48	0.88	+0.40	Refinamento de <i>prompt</i> , melhoria de contexto, ajuste do <i>chat_template</i> e <i>fine-tuning</i>
Phi 4	0.46	0.85	+0.39	Refinamento de <i>prompt</i> , melhoria de contexto, ajuste do <i>chat_template</i> e <i>fine-tuning</i>

Evolução das métricas de *F1-score* por modelo ao longo das rodadas de refinamento de *prompt* e parâmetros (versão inicial vs. versão final).

(continuação)

Modelo	<i>F1</i> <i>vInicial</i>	<i>F1</i> <i>vFinal</i>	$\Delta F1$	Principais ajustes
DeepSeek R1 Distill Qwen 2.5 32B	0.48	0.62	+0.14	Refinamento de <i>prompt</i> , melhoria de contexto, ajuste do <i>chat_template</i> e <i>fine-tuning</i>

Fonte: Autoria própria (2026).

A Tabela 3 apresenta a evolução do *F1-score* dos modelos entre a versão inicial dos *prompts* e a configuração final adotada nos experimentos. Observa-se que modelos mais sensíveis a instruções explícitas de idioma, como o Qwen 2.5, o Phi 4 e o DeepSeek R1 Distill Qwen 2.5, demandaram ajustes mais significativos ao longo do processo. No caso do Qwen 2.5, houve a substituição da versão inicial de 7 bilhões de parâmetros por uma versão de 14 bilhões de parâmetros. Em razão dessa mudança, não há resultados correspondentes à versão inicial desse modelo nos experimentos, o que inviabiliza a comparação direta de sua evolução. Para o modelo Phi 4, verificou-se um ganho expressivo de desempenho: inicialmente apresentando o menor *F1-score* entre os modelos avaliados, passou a ocupar uma das melhores posições na configuração final, atingindo um *F1-score* de 0,85. Já o modelo DeepSeek R1 Distill Qwen 2.5 apresentou melhora em relação à versão inicial; contudo, seu desempenho permaneceu inferior ao dos demais modelos, possivelmente em função de limitações decorrentes do processo de destilação, que pode reduzir a capacidade de generalização e a qualidade da representação semântica em tarefas mais complexas.

No que se refere ao refinamento dos *prompts*, destacam-se algumas estratégias fundamentais: a separação entre *prompt* e *system_message*, a definição clara da tarefa, a inclusão de instruções estruturadas com regras que controlam as seções da resposta – garantindo, por exemplo, a presença obrigatória de uma conclusão – e a introdução de uma escala de confiança. Esta última contribui para explicitar a semântica associada às probabilidades fornecidas pelo modelo, aproximando a estimativa de confiança da acurácia real observada. Ademais, foi implementada uma estrutura que induz o modelo a classificar o tipo de conteúdo antes de proceder à análise factual, promovendo maior consistência nas respostas.

Quanto à melhoria de contexto, além da etapa de extração de palavras-chave das notícias para a construção das consultas de busca, foram adicionados termos como “boato”, “falso”, “fake”, “checagem” e “verificação”. Essa estratégia está alinhada à natureza do conjunto de dados *FakeTrue.Br*, que foi construído a partir da coleta de conteúdos provenientes de portais de *fact-checking* e de fontes jornalísticas, favorecendo a recuperação de evidências mais relevantes para a tarefa. Por fim, as principais melhorias relacionadas ao *fine-tuning* concentraram-se na redução da temperatura e na limitação do número máximo de novos *tokens* gerados nas respostas. Essas definições foram apoiadas por um cálculo prévio do tamanho máximo de *tokens* de entrada de cada modelo, associado à adoção de uma margem de segurança de 100 *tokens*,

o que contribuiu para maior estabilidade, controle da geração textual e aderência às restrições de contexto.

5.5 Resultados da Fase de Testes Controlados

Esta seção detalha os resultados obtidos na fase de testes, que envolveu 100 instâncias balanceadas do *FakeTrue.Br*, comparando o desempenho de sete modelos em seis estratégias de *prompting*.

5.5.1 Métricas Quantitativas por Estratégia de *Prompting*

A Tabela 4 resume o desempenho médio dos modelos, agrupado por estratégia de *prompting*. Os resultados indicam que as estratégias que empregam o conhecimento interno dos modelos (**-in*) apresentam desempenho superior às estratégias que utilizam recuperação de conhecimento externo (**-ex*) em todas as métricas avaliadas.

Tabela 4 – Desempenho médio dos modelos por estratégia de *prompting* — Acurácia, Precisão, Recall, F1-score macro, Kappa e MCC (médias sobre os 7 modelos, 100 instâncias).

Estratégia	Acurácia	Precisão	Recall	F1-score	Kappa	MCC
zero-shot-in	0.63	0.81	0.79	0.78	0.39	0.43
zero-shot-ex	0.62	0.81	0.78	0.77	0.37	0.41
few-shot-in	0.70	0.88	0.87	0.87	0.53	0.56
few-shot-ex	0.70	0.82	0.80	0.79	0.48	0.50
cot-in	0.71	0.91	0.91	0.90	0.53	0.57
cot-ex	0.65	0.83	0.78	0.77	0.35	0.41

Fonte: Autoria própria (2026).

A estratégia *cot-in* obteve os melhores resultados médios neste experimento, registrando acurácia de 71%, precisão de 91%, *recall* de 91% e *F1-score macro* de 90%. Adicionalmente, alcançou os maiores valores de *Cohen's Kappa* (0,53) e *Matthews Correlation Coefficient* (0,57). Esses valores sugerem não apenas uma elevada capacidade de classificação, mas também uma maior concordância com os rótulos de referência e um melhor equilíbrio entre as classes. A estratégia *few-shot-in* demonstrou o segundo melhor desempenho geral, com um *F1-score macro* de 87% e valores de *Kappa* e *MCC* próximos aos da estratégia *cot-in*. Conclui-se que a inclusão de exemplos demonstrativos (*few-shot*) e de raciocínio passo a passo (*Chain-of-Thought*) contribuiu significativamente para o desempenho quando combinada com o conhecimento interno dos modelos. Em contraste, as estratégias que empregaram conhecimento externo exibiram uma redução consistente em todas as métricas, sendo mais acentuada nas abordagens baseadas em raciocínio encadeado (*cot-ex*), que apresentaram um *F1-score* médio de 77%.

Embora a literatura frequentemente relacione a recuperação de conhecimento externo a melhorias em tarefas de verificação factual, os resultados deste experimento indicam um efeito distinto. A análise qualitativa das respostas sugere que parte dos erros nas estratégias **-ex* resultou de uma ambiguidade na definição da tarefa fornecida pelo *system_message*. Dado que o conjunto *FakeTrue.Br* contém tanto notícias factuais quanto verificações jornalísticas de boatos rotuladas como *REAL*, e as fontes recuperadas pelo mecanismo de RAG são predominantemente de veículos jornalísticos e plataformas de *fact-checking*, os modelos passaram a associar a existência de fontes confiáveis que desmentem uma alegação à classe *REAL*, independentemente do conteúdo efetivo da notícia analisada.

Esse comportamento levou a classificações incorretas em cenários onde a notícia correspondia à própria alegação falsa, mas as fontes externas recuperadas continham o desmentido. Nessas situações, os modelos frequentemente interpretaram a notícia como uma verificação de fatos legítima, enquanto o desmentido estava presente apenas nas fontes externas. Como consequência, observou-se uma redução sistemática do desempenho das estratégias baseadas em conhecimento externo, sugerindo que o problema reside na interpretação das evidências recuperadas, e não necessariamente na qualidade das fontes utilizadas.

A Figura 5 complementa esta análise ao apresentar a comparação visual dos valores médios de *F1-score* alcançados por cada estratégia de *prompting*. Observa-se um desempenho superior das abordagens *cot-in* e *few-shot-in*. Em contraste, todas as estratégias que integraram recuperação de conhecimento externo exibiram resultados inferiores quando comparadas às suas respectivas contrapartes internas.




Figura 5 – Comparação do *F1-score* médio por estratégia de *prompting*.

Fonte: Autoria própria (2026).

A diferença observada sugere que o mecanismo de recuperação de evidências, quando combinado à formulação original do *system_message*, introduziu um viés de classificação associado à presença de conteúdo de verificação de fatos nas fontes recuperadas. Consequen-

temente, o gráfico corrobora a hipótese de que a principal limitação das estratégias *-ex não residia na disponibilidade de evidências externas, mas sim na interpretação dessas evidências durante o processo de decisão. Este resultado fundamenta a necessidade de revisar as instruções da *system_message*, conforme detalhado posteriormente.

5.5.2 Métricas Quantitativas por Modelo de Linguagem

A Tabela 5 detalha o desempenho individual de cada modelo em sua configuração de *prompting* ideal. A avaliação utilizou um conjunto de métricas complementares, que incluiu acurácia, *F1-score macro*, coeficiente *Kappa*, *MCC* e taxa de abstenção. Dada a variação na proporção de respostas classificadas como *INDETERMINADO* entre os modelos, a análise priorizou métricas que avaliam simultaneamente o desempenho, o equilíbrio entre classes e a confiabilidade das decisões.

Tabela 5 – Desempenho individual dos modelos — melhor estratégia de cada modelo.								
Modelo	Melhor Estratégia	Acurácia	Precisão	Recall	F1-score	Kappa	MCC	Abstenção (%)
Phi 4	cot-in	0.85	0.98	0.98	0.98	0.73	0.76	13
Gemma 3 12B IT	cot-in	0.83	0.97	0.96	0.96	0.70	0.73	14
Falcon 3 10B Instruct	cot-in	0.77	0.99	0.98	0.99	0.62	0.68	22
Qwen 2.5 14B Instruct	cot-in	0.74	0.96	0.94	0.95	0.57	0.63	22
Mistral 7B Instruct	few-shot-in	0.77	0.93	0.93	0.93	0.61	0.64	17
Llama 3.1 8B Instruct	cot-in	0.60	0.91	0.94	0.92	0.41	0.48	35
DeepSeek R1 Distill Qwen 2.5 32B	cot-in	0.59	0.75	0.74	0.72	0.31	0.33	18

Fonte: Autoria própria (2026).

O modelo Phi-4 demonstrou o melhor desempenho geral com a estratégia *cot-in*, atingindo uma acurácia de 85% e *F1-score macro* de 98%. Adicionalmente, o Phi-4 apresentou os valores mais elevados de *Kappa* e *MCC* entre todas as combinações de modelo e estratégia testadas. Essas métricas corrigem o efeito de concordâncias aleatórias e são menos suscetíveis às diferenças de cobertura entre os modelos. O modelo também obteve um *recall* de 100% para a classe *REAL* e 95% para a classe *FAKE*, indicando um equilíbrio na identificação das duas categorias.

O Gemma 3 12B IT, também com a estratégia *cot-in*, alcançou o segundo melhor desempenho. Este modelo apresentou uma acurácia de 83%, *Kappa* de 70%, *F1-score macro* de 96% e *MCC* de 73%, mantendo consistência em todas as métricas analisadas. Seus valores de *recall* de 98% para a classe *REAL* e 95% para a classe *FAKE* também refletem um comportamento equilibrado, sem favorecimento significativo de uma classe.

Embora o Falcon 3 10B Instruct tenha obtido o maior *F1-score macro* da avaliação, 99%, em sua configuração *cot-in*, este resultado foi acompanhado por uma cobertura substancialmente menor, de 78%, correspondente a uma taxa de abstenção de 22%. Isso implica que parte do desempenho elevado pode ser atribuída à exclusão de instâncias mais desafiadoras. Uma situação análoga foi observada na configuração *few-shot-ex*, que exibiu alta acurácia global, mas valores inferiores de calibração probabilística e capacidade discriminativa, conforme indicado por um *Brier Score* mais elevado e menor poder de separação entre acertos e erros.

Em geral, os resultados sugerem que as estratégias baseadas em raciocínio encadeado com conhecimento interno (*cot-in*) resultaram nos melhores desempenhos para a maioria dos modelos avaliados. Este padrão é consistente com a análise da Subseção 5.5.1, que identificou um viés introduzido pela combinação entre a recuperação de conhecimento externo e a formulação original do *system_prompt*. Conforme discutido, esse fator impactou negativamente algumas estratégias **-ex*, favorecendo o desempenho relativo das abordagens que utilizam exclusivamente o conhecimento interno dos modelos.

A Figura 6 complementa esta análise ao ilustrar a distribuição dos valores de *F1-score* para cada combinação de modelo e estratégia de *prompting*. Observa-se que as estratégias *cot-in* concentram os melhores resultados para a maioria dos modelos, destacando os desempenhos do Phi-4, Gemma 3 12B IT e Falcon 3 10B Instruct. O gráfico também evidencia uma redução sistemática nas estratégias que utilizam recuperação de conhecimento externo, reforçando a hipótese de que a ambiguidade no *system_prompt* influenciou negativamente a interpretação das evidências recuperadas pelo mecanismo de RAG.

5.5.3 Métricas de Cobertura e Abstenção

A taxa de abstenção indica a proporção de instâncias classificadas como *INDETERMINADO*, representando casos em que o modelo não atingiu o nível de confiança mínimo para uma classificação definitiva. Consequentemente, a cobertura refere-se à proporção de notícias para as quais o sistema forneceu um veredito *FAKE* ou *REAL*. A avaliação conjunta dessas métricas permite analisar tanto a qualidade das classificações quanto a disposição dos modelos em tomar decisões em cenários potencialmente ambíguos.

Os resultados da Tabela 6 revelam diferenças significativas entre modelos e estratégias de *prompting*. O menor índice de abstenção foi observado no modelo Falcon 3 10B Instruct com a estratégia *few-shot-ex*, que registrou 5% de respostas *INDETERMINADO*, seguido pelo Phi-4 com a mesma estratégia, com 6%. Em contraste, os maiores índices foram nas estratégias *cot-ex* do Gemma 3 12B IT (47%) e do Qwen 2.5 14B Instruct (39%), o que sugere




Figura 6 – *F1-score* por modelo e por estratégia de *prompting*.

Fonte: Autoria própria (2026).

uma dificuldade elevada desses modelos em produzir decisões conclusivas quando submetidos simultaneamente ao raciocínio encadeado e à recuperação de conhecimento externo.

Tabela 6 – Taxa de abstenção (%) e cobertura por modelo e por estratégia de *prompting*.

Modelo	zero-shot-in	zero-shot-ex	few-shot-in	few-shot-ex	cot-in	cot-ex
Phi 4	13	29	11	6	13	10
Gemma 3 12B IT	13	12	18	7	14	47

Taxa de abstenção (%) e cobertura por modelo e por estratégia de *prompting*.

(continuação)

Modelo	zero-shot-in	zero-shot-ex	few-shot-in	few-shot-ex	cot-in	cot-ex
Falcon 3 10B Instruct	14	20	16	5	22	8
Qwen 2.5 14B Instruct	35	20	31	15	22	39
Mistral 7B Instruct	21	24	17	21	23	25
Llama 3.1 8B Instruct	25	23	11	9	35	14
DeepSeek R1 Distill Qwen 2.5 32B	21	12	18	17	18	18

Fonte: Autoria própria (2026).

Ao contrário do esperado, as estratégias com recuperação de conhecimento externo (*-ex) não reduziram consistentemente as taxas de abstenção. Em diversos modelos, tal como Gemma 3 12B IT e Qwen 2.5 14B Instruct, houve um aumento significativo na frequência de respostas *INDETERMINADO*. Este comportamento sugere que a inclusão das evidências recuperadas pelo mecanismo de RAG introduziu informações potencialmente conflitantes ou ambíguas no processo de decisão. Este fenômeno é consistente com o que foi discutido na Subseção 5.5.1 para as estratégias *-ex. A interação entre o conteúdo recuperado pelo mecanismo de RAG e a formulação original das instruções aumentou a ocorrência de evidências interpretadas como conflitantes, elevando a incerteza dos modelos e, por conseguinte, a frequência de respostas classificadas como *INDETERMINADO*.

Também se observa que estratégias baseadas em *Chain-of-Thought* não produziram um comportamento uniforme. Enquanto modelos como Phi-4 e Gemma 3 12B IT obtiveram bons resultados com *cot-in*, mantendo taxas de abstenção moderadas (13% e 14%, respectivamente), outros modelos apresentaram um aumento substancial da abstenção quando o raciocínio encaadeado foi combinado com a recuperação externa de conhecimento. Este resultado indica que a eficácia do raciocínio explícito depende não apenas da capacidade do modelo, mas também da qualidade e consistência das evidências fornecidas durante a inferência.

Em suma, os resultados indicam que a cobertura não é determinada exclusivamente pela complexidade instrucional do *prompt*, mas também pela interação entre o modelo, a estratégia de raciocínio empregada e a natureza das evidências disponibilizadas. Em particular, a alta taxa de abstenção observada em algumas estratégias *-ex constitui uma evidência adicional de que a configuração original do sistema introduziu ambiguidades interpretativas que impactaram negativamente o processo de tomada de decisão dos modelos.

5.5.4 Métricas Probabilísticas e de Calibração

Além das métricas de classificação, a análise probabilística permite avaliar a qualidade das estimativas de confiança produzidas pelos modelos. A Tabela 7 detalha os resultados de ROC-AUC, PR-AUC, *Brier Score*, ECE (*Expected Calibration Error*) e confiança média para cada modelo em sua melhor configuração de *prompting*. É importante destacar que as métricas *Brier Score* e ECE foram calculadas apenas para as instâncias efetivamente classificadas (*FAKE* e *REAL*).

Tabela 7 – Métricas probabilísticas dos modelos na melhor estratégia de *prompting*.

Modelo	Melhor Estratégia	ROC-AUC	PR-AUC	<i>Brier Score</i>	ECE	Confiança Média
Phi 4	cot-in	0.64	0.54	0.02	0.08	0.90
Gemma 3 12B IT	cot-in	0.52	0.56	0.04	0.04	0.93
Falcon 3 10B Instruct	cot-in	0.38	0.57	0.02	0.05	0.94
Qwen 2.5 14B Instruct	cot-in	0.46	0.58	0.05	0.06	0.89
Mistral 7B Instruct	few-shot-in	0.57	0.60	0.11	0.08	0.90
Llama 3.1 8B Instruct	cot-in	0.85	0.84	0.29	0.30	0.67
DeepSeek R1 Distill Qwen 2.5 32B	cot-in	0.87	0.83	0.26	0.29	0.88

Fonte: Autoria própria (2026).

Observa-se que os modelos com melhor desempenho na tarefa de classificação também apresentaram as melhores métricas de calibração. O Phi-4, empregando a estratégia *cot-in*, obteve o menor *Brier Score* (0,02), o que sugere um alinhamento entre as probabilidades estimadas e a frequência real de acertos. Seu ECE de 0,08 indica uma baixa discrepância entre a confiança prevista e o desempenho empírico, o que pode permitir interpretar as probabilidades fornecidas pelo modelo como estimativas da incerteza da predição.

O Gemma 3 12B IT apresentou o segundo melhor resultado de calibração, com um *Brier Score* de 0,04 e o menor ECE da tabela (0,04), o que aponta para uma consistência entre a confiança e a acurácia observada. Estes resultados reforçam as observações das métricas de classificação, consolidando o Phi-4 e o Gemma 3 como modelos robustos no conjunto avaliado.

Embora os modelos Llama 3.1 8B Instruct e DeepSeek R1 Distill Qwen 2.5 32B tenham alcançado os maiores valores de ROC-AUC (0,85 e 0,87, respectivamente) e PR-AUC (0,84 e 0,83), ambos apresentaram indicadores de calibração menos favoráveis, com *Brier Scores* superiores a 0,25 e ECE próximos de 0,30. Isso sugere que, apesar de distinguirem corretamente os exemplos, suas probabilidades estimadas podem não refletir a chance real de acerto, podendo produzir níveis de confiança excessivamente otimistas ou pessimistas. Por outro lado, os modelos Phi-4, Gemma 3 e Falcon 3 demonstraram valores mais modestos de ROC-AUC,

mas com *Brier Score* e ECE substancialmente menores. Em aplicações de verificação automática de fatos, onde a confiabilidade da decisão é relevante, as métricas de calibração podem ser úteis para interpretar a confiança do modelo na tomada de decisão ou no encaminhamento para revisão humana.

5.5.5 Avaliação Qualitativa das Justificativas

A Tabela 8 apresenta os resultados da avaliação qualitativa das justificativas geradas pelos modelos em suas melhores configurações de *prompting*. As métricas analisadas foram factualidade e relevância, calculadas por meio de similaridade semântica baseada em *embeddings* do modelo *multilingual-e5-large* (Wang et al., 2024b).

Tabela 8 – Métricas qualitativas por modelo na melhor estratégia de *prompting*.

Modelo	Melhor Estratégia	Factualidade	Relevância
Phi 4	cot-in	0.91	0.94
Gemma 3 12B IT	cot-in	0.91	0.94
Falcon 3 10B Instruct	cot-in	0.91	0.95
Qwen 2.5 14B Instruct	cot-in	0.91	0.95
Mistral 7B Instruct	few-shot-in	0.92	0.94
Llama 3.1 8B Instruct	cot-in	0.91	0.95
DeepSeek R1 Distill Qwen 2.5 32B	cot-in	0.91	0.95

Fonte: Autoria própria (2026).

A Tabela 8 sintetiza as métricas qualitativas por modelo. Observa-se que a estratégia *cot-ex* produziu os maiores índices de factualidade na maioria dos modelos, o que pode indicar que o raciocínio encadeado, combinado com fontes externas, aumenta o alinhamento das justificativas com as evidências disponíveis. Os resultados mostram baixa variabilidade entre os modelos avaliados. Os valores de factualidade variaram entre 0,91 e 0,92, enquanto a relevância se manteve entre 0,94 e 0,95 para todos os modelos. O Mistral 7B Instruct, utilizando a estratégia *few-shot-in*, apresentou o maior índice de factualidade de 0,92, o que pode indicar um alinhamento semântico entre suas justificativas e as evidências disponíveis. Em relação à relevância, os modelos Falcon 3 10B Instruct, Qwen 2.5 14B Instruct, Llama 3.1 8B Instruct e DeepSeek R1 Distill Qwen 2.5 32B obtiveram o valor máximo de 0,95, sugerindo aderência às instruções da tarefa. A reduzida dispersão dos resultados sugere que as justificativas produzidas mantiveram um grau de alinhamento tanto com as evidências recuperadas quanto com as instruções fornecidas, independentemente do modelo. Este comportamento pode ser atribuído à estruturação do *prompt*, que impõe um formato padronizado de raciocínio e exige a utilização explícita das fontes recuperadas na construção da resposta.

5.5.6 Avaliação com RAGAS

A avaliação com RAGAS, conduzida utilizando o modelo *Gemma3:12b* via Ollama como *LLM* avaliador e apresentada na Tabela 9, fornece uma avaliação complementar às métricas qualitativas. Esta avaliação quantifica o grau de alinhamento entre as justificativas geradas pelos modelos e as evidências disponíveis para cada instância. Especificamente, a métrica *faithfulness* verifica a consistência dos argumentos apresentados na resposta com as fontes de referência, enquanto a métrica *answer relevancy* avalia o foco da justificativa na tarefa de classificação da notícia.

Tabela 9 – Métricas RAGAS por modelo na melhor estratégia de *prompting*.

Modelo	Melhor Estratégia	<i>Faithfulness</i>	<i>Answer Relevancy</i>
Phi 4	cot-in	0.75	0.77
Gemma 3 12B IT	cot-in	0.72	0.74
Falcon 3 10B Instruct	cot-in	0.76	0.65
Qwen 2.5 14B Instruct	cot-in	0.75	0.69
Mistral 7B Instruct	few-shot-in	0.62	0.71
Llama 3.1 8B Instruct	cot-in	0.68	0.69
DeepSeek R1 Distill Qwen 2.5 32B	cot-in	0.70	0.77

Fonte: Autoria própria (2026).

O modelo Falcon 3 10B Instruct alcançou o maior índice de *faithfulness*, com 0,76, seguido por Phi-4 e Qwen 2.5 14B Instruct, ambos com 0,75. Estes resultados sugerem que as justificativas geradas por esses modelos demonstram um alinhamento semântico com as evidências de referência, minimizando a incidência de afirmações não corroboradas pelo contexto disponível. No que concerne à métrica *answer relevancy*, os melhores desempenhos foram observados no Phi-4 e no DeepSeek R1 Distill Qwen 2.5 32B, ambos com um valor de 0,77. Este resultado indica que as respostas destes modelos mantiveram um foco acentuado na tarefa de verificação factual, com menor ocorrência de informações periféricas ou divagações argumentativas.

Um ponto notável é que o Phi-4 foi o único modelo a exibir simultaneamente elevados índices de *faithfulness* (0,75) e *answer relevancy* (0,77), o que corrobora os resultados observados nas métricas quantitativas e probabilísticas. Embora o Falcon 3 tenha atingido o maior valor de *faithfulness*, sua relevância de 0,65 foi consideravelmente inferior, sugerindo que justificativas semanticamente alinhadas às evidências não necessariamente demonstram o maior foco na decisão de classificação. Analogamente, o DeepSeek apresentou alta relevância, mas um desempenho geral inferior nas métricas de classificação previamente abordadas.

Em uma análise conjunta dos resultados quantitativos, probabilísticos e qualitativos, o Phi-4 demonstrou o comportamento mais equilibrado em termos de capacidade preditiva, calibração probabilística e qualidade argumentativa das justificativas. O Gemma 3 12B IT, por sua vez, emergiu como a segunda melhor alternativa, exibindo desempenho consistente em todas as dimensões avaliadas.

A Figura 7 ilustra a comparação das métricas de *faithfulness* e *answer relevancy* para todas as estratégias de *prompting* avaliadas. Os resultados demonstram um padrão consistente: as estratégias que incorporam recuperação de contexto externo (*-ex) geraram valores substancialmente superiores em comparação com as estratégias baseadas exclusivamente no conhecimento interno do modelo (*-in). Em média, a métrica de *faithfulness* elevou-se de aproximadamente 0,66 nos cenários internos para cerca de 0,79 nos cenários externos, enquanto a *answer relevancy* incrementou-se de aproximadamente 0,71 para 0,78. Este ganho foi particularmente notório nas estratégias *cot-ex*, que atingiram os índices mais elevados de fidelidade ao contexto em praticamente todos os modelos, com valores entre 0,81 e 0,84 para *faithfulness* e entre 0,73 e 0,83 para *answer relevancy*.




Figura 7 – Comparação de *faithfulness* e *answer relevancy* (RAGAS) por modelo nas estratégias de *prompting*.

Fonte: Autoria própria (2026).

Estes resultados indicam que a recuperação de evidências externas aprimora significativamente a aderência das justificativas ao contexto de referência e preserva o foco das respostas na tarefa de verificação factual. No entanto, esta melhoria nas métricas RAGAS não implica necessariamente um desempenho de classificação superior, visto que as estratégias internas, em especial a *cot-in*, apresentaram os resultados quantitativos globais mais favoráveis.

5.6 Resultados sobre o *Dataset* Completo

Com base nos resultados obtidos na fase de testes controlados, o modelo **Phi-4**, associado à estratégia ***cot-in***, foi selecionado para avaliação no corpus *FakeTrue.Br*, composto por 3.582 notícias. O objetivo desta etapa consistiu em verificar se o desempenho observado na amostra inicial de 100 instâncias se mantém diante da maior diversidade temática, lexical e estrutural do conjunto completo. A Tabela 10 apresenta os dados detalhados desta configuração, que obteve o melhor desempenho geral durante a fase experimental.

Tabela 10 – Desempenho do modelo Phi-4 com a estratégia *cot-in* sobre o *dataset* completo do *FakeTrue.Br*

Acurácia	Precisão	Recall	F1-score	Kappa	MCC	Brier Score	ECE	Abstenção (%)
0.78	0.96	0.95	0.95	0.63	0.67	0.04	0.06	18,4

Fonte: Autoria própria (2026).

Os resultados indicam a estabilidade do modelo em cenários de maior escala. Considerando as 3.582 instâncias avaliadas, o Phi-4 alcançou acurácia global de 77,97%, atingindo 95,55% de acurácia nos casos em que produziu uma classificação definitiva. O *F1-score macro* de 95,45% evidencia o equilíbrio entre as classes *REAL* e *FAKE*, mesmo com o aumento significativo na dimensão do experimento. A análise de cobertura aponta que o modelo classificou aproximadamente 81,6% das notícias, abstendo-se em 18,4% dos casos (659 notícias). Este comportamento é coerente com a utilização da classe *INDETERMINADO* como mecanismo explícito de controle de incerteza. Em tarefas de verificação de fatos, tal funcionalidade é relevante para mitigar o risco de classificações incorretas em situações ambíguas ou insuficientemente fundamentadas por evidências.

As métricas de concordância permaneceram elevadas no conjunto completo, com Kappa de 0,628 e MCC de 0,666, o que sugere uma concordância substancial com os rótulos de referência. Observou-se ainda um desempenho equilibrado entre as classes, com *recall* de 98,42% para notícias reais e 91,87% para notícias falsas, indicando baixa propensão a vieses para categorias específicas. Sob a perspectiva probabilística, o modelo manteve a calibração das estimativas de confiança, com *Brier Score* de 0,041 e ECE de 0,063. Esses valores indicam que as probabilidades atribuídas às predições estão alinhadas à frequência de acertos observada, característica importante para sistemas de apoio à tomada de decisão.

Em suma, a avaliação no corpus completo corrobora a capacidade de generalização do Phi-4 com a estratégia *cot-in*, fundamentando sua integração ao protótipo *Aletheia*. Embora ocorra uma redução esperada na acurácia global em relação aos testes controlados, decorrente da maior heterogeneidade do conjunto de dados, o modelo preserva níveis elevados de precisão, equilíbrio e confiabilidade, demonstrando viabilidade para a detecção de desinformação em língua portuguesa

5.7 Análise de Generalização: Notícias Fora da Distribuição

A fim de avaliar a capacidade de generalização do sistema proposto em cenários de uso prático, realizou-se uma análise complementar com informações de fora do período de abrangência do corpus *FakeTrue.Br*. O objetivo foi verificar se os modelos selecionados manteriam um desempenho satisfatório diante de conteúdos inéditos, não incluídos na fase de testes controlados. Para essa avaliação, selecionaram-se notícias de diversas áreas temáticas, como política, saúde e conhecimentos gerais. O conjunto incluiu tanto conteúdos verdadeiros de veículos jornalísticos reconhecidos quanto conteúdos classificados como falsos por agências de *fact-checking*. Esta seleção manteve o equilíbrio entre as classes, simulando condições mais próximas das encontradas em aplicações reais.

Para demonstrar a viabilidade prática da proposta, desenvolveu-se um protótipo funcional do sistema em duas plataformas de troca de informações amplamente utilizadas no Brasil: Telegram e WhatsApp. Os protótipos foram implementados com um fluxo conversacional estruturado, mensagens orientativas e comandos específicos para submissão e análise de notícias. A Figura 8 exibe a interface do *bot* para o Telegram, e a Figura 9 ilustra a versão para o WhatsApp.




Figura 8 – Protótipo do *Bot* no Telegram.

Fonte: Autoria própria (2026).

Os resultados desta etapa, apresentados na Figura 10, indicam que o modelo Phi-4 manteve um desempenho consistente, mesmo diante de notícias ausentes do conjunto experimental original, classificando corretamente as instâncias avaliadas. Esse resultado sugere que os padrões aprendidos na validação não se restringiram às características específicas do corpus *FakeTrue.Br*, demonstrando a capacidade de adaptação a novos contextos informacionais.

Observou-se que, para eventos recentes e temas emergentes, as fontes externas recuperadas pelo mecanismo de busca tiveram maior relevância na decisão final, diminuindo a dependência exclusiva do conhecimento paramétrico dos modelos. Este comportamento é re-




Figura 9 – Protótipo do Bot no WhatsApp.

Fonte: Autoria própria (2026).

levante em tarefas de verificação de fatos, onde a atualização constante das informações é um requisito fundamental. Embora esta avaliação seja exploratória e não tenha sido conduzida sobre um conjunto formalmente anotado, os resultados obtidos fornecem evidências preliminares de que a arquitetura proposta tem potencial para aplicação em cenários reais de monitoramento e verificação de notícias. A integração entre *LLMs*, recuperação de conhecimento externo e geração de justificativas explicáveis demonstrou a capacidade de produzir respostas consistentes, mesmo com conteúdos inéditos e temporalmente distantes do corpus experimental.

5.8 Discussão Geral

Os resultados apresentados neste capítulo permitem extrair três conclusões centrais sobre o uso de *LLMs* abertos para detecção de *fake news* em português. Em primeiro lugar, constatou-se que a estrutura de raciocínio fornecida ao modelo exerce um impacto mais consistente sobre o desempenho do que a mera disponibilização de conhecimento externo. As estratégias baseadas em *Chain-of-Thought* apresentaram os melhores resultados para a maioria dos modelos avaliados, com especial destaque para a configuração *cot-in*, empregada pelos seis modelos de melhor desempenho individual. Este resultado sugere que, para tarefas de ve-




Figura 10 – Respostas dos bots para notícias de fora da distribuição.

Fonte: Autoria própria (2026).

ificação jornalística, a capacidade de organizar explicitamente o processo de decisão pode ser tão ou mais importante do que a quantidade de informação disponibilizada ao modelo.

Em segundo lugar, a recuperação de conhecimento externo produziu um efeito distinto sobre diferentes dimensões da avaliação. Embora as estratégias com RAG tenham alcançado os maiores valores nas métricas do *framework RAGAS*, particularmente *faithfulness* e *answer*

relevancy, esse ganho qualitativo não se traduziu necessariamente em melhores métricas de classificação. A análise das respostas revelou que parte dessa discrepância decorre da interação entre o contexto recuperado e a formulação original do *system_message*. Dado que o corpus *FakeTrue.Br* contém tanto notícias factuais quanto verificações jornalísticas de boatos, o modelo passou a interpretar incorretamente determinadas notícias falsas como verdadeiras quando as fontes externas recuperadas continham textos de agências de *fact-checking* desmentindo a alegação. Este comportamento evidenciou uma ambiguidade na definição da tarefa que pode ser corrigida mediante a introdução de um critério de localização do desmentido no *prompt*.

Em terceiro lugar, os resultados demonstram que a avaliação de sistemas baseados em *LLMs* deve considerar simultaneamente o desempenho classificatório, a cobertura, a calibração probabilística e a qualidade das justificativas. Modelos como Phi-4 e Gemma 3 não apenas exibiram elevados valores de acurácia e *F1-score*, mas também melhores índices de calibração, menores valores de *Brier Score* e justificativas semanticamente alinhadas ao contexto fornecido. Este resultado reforça a importância de métricas complementares para a avaliação de sistemas explicáveis, uma vez que altas taxas de acerto isoladamente não garantem confiabilidade operacional.

Finalmente, os desafios técnicos documentados na Seção 5.3, incluindo limitações de memória, comportamento multilíngue indesejado em alguns modelos, variabilidade na qualidade do contexto recuperado e sensibilidade às instruções do sistema, evidenciam que a construção de *pipelines* experimentais baseados em *LLMs* locais exige cuidados metodológicos e de engenharia que influenciam diretamente a validade dos resultados. Nesse sentido, as soluções desenvolvidas no âmbito do *Aletheia* constituem contribuições que transcendem o domínio da detecção de *fake news*, podendo ser reaproveitadas em outros cenários de NLP e sistemas de IA explicável para a língua portuguesa.

6 CONSIDERAÇÕES FINAIS

O presente estudo descreveu a concepção, implementação e avaliação do *Aletheia*, um sistema para a detecção de *fake news* em português brasileiro. A aplicação integra LLMs, técnicas de *reasoning*, recuperação de conhecimento externo. A pesquisa foi motivada pelo crescente impacto da desinformação digital na opinião pública, nos processos democráticos e na tomada de decisão dos cidadãos, especialmente no contexto brasileiro. A arquitetura desenvolvida integrou sete LLMs de código aberto, executados localmente, seis estratégias distintas de *prompting*, mecanismos de recuperação de contexto factual via RAG e um conjunto de métricas quantitativas, qualitativas e probabilísticas. O sistema resultante é capaz de classificar notícias como reais ou falsas, além de fornecer justificativas interpretáveis, evidências de suporte e estimativas explícitas de confiança. Adicionalmente, foi desenvolvido um protótipo funcional integrado às plataformas Telegram e WhatsApp, demonstrando a viabilidade de disponibilizar ferramentas de verificação assistida diretamente nos canais digitais utilizados pela população brasileira.

6.1 Síntese dos Resultados e Objetivos da Pesquisa

1. Qual é a eficácia e o potencial dos principais LLMs na classificação de notícias falsas?

Os experimentos demonstraram que modelos abertos de linguagem possuem potencial para a tarefa de detecção de notícias falsas quando combinados com estratégias adequadas de instrução. Entre os sete modelos avaliados, o **Phi-4** (Microsoft, 2024), utilizando a estratégia **cot-in**, apresentou o melhor desempenho global, atingindo 85% de acurácia geral, 97,7% de acurácia entre os casos classificados, um *F1-score macro* de 97,7%, *Kappa* de 0,735 e *MCC* de 0,756. Esses resultados indicam capacidade de generalização e concordância com as classificações de referência.

O segundo melhor desempenho foi obtido pelo **Gemma 3 12B IT** (Google, 2024), também com a estratégia **cot-in**, alcançando 83% de acurácia geral, *F1-score macro* de 96,5%, *Kappa* de 0,702 e equilíbrio entre as classes *REAL* e *FAKE*. Os resultados sugerem que modelos abertos de porte intermediário podem atingir níveis de desempenho comparáveis aos observados em sistemas proprietários na literatura.

2. O uso de *reasoning* pode aprimorar a explicabilidade dos resultados obtidos pelos modelos de IA?

Os resultados indicam que estratégias baseadas em *Chain-of-Thought* (CoT) contribuíram para a qualidade das justificativas produzidas. As configurações **cot-in** foram responsáveis pelos melhores desempenhos em seis dos sete modelos avaliados, sugerindo que o raciocínio explícito auxilia os modelos a organizar as evidências e a produzir justificativas mais coerentes e auditáveis (Rudin, 2019). As métricas qualita-

tivas de factualidade e relevância apresentaram valores elevados para os modelos de melhor desempenho, enquanto as análises probabilísticas demonstraram que modelos como Phi-4 e Gemma 3 produziram estimativas de confiança mais bem calibradas. O Phi-4 obteve o menor *Brier Score* (0,024), indicando correspondência entre a confiança declarada e a taxa real de acerto.

3. Como os modelos propostos se comparam a métodos tradicionais de verificação de fatos?

Os resultados demonstraram que os *LLMs* avaliados são capazes de reproduzir parte do processo de verificação normalmente realizado por checadores humanos, mas com maior velocidade e escalabilidade. Contudo, a pesquisa revelou que a qualidade do raciocínio produzido depende da formulação das instruções fornecidas ao modelo. Uma ambiguidade estrutural foi identificada na *system_message* utilizada inicialmente. Dado que o conjunto *FakeTrue.Br* (Chavarro et al., 2023) contém notícias factuais e conteúdos de *fact-checking*, a recuperação de documentos externos de agências verificadoras induzia alguns modelos a interpretar incorretamente determinadas notícias falsas como verdadeiras. Esse comportamento afetou principalmente as estratégias com conhecimento externo, reduzindo o desempenho classificatório, apesar dos ganhos observados em métricas de ancoragem factual. A análise detalhada desse fenômeno permitiu propor uma reformulação das instruções do sistema, baseada em um critério explícito de localização do desmentido. Esta é uma contribuição metodológica que pode ser útil para futuras pesquisas envolvendo RAG aplicado à verificação automática de fatos.

6.2 Contribuições do Trabalho

As principais contribuições deste estudo para a Engenharia da Computação e para a sociedade podem ser delineadas nos seguintes pontos:

- **Desenvolvimento do Sistema *Aletheia*:** Foi desenvolvido um sistema modular e transparente para a detecção de *fake news* em português brasileiro. Este sistema foi adaptado às especificidades linguísticas e socioculturais do Brasil e disponibilizado como um protótipo funcional na forma de um *bot* para as plataformas Telegram e WhatsApp.
- **Avaliação empírica de *LLMs* em português brasileiro:** Realizou-se uma avaliação sistemática de sete modelos de linguagem de grande porte de código aberto, empregando seis estratégias de *prompting* distintas. Esta avaliação utilizou métricas quantitativas, probabilísticas e qualitativas, estabelecendo um protocolo experimental replicável para futuras investigações na área de desinformação em língua portuguesa.

- **Validação da XAI em verificação factual:** Foram obtidas evidências empíricas de que o raciocínio estruturado (CoT) e a incorporação de conhecimento externo (RAG) influenciam diretamente a confiabilidade e a interpretabilidade de *LLMs* na tarefa de checagem de fatos. Este achado contribui para o avanço da explicabilidade em sistemas de NLP aplicados, alinhando-se aos princípios de transparência e confiabilidade destacados na literatura ([Hassija vinay chamola, 2024](#); [Saeed; Omlin, 2023](#)).
- **Reconhecimento científico:** Os resultados preliminares deste trabalho foram submetidos, aprovados e apresentados no **25º Congresso Nacional de Iniciação Científica (CONIC SEMESP) de 2025**.

6.3 Limitações e Trabalhos Futuros

Apesar dos avanços alcançados, o projeto *Aletheia* apresenta limitações inerentes ao seu escopo e à tecnologia utilizada, as quais indicam direções para futuras pesquisas.

6.3.1 Limitações

- **Custo computacional:** A dependência de *LLMs*, particularmente de modelos como *DeepSeek R1 Distill Qwen 32B* e *Qwen 2.5 14B* na fase experimental, acarreta um custo de inferência elevado. Tal fato limita a escalabilidade imediata do sistema para ambientes em tempo real que lidam com alto volume de requisições.
- **Escopo do conjunto de dados:** Os experimentos foram conduzidos sobre o conjunto de dados balanceado *FakeTrue.Br*. Embora esta escolha favoreça o controle experimental e a viabilidade computacional, ela restringe a generalização dos resultados a outros domínios, períodos temporais e estilos jornalísticos.
- **Latência na recuperação externa:** O mecanismo de contextualização via RAG envolve buscas em múltiplas fontes externas durante a execução. Esta característica introduz uma latência operacional que pode ser incompatível com aplicações de verificação em tempo real para usuários finais.
- **Escopo unimodal:** A abordagem atual está restrita à análise textual, não abrangendo a vertente multimodal da desinformação contemporânea. Esta lacuna inclui imagens manipuladas, vídeos sintéticos (*deepfakes*) e conteúdo de áudio, representando um desafio crescente diante da proliferação de conteúdos gerados por IA generativa ([Sun et al., 2024](#)).

6.3.2 Trabalhos Futuros

Como continuação desta pesquisa, propõem-se as seguintes direções para estudos futuros:

- **Leitura automática de *links*:** O sistema já dispõe de um módulo para extração de conteúdo de páginas *web*, que pode ser reestruturado para identificar URLs em mensagens de usuário. Isso possibilitaria a extração automática do conteúdo referenciado na URL para análise, eliminando a inserção manual pelo usuário. Esta funcionalidade pode aprimorar a usabilidade e a eficiência do processo de verificação em plataformas de mensagens, como Telegram e WhatsApp.
- **Implementação e avaliação do *ensemble*:** Uma arquitetura de *ensemble* foi desenvolvida em nível de código, concebida para integrar o *Aletheia*. Contudo, sua validação experimental não pôde ser concluída dentro do prazo deste trabalho. Sugere-se, portanto, a implementação e avaliação desta proposta de *ensemble* em um contexto prático. A arquitetura combina múltiplos *LLMs* por votação ponderada com base no desempenho individual, raciocínio distribuído das justificativas e diversidade arquitetural, visando mitigar vieses de predição e melhorar a confiabilidade global (Tan; Gilbert, 2003).
- **Ampliação das métricas qualitativas:** Sugere-se o exame de métricas adicionais de explicabilidade, como *context precision* e *context recall* do *framework RAGAS*, além de métodos de detecção de alucinação baseados em verificação externa (*SelfCheckGPT*) (Manakul; Liusie; Gales, 2023). O objetivo é criar uma avaliação qualitativa ainda mais abrangente.
- **Avaliação em múltiplos *datasets*:** Recomenda-se expandir os experimentos para outros corpora mencionados na Seção 4.1, incluindo o *Fake.br Corpus* (Monteiro et al., 2018; Silva et al., 2020b), o *FakeRecognia* (Garcia; Afonso; Papa, 2022) e o *FakeWhatsApp.Br* (Cunha, 2021). Isso permitiria avaliar a generalização dos modelos e das estratégias de *prompting* em diferentes domínios, estilos discursivos e fontes de desinformação.
- **Expansão multimodal:** Propõe-se integrar modelos de visão e linguagem (LVLMs) para a detecção de desinformação em conteúdo multimodal, abrangendo imagens, vídeos e áudios manipulados, alinhando-se aos desafios emergentes identificados na literatura (Sun et al., 2024; Chen; Shu, 2024).
- **Avaliação e aplicação de *SLMs*:** Sugere-se explorar Modelos de Linguagem Pequena (SLMs), como variantes destiladas dos modelos avaliados. O propósito é reduzir o custo de inferência e viabilizar a implantação em dispositivos com recursos computaci-

onais limitados, expandindo o alcance do sistema sem comprometer significativamente o desempenho preditivo (Jiang *et al.*, 2023a).

- **Integração com modelos via API:** Recomenda-se avaliar *LLMs* proprietários acessíveis via APIs externas, como GPT-4o (Hurst *et al.*, 2024), Gemini-2.5 (Comanici *et al.*, 2025) e Claude-Opus-4.7 (Anthropic, 2024; Bai, 2022), em comparação direta com os modelos locais avaliados neste estudo. Esta abordagem visa quantificar os ganhos de desempenho, custo operacional e privacidade de dados, em continuidade à linha de investigação de (Gôlo *et al.*, 2024).

Finalmente, *Aletheia* representa um avanço em direção a sistemas de verificação de fatos que são, simultaneamente, precisos, explicáveis e acessíveis à população brasileira. Os resultados obtidos indicam que *LLMs* de código aberto, quando apropriadamente guiados por estratégias de *prompting* e enriquecidos com recuperação de conhecimento externo, são capazes de realizar classificações confiáveis e justificadas de notícias em português, sem a dependência de modelos proprietários ou de grandes volumes de dados rotulados. A transparência das decisões e a acessibilidade do protótipo em aplicativos de mensagens reforçam o potencial de impacto social desta pesquisa no combate à desinformação no Brasil, contribuindo tanto para o avanço do conhecimento acadêmico quanto para o desenvolvimento de soluções práticas aplicáveis por jornalistas, pesquisadores e o público em geral.

REFERÊNCIAS

- ABDALI, S.; SHAHAM, S.; KRISHNAMACHARI, B. Multi-modal misinformation detection: Approaches, challenges and opportunities, . Association for Computing Machinery New York, NY, USA v. 57, n. 3,, nov. 2024. ISSN 0360-0300. Disponível em: <https://doi.org/10.1145/3697349>.
- ACHIAM, J. *et al.* Gpt-4 technical report. **arXiv preprint arXiv:2303.08774**, ,, 2023.
- AHMAD, T. *et al.* Explainable ai: Interpreting deep learning models for decision support. **Advances in Deep Learning Techniques**, v. 4, n. 1, p. 80–108, 2024.
- AI, M. **Introducing LLaMA: A foundational, 65-billion-parameter language model**, . 2023. Publicado no blog da Meta AI. Acessado em 26 de abril de 2025. Disponível em: <https://ai.meta.com/blog/large-language-model-llama-meta-ai/>.
- AI, S. **Navigating the LLM Landscape: A Comparative Analysis of Leading Large Language Models**, . 2025. Publicado no site da Sapling AI. Acessado em 26 de abril de 2025. Disponível em: <https://sapling.ai/llm/index>.
- AJAO, O.; BHOWMIK, D.; ZARGARI, S. Sentiment aware fake news detection on online social networks. *In*: IEEE. ICASSP 2019-2019 IEEE INTERNATIONAL CONFERENCE ON ACOUSTICS, SPEECH AND SIGNAL PROCESSING (ICASSP). 2019. **Anais [...]** [S.l.], 2019. p. 2507–2511.
- ALDWAIRI, M.; ALWAHEDI, A. Detecting fake news in social media networks. **Procedia Computer Science**, v. 141,, p. 215–222, 2018. ISSN 1877-0509. The 9th International Conference on Emerging Ubiquitous Systems and Pervasive Networks (EUSPN-2018) / The 8th International Conference on Current and Future Trends of Information and Communication Technologies in Healthcare (ICTH-2018) / Affiliated Workshops. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1877050918318210>.
- ALESAWI, B.; AL-TAI, M. H. Detecting arabic misinformation using an attention mechanism-based model. **Iraqi Journal For Computer Science and Mathematics**, v. 5, n. 1, p. 285–298, 2024.
- ALGHAMDI, J.; LUO, S.; LIN, Y. A comprehensive survey on machine learning approaches for fake news detection. **Multimedia Tools and Applications**, Springer v. 83,, p. 51009–51067, 2024. Disponível em: <https://doi.org/10.1007/s11042-023-17470-8>.
- ALLCOTT, H.; GENTZKOW, M. Social media and fake news in the 2016 election. **Journal of Economic Perspectives**, v. 31, n. 2, p. 211–236, May 2017. Disponível em: <https://www.aeaweb.org/articles?id=10.1257/jep.31.2.211>.
- ALVAREZ, J. M. *et al.* Policy advice and best practices on bias and fairness in ai. **Ethics and Information Technology**, v. 26,, p. 31, 2024. Disponível em: <https://doi.org/10.1007/s10676-024-09746-w>.
- ALYOUBI, S.; KALKATAWI, M.; ABUKHODAIR, F. The detection of fake news in arabic tweets using deep learning. **Applied Sciences**, v. 13, n. 14,, 2023. ISSN 2076-3417. Disponível em: <https://www.mdpi.com/2076-3417/13/14/8209>.
- Anthropic. **Claude: documentação oficial da API**, . 2024. Documentação online. Disponível em: <https://platform.claude.com/docs/>.
- ANTOUN, W.; BALY, F.; HAJJ, H. **AraBERT: Transformer-based Model for Arabic Language Understanding**, . 2021. Disponível em: <https://arxiv.org/abs/2003.00104>.

- ARGYLE, L. P. *et al.* Out of one, many: Using language models to simulate human samples. **Political Analysis**, Cambridge University Press v. 31, n. 3, p. 337–351, 2023.
- ASAI, A. *et al.* **Self-rag: Learning to retrieve, generate, and critique through self-reflection**, . 2023.
- ASLAN, L.; PTASZYNSKI, M.; JAUHIAINEN, J. Are strong baselines enough? false news detection with machine learning. **Future Internet**, v. 16, n. 322,, 2024.
- AÏMEUR, S. A. E.; BRASSARD, G. Fake news, disinformation and misinformation in social media: a review. **Social Network Analysis and Mining**, v. 13,, p. 30, 2023. ISSN 1869-5469. Disponível em: <https://doi.org/10.1007/s13278-023-01028-5>.
- BAI, Y. e. a. Constitutional ai: harmlessness from ai feedback. **arXiv preprint arXiv:2212.08073**, ,, 2022. Disponível em: <https://arxiv.org/abs/2212.08073>.
- BANH, L.; STROBEL, G. Generative artificial intelligence. **Electronic Markets**, v. 33, n. 1, p. 63, 2023. Disponível em: <https://doi.org/10.1007/s12525-023-00680-1>.
- BANKO, M.; BRILL, E. Scaling to very very large corpora for natural language disambiguation. *In*: PROCEEDINGS OF THE 39TH ANNUAL MEETING OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS. 2001, Toulouse, France. **Anais [...]** Toulouse, France: Association for Computational Linguistics, 2001. p. 26–33. Disponível em: <https://aclanthology.org/P01-1005/>.
- BAYER, J. *et al.* European Parliament, LIBE Committee, Policy Department for Citizens' Rights and Constitutional Affairs **Disinformation and Propaganda – Impact on the Functioning of the Rule of Law in the EU and its Member States**. [S.l.], 2019. Disponível em: <https://ssrn.com/abstract=3409279>.
- BEISECKER, C. S. S.; HEIN, S. Shades of fake news: how fallacies influence consumers' perception. **European Journal of Information Systems**, v. 33, n. 1, p. 41–60, 2022. Disponível em: <https://doi.org/10.1080/0960085X.2022.2110000>.
- BENGTSSON, S.; JOHANSSON, S. A phenomenology of news: Understanding news in digital culture. **Journalism**, v. 22, n. 11, p. 2873–2889, 2021. Disponível em: <https://doi.org/10.1177/1464884919901194>.
- BHUYAN, B. P. *et al.* Neuro-symbolic artificial intelligence: a survey. **Neural Computing and Applications**, v. 36,, p. 12809–12844, 2024. Disponível em: <https://doi.org/10.1007/s00521-024-09960-z>.
- BOBEK, S.; NALEPA, G. J. Introducing uncertainty into explainable ai methods. *In*: PASZYNSKI, M. *et al.* (Ed.). COMPUTATIONAL SCIENCE – ICCS 2021. 2021, Cham. **Anais [...]** Cham: Springer International Publishing, 2021. p. 444–457. ISBN 978-3-030-77980-1.
- BODNAR, T. *et al.* Increasing the veracity of event detection on social media networks through user trust modeling. *In*: 2014 IEEE INTERNATIONAL CONFERENCE ON BIG DATA (BIG DATA). 2014. **Anais [...]** [S.l.: s.n.], 2014. p. 636–643.
- BOISSONNEAULT, D.; HENSEN, E. Fake news detection with large language models on the liar dataset, ,, 2024.
- BOMMASANI, R. *et al.* **On the Opportunities and Risks of Foundation Models**, . 2022. Disponível em: <https://arxiv.org/abs/2108.07258>.
- BORGEAUD, S. *et al.* Improving language models by retrieving from trillions of tokens. *In*: PMLR. INTERNATIONAL CONFERENCE ON MACHINE LEARNING. 2022. **Anais [...]** [S.l.], 2022. p. 2206–2240.

BRODA, E.; STRÖMBÄCK, J. Misinformation, disinformation, and fake news: Lessons from an interdisciplinary, systematic literature review. **Annals of the International Communication Association**, v. 48, n. 2, p. 139–166, June 2024. Disponível em: <https://doi.org/10.1080/23808985.2024.2323736>.

BROWN, T. B. *et al.* **Language Models are Few-Shot Learners**, . 2020. Disponível em: <https://arxiv.org/abs/2005.14165>.

BUCHHOLZ, M. G. **Assessing the Effectiveness of GPT-3 in Detecting False Political Statements: A Case Study on the LIAR Dataset**, . 2023. Disponível em: <https://arxiv.org/abs/2306.08190>.

BUNTAIN, C.; GOLBECK, J. **Automatically identifying fake news in popular twitter threads**, . 2017. 208–215 p.

CAGE, J.; HERVE, N.; MAZOYER, B. Social media influence mainstream media: Evidence from two billion tweets. **SSRN Electronic Journal**, , July 2020. Disponível em: <https://ssrn.com/abstract=3663899>.

CAPUANO, N. *et al.* Content-based fake news detection with machine and deep learning: a systematic review. **Neurocomputing**, v. 530,, p. 91–103, 2023. ISSN 0925-2312. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0925231223001376>.

CARD, D. *et al.* The media frames corpus: Annotations of frames across issues. *In*: ZONG, C.; STRUBE, M. (Ed.). PROCEEDINGS OF THE 53RD ANNUAL MEETING OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS AND THE 7TH INTERNATIONAL JOINT CONFERENCE ON NATURAL LANGUAGE PROCESSING (VOLUME 2: SHORT PAPERS). 2015, Beijing, China. **Anais [...]** Beijing, China: Association for Computational Linguistics, 2015. p. 438–444. Disponível em: <https://aclanthology.org/P15-2072/>.

CARLSON, J. **Redis in action**. [S.l.]: Simon and Schuster, 2013.

CHARLES, A. C.; RUBACK, L.; OLIVEIRA, J. Fakepedia corpus: A flexible fake news corpus in portuguese. *In*: SPRINGER. INTERNATIONAL CONFERENCE ON COMPUTATIONAL PROCESSING OF THE PORTUGUESE LANGUAGE. 2022. **Anais [...]** [S.l.], 2022. p. 37–45.

CHAVARRO, J. *et al.* Faketruebr: Um corpus brasileiro de notícias falsas. *In*: ANAIS DA XVIII ESCOLA REGIONAL DE BANCO DE DADOS. 2023, Porto Alegre, RS, Brasil. **Anais [...]** Porto Alegre, RS, Brasil: SBC, 2023. p. 108–117. ISSN 2595-413X. Disponível em: <https://sol.sbc.org.br/index.php/erbd/article/view/24352>.

CHEN, C.; SHU, K. **Can LLM-Generated Misinformation Be Detected?**, . 2024. Disponível em: <https://arxiv.org/abs/2309.13788>.

CHEN, C. *et al.* **Combating Health Misinformation in Social Media: Characterization, Detection, Intervention, and Open Issues**, . 2022. Disponível em: <https://arxiv.org/abs/2211.05289>.

CHEN, J. *et al.* Complex claim verification with evidence retrieved in the wild. **arXiv preprint arXiv:2305.11859**, , 2023.

CHEN, Y. *et al.* Cross-modal ambiguity learning for multimodal fake news detection. *In*: PROCEEDINGS OF THE ACM WEB CONFERENCE 2022. 2022, New York, NY, USA. **Anais [...]** New York, NY, USA: Association for Computing Machinery, 2022. p. 2897–2905. ISBN 9781450390965. Disponível em: <https://doi.org/10.1145/3485447.3511968>.

CHEUNG, T.-H.; LAM, K.-M. **FactLLaMA: Optimizing Instruction-Following Language Models with External Knowledge for Automated Fact-Checking**, . 2023. Disponível em: <https://arxiv.org/abs/2309.00240>.

CHIANG, W.-L. *et al.* Vicuna: An open-source chatbot impressing gpt-4 with 90 **LMSYS Org**, v. 2, n. 3, p. 6, 2023. Accessed 14 April 2023. Disponível em: <https://vicuna.lmsys.org>.

CHICCO, D.; JURMAN, G. The advantages of the matthews correlation coefficient (mcc) over f1 score and accuracy in binary classification evaluation. **BMC genomics**, Springer v. 21, n. 1, p. 6, 2020.

COMANICI, G. *et al.* Gemini 2.5: Pushing the frontier with advanced reasoning, multimodality, long context, and next generation agentic capabilities. **arXiv preprint arXiv:2507.06261**, , 2025.

CORTES, C.; DESALVO, G.; MOHRI, M. Learning with rejection. *In*: SPRINGER. INTERNATIONAL CONFERENCE ON ALGORITHMIC LEARNING THEORY. 2016. **Anais [...]** [S.l.], 2016. p. 67–82.

CORTESE, J. F. N. B. *et al.* Should explainability be a fifth ethical principle in ai ethics? **AI and Ethics**, v. 3,, p. 123–134, 2023. ISSN 2730-5961. Disponível em: <https://doi.org/10.1007/s43681-022-00152-w>.

COUTO, J. M. *et al.* Central de fatos: Um repositório de checagens de fatos. *In*: SBC. DATASET SHOWCASE WORKSHOP (DSW). 2021. **Anais [...]** [S.l.], 2021. p. 128–137.

CUI, L.; LEE, D. Coaid: Covid-19 healthcare misinformation dataset. **arXiv preprint arXiv:2006.00885**, , 2020.

CUNHA, L. C. C. d. Fakewhatsapp. br: detecção de desinformação e desinformadores em grupos públicos do whatsapp em pt-br, ,. 2021.

DAI, E.; SUN, Y.; WANG, S. Ginger cannot cure cancer: Battling fake health news with a comprehensive data repository. *In*: PROCEEDINGS OF THE INTERNATIONAL AAAI CONFERENCE ON WEB AND SOCIAL MEDIA. 14., 2020. **Anais [...]** [S.l.: s.n.], 2020. p. 853–862.

DATABRICKS. **Free Dolly: Introducing the world's first open and commercially viable instruction-tuned LLM**, . 2023. Publicado no blog da Databricks. Acessado em 26 de abril de 2025. Disponível em: <https://www.databricks.com/blog/2023/04/12/dolly-first-open-commercially-viable-instruction-tuned-llm>.

DAVIS, J.; GOADRIC, M. The relationship between precision-recall and roc curves. *In*: PROCEEDINGS OF THE 23RD INTERNATIONAL CONFERENCE ON MACHINE LEARNING. 2006. **Anais [...]** [S.l.: s.n.], 2006. p. 233–240.

DeepSeek-AI. **DeepSeek-R1-Distill-Qwen-32B**, . 2025. Modelo de linguagem de grande porte destilado a partir do Qwen-32B, disponibilizado na plataforma Hugging Face. Disponível em: <https://huggingface.co/deepseek-ai/DeepSeek-R1-Distill-Qwen-32B>.

DEVLIN, J. *et al.* BERT: Pre-training of deep bidirectional transformers for language understanding. *In*: BURSTEIN, J.; DORAN, C.; SOLORIO, T. (Ed.). PROCEEDINGS OF THE 2019 CONFERENCE OF THE NORTH AMERICAN CHAPTER OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS: HUMAN LANGUAGE TECHNOLOGIES, VOLUME 1 (LONG AND SHORT PAPERS). 2019, Minneapolis, Minnesota. **Anais [...]** Minneapolis, Minnesota: Association for Computational Linguistics, 2019. p. 4171–4186. Disponível em: <https://aclanthology.org/N19-1423/>.

DHIMAN, B. **The Rise and Impact of Misinformation and Fake News on Digital Youth: A Critical Review**, . 2023.

DICK, P. K. **Quote: "A ferramenta básica para a manipulação da realidade..."**, . 1978. Citação atribuída a Philip K. Dick em 1978, frequentemente associada ao ensaio "How to Build a Universe That Doesn't Fall Apart Two Days Later".

DONADIO, R. **Why the Macron Hacking Attack Landed with a Thud in France**, . 2017. Publicado no The New York Times. Acessado em 26 de abril de 2025. Disponível em: <https://www.nytimes.com/2017/05/08/world/europe/macron-hacking-attack-france.html>.

DUARTE, F. **Number of ChatGPT users (November 2023)**, . 2023. Publicado no blog Exploding Topics. Acessado em 26 de abril de 2025. Disponível em: <https://explodingtopics.com/blog/chatgpt-users>.

DuckDuckGo. **DuckDuckGo API Documentation**, . 2024. Disponível em: <https://duckduckgo.com/api>.

ES, S. *et al.* Ragas: Automated evaluation of retrieval augmented generation. *In: PROCEEDINGS OF THE 18TH CONFERENCE OF THE EUROPEAN CHAPTER OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS: SYSTEM DEMONSTRATIONS*. 2024. **Anais [...]** [S.l.: s.n.], 2024. p. 150–158.

FAN, A. *et al.* Generating fact checking briefs. **arXiv preprint arXiv:2011.05448**, , 2020.

FARIS, R. *et al.* Partisanship, propaganda, and disinformation: Online media and the 2016 u.s. presidential election. **Berkman Klein Center Research Publication 2017-6**, , 08 2017. Disponível em: <https://ssrn.com/abstract=3019414>.

FENG, S. *et al.* Knowledge card: Filling llms' knowledge gaps with plug-in specialized language models. *In: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS*. 2023. **Anais [...]** [s.n.], 2023. Disponível em: <https://api.semanticscholar.org/CorpusID:258741298>.

FENG, S. Y. *et al.* **A Survey of Data Augmentation Approaches for NLP**, . 2021. Disponível em: <https://arxiv.org/abs/2105.03075>.

FLAMINO, J. *et al.* Political polarization of news media and influencers on twitter in the 2016 and 2020 us presidential elections. **Nature Human Behaviour**, v. 7, p. 904–916, 2023. Disponível em: <https://doi.org/10.1038/s41562-023-01550-8>.

FOTOPOULOS, S. Traditional media versus new media: Between trust and use. **European View**, v. 22, n. 2, p. 277–286, 2023. Disponível em: <https://doi.org/10.1177/17816858231204738>.

FOUAD, K. M.; SABBEH, S. F.; MEDHAT, W. Arabic fake news detection using deep learning. **Computers, Materials & Continua**, v. 71, n. 2, 2022.

FRANTAR, E. *et al.* **GPTQ: Accurate Post-Training Quantization for Generative Pre-trained Transformers**, . 2023. Disponível em: <https://arxiv.org/abs/2210.17323>.

FRIEDL, J. **Mastering regular expressions**. [S.l.]: "O'Reilly Media, Inc.", 2006.

FUNG, Y. *et al.* The battlefield of combating misinformation and coping with media bias. *In: ALONSO, M. A.; WEI, Z. (Ed.). PROCEEDINGS OF THE 2ND CONFERENCE OF THE ASIA-PACIFIC CHAPTER OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS AND THE 12TH INTERNATIONAL JOINT CONFERENCE ON NATURAL LANGUAGE PROCESSING: TUTORIAL ABSTRACTS*. 2022, Taipei. **Anais [...]** Taipei: Association for Computational Linguistics, 2022. p. 28–34. Disponível em: <https://aclanthology.org/2022.acl-tutorials.5/>.

GALHARDO, R. **Uso das fake news nas eleições do Brasil é “sem precedentes”, diz chefe da missão da OEA**, . 2018. Disponível em: <https://politica.estadao.com.br/noticias/eleicoes,uso-de-fake-news-nas-eleicoes-do-brasil-e-sem-precedentes-diz-chefe-de-missao-da-oea,70002563620>.

GARCIA, G. L.; AFONSO, L. C.; PAPA, J. P. Fakerecogna: A new brazilian corpus for fake news detection. *In*: SPRINGER. INTERNATIONAL CONFERENCE ON COMPUTATIONAL PROCESSING OF THE PORTUGUESE LANGUAGE. 2022. **Anais [...]** [S.l.], 2022. p. 57–67.

GEIFMAN, Y.; EL-YANIV, R. Selective classification for deep neural networks. **Advances in neural information processing systems**, v. 30,, 2017.

GIRDHAR, R. *et al.* Imagebind: One embedding space to bind them all. *In*: PROCEEDINGS OF THE IEEE/CVF CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR). 2023. **Anais [...]** [S.l.: s.n.], 2023. p. 15180–15190.

GLENN, W. B. *et al.* Verification of forecasts expressed in terms of probability. **Monthly weather review**, War Department, Office of the Chief Signal Officer v. 78, n. 1, p. 1–3, 1950.

GOLDSTEIN, J. A. *et al.* **Generative Language Models and Automated Influence Operations: Emerging Threats and Potential Mitigations**, . 2023. Disponível em: <https://arxiv.org/abs/2301.04246>.

GONG, S. *et al.* **Fake News Detection Through Graph-based Neural Networks: A Survey**, . 2023. Disponível em: <https://arxiv.org/abs/2307.12639>.

GONGANE, V. U.; MUNOT, M. V.; ANUSE, A. D. A survey of explainable ai techniques for detection of fake news and hate speech on social media platforms. **Journal of Computational Social Science**, v. 7,, p. 587–623, 2024. Disponível em: <https://doi.org/10.1007/s42001-024-00248-9>.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. [S.l.]: MIT Press, 2016. <http://www.deeplearningbook.org>.

Google. **Gemma-3-12B-IT**, . 2024. Modelo de linguagem de grande porte ajustado para instruções, disponibilizado pelo Google na plataforma Hugging Face. Disponível em: <https://huggingface.co/google/gemma-3-12b-it>.

Google LLC. **Fact Check Tools API Documentation**, . 2024. Disponível em: <https://developers.google.com/fact-check/tools/api>.

GOZALO-BRIZUELA, R.; GARRIDO-MERCHÁN, E. C. **A survey of Generative AI Applications**, . 2023. Disponível em: <https://arxiv.org/abs/2306.02781>.

GRAVES, L.; AMAZEEN, M. A. **Fact-Checking as Idea and Practice in Journalism**, . 2019. Disponível em: <https://oxfordre.com/communication/view/10.1093/acrefore/9780190228613.001.0001/acrefore-9780190228613-e-808>.

GROH, M. *et al.* **Human Detection of Political Speech Deepfakes across Transcripts, Audio, and Video**, . 2024. Disponível em: <https://arxiv.org/abs/2202.12883>.

GROSS, M. The dangers of a post-truth world. **Current Biology**, v. 27, n. 1, p. R1–R4, 2017. ISSN 0960-9822. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0960982216315159>.

GUIDOTTI, R. *et al.* A survey of methods for explaining black box models. **ACM Comput. Surv.**, Association for Computing Machinery New York, NY, USA v. 51, n. 5,, ago. 2018. ISSN 0360-0300. Disponível em: <https://doi.org/10.1145/3236009>.

GUO, C. *et al.* On calibration of modern neural networks. *In*: PMLR. INTERNATIONAL CONFERENCE ON MACHINE LEARNING. 2017. **Anais [...]** [S.l.], 2017. p. 1321–1330.

GôLO, M. *et al.* On the use of large language models to detect brazilian politics fake news. *In*: ANAIS DO XXI ENCONTRO NACIONAL DE INTELIGÊNCIA ARTIFICIAL E COMPUTACIONAL. 2024, Porto Alegre, RS, Brasil. **Anais [...]** Porto Alegre, RS, Brasil: SBC, 2024. p. 1–12. ISSN 2763-9061. Disponível em: <https://sol.sbc.org.br/index.php/eniac/article/view/33777>.

GôLO, M. P. S. *et al.* One-class learning for fake news detection through multimodal variational autoencoders. **Engineering Applications of Artificial Intelligence**, v. 122,, p. 106088, 2023. ISSN 0952-1976. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0952197623002725>.

HAOUARI, F. *et al.* **ArCOV19-Rumors: Arabic COVID-19 Twitter Dataset for Misinformation Detection**, . 2021. Disponível em: <https://arxiv.org/abs/2010.08768>.

HASSIJA VINAY CHAMOLA, A. M. e. a. V. Interpreting black-box models: A review on explainable artificial intelligence. **Cognitive Computation**, v. 16,, p. 45–74, 2024. Disponível em: <https://doi.org/10.1007/s12559-023-10179-8>.

HE, P. *et al.* Deberta: Decoding-enhanced bert with disentangled attention. **arXiv preprint arXiv:2006.03654**, ,,, 2020.

HELMSTETTER, S.; PAULHEIM, H. Weakly supervised learning for fake news detection on twitter. *In*: IEEE. 2018 IEEE/ACM INTERNATIONAL CONFERENCE ON ADVANCES IN SOCIAL NETWORKS ANALYSIS AND MINING (ASONAM). 2018. **Anais [...]** [S.l.], 2018. p. 274–277.

HINTON, G.; VINYALS, O.; DEAN, J. Distilling the knowledge in a neural network. **arXiv preprint arXiv:1503.02531**, ,,, 2015.

HONNIBAL, M. *et al.* spacy: Industrial-strength natural language processing in python, . Zenodo, Honolulu, HI, USA,,, 2020.

HORVATH, J. *et al.* Manipulation detection in satellite images using vision transformer. *In*: PROCEEDINGS OF THE IEEE/CVF CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR) WORKSHOPS. 2021. **Anais [...]** [S.l.: s.n.], 2021. p. 1032–1041.

HOU, T.-Y.; TSENG, Y.-C.; YUAN, C. W. T. Is this ai sexist? the effects of a biased ai's anthropomorphic appearance and explainability on users' bias perceptions and trust. **International Journal of Information Management**, v. 76,, p. 102775, 2024. ISSN 0268-4012. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0268401224000239>.

HU, B. *et al.* Bad actor, good advisor: Exploring the role of large language models in fake news detection. *In*: PROCEEDINGS OF THE AAAI CONFERENCE ON ARTIFICIAL INTELLIGENCE. 38 n. 20., 2024. **Anais [...]** [S.l.: s.n.], 2024. p. 22105–22113.

HURST, A. *et al.* Gpt-4o system card. **arXiv preprint arXiv:2410.21276**, ,,, 2024.

INC., T. Twilio Engineering **Programmable Communications: The Twilio API Reference and Architecture Guide**. [S.l.], 2025. Disponível em: <https://www.twilio.com/docs>.

ISSA, B. *et al.* A comparative study on embedding models for keyword extraction using keybert method. *In*: IEEE. 2023 IEEE 13TH INTERNATIONAL CONFERENCE ON SYSTEM ENGINEERING AND TECHNOLOGY (ICSET). 2023. **Anais [...]** [S.l.], 2023. p. 40–45.

ITO, J. *et al.* Assessment of tweet credibility with lda features. *In*: PROCEEDINGS OF THE 24TH INTERNATIONAL CONFERENCE ON WORLD WIDE WEB. 2015, New York, NY, USA.

Anais [...] New York, NY, USA: Association for Computing Machinery, 2015. p. 953–958. ISBN 9781450334730. Disponível em: <https://doi.org/10.1145/2740908.2742569>.

JIANG, B. *et al.* **Disinformation Detection: An Evolving Challenge in the Age of LLMs**, . 2023. Disponível em: <https://arxiv.org/abs/2309.15847>.

JIANG, Z. *et al.* Active retrieval augmented generation. *In*: PROCEEDINGS OF THE 2023 CONFERENCE ON EMPIRICAL METHODS IN NATURAL LANGUAGE PROCESSING. 2023. **Anais [...]** [S.l.: s.n.], 2023. p. 7969–7992.

JIN, Z. *et al.* Multimodal fusion with recurrent neural networks for rumor detection on microblogs. *In*: PROCEEDINGS OF THE 25TH ACM INTERNATIONAL CONFERENCE ON MULTIMEDIA. 2017, New York, NY, USA. **Anais [...]** New York, NY, USA: Association for Computing Machinery, 2017. p. 795–816. ISBN 9781450349062. Disponível em: <https://doi.org/10.1145/3123266.3123454>.

JOHNSON, J.; DOUZE, M.; JÉGOU, H. Billion-scale similarity search with gpus. **IEEE Transactions on Big Data**, IEEE v. 7, n. 3, p. 535–547, 2019.

JUNKERT, F. G. Fake news and the 2018 brazilian presidential election. *In*: _____. **The Rule of Law in Cyberspace**. Cham: Springer International Publishing, 2022. p. 167–185. ISBN 978-3-031-07377-9. Disponível em: https://doi.org/10.1007/978-3-031-07377-9_9.

KAREEM, W.; ABBAS, N. Fighting lies with intelligence: Using large language models and chain of thoughts technique to combat fake news. *In*: BRAMER, M.; STAHL, F. (Ed.). **ARTIFICIAL INTELLIGENCE XL**. 2023, Cham. **Anais [...]** Cham: Springer Nature Switzerland, 2023. p. 253–258. ISBN 978-3-031-47994-6.

KARIM, F. *et al.* Lstm fully convolutional networks for time series classification. **IEEE Access**, v. 6,, p. 1662–1669, 2018.

KELLER, F. *et al.* Political astroturfing on twitter: How to coordinate a disinformation campaign. **Political Communication**, Taylor and Francis Ltd. v. 37, n. 2, p. 256–280, mar. 2020. ISSN 1058-4609.

KEYA, A. J. *et al.* Augfake-bert: Handling imbalance through augmentation of fake news using bert to enhance the performance of fake news classification. **Applied Sciences**, v. 12, n. 17,, 2022. ISSN 2076-3417. Disponível em: <https://www.mdpi.com/2076-3417/12/17/8398>.

KOHAVI, R. Glossary of terms. **Machine learning**, v. 30,, p. 271–274, 1998.

KÖPF, A. *et al.* Openassistant conversations-democratizing large language model alignment. **Advances in Neural Information Processing Systems**, v. 36,, p. 47669–47681, 2023.

KRIZHEVSKY, A.; SUTSKEVER, I.; HINTON, G. E. Imagenet classification with deep convolutional neural networks. **Commun. ACM**, Association for Computing Machinery New York, NY, USA v. 60, n. 6, p. 84–90, maio 2017. ISSN 0001-0782. Disponível em: <https://doi.org/10.1145/3065386>.

KULA, S. *et al.* Sentiment analysis for fake news detection by means of neural networks. *In*: KRZHIZHANOVSKAYA, V. V. *et al.* (Ed.). **COMPUTATIONAL SCIENCE – ICCS 2020**. 2020, Cham. **Anais [...]** Cham: Springer International Publishing, 2020. p. 653–666. ISBN 978-3-030-50423-6.

KUMAR, S.; SHAH, N. **False Information on Web and Social Media: A Survey**, . 2018. Disponível em: <https://arxiv.org/abs/1804.08559>.

- KWAK, H.; AN, J.; AHN, Y.-Y. A systematic media frame analysis of 1.5 million new york times articles from 2000 to 2017. *In: PROCEEDINGS OF THE 12TH ACM CONFERENCE ON WEB SCIENCE*. 2020. **Anais [...]** [S.l.: s.n.], 2020. p. 305–314.
- LAZER, D. *et al.* The science of fake news. **Science**, v. 359,, p. 1094–1096, 03 2018.
- LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. **Nature**, v. 521,, p. 436–444, 2015. Disponível em: <https://doi.org/10.1038/nature14539>.
- LEETARU, K.; SCHRODT, P. A. Gdelt: Global database of events, language, and tone. **Journal of Conflict Resolution**, SAGE Publications v. 57, n. 6, p. 1157–1180, 2023.
- LEITE, J. A. *et al.* Detecting misinformation with llm-predicted credibility signals and weak supervision., . Sheffield,,, 2023.
- LESTER, B.; AL-RFOU, R.; CONSTANT, N. **The Power of Scale for Parameter-Efficient Prompt Tuning**, . 2021. Disponível em: <https://arxiv.org/abs/2104.08691>.
- LIANG, P. *et al.* Holistic evaluation of language models. **arXiv preprint arXiv:2211.09110**, ,, 2022.
- LIAO, H. *et al.* Muser: A multi-step evidence retrieval enhancement framework for fake news detection. *In: PROCEEDINGS OF THE 29TH ACM SIGKDD CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING*. 2023. **Anais [...]** ACM, 2023. p. 4461–4472. Disponível em: <http://dx.doi.org/10.1145/3580305.3599873>.
- LIAO, Q. V.; VAUGHAN, J. W. **AI Transparency in the Age of LLMs: A Human-Centered Research Roadmap**, . 2023. Disponível em: <https://arxiv.org/abs/2306.01941>.
- LIN, C.-Y. Rouge: A package for automatic evaluation of summaries. *In: TEXT SUMMARIZATION BRANCHES OUT*. 2004. **Anais [...]** [S.l.: s.n.], 2004. p. 74–81.
- LIU, H. *et al.* Visual instruction tuning. *In: OH, A. et al. (Ed.). ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS*. 36., 2023. **Anais [...]** Curran Associates, Inc., 2023. p. 34892–34916. Disponível em: https://proceedings.neurips.cc/paper_files/paper/2023/file/6dcf277ea32ce3288914faf369fe6de0-Paper-Conference.pdf.
- LIU, X. *et al.* Fakenewsgpt4: advancing multimodal fake news detection through knowledge-augmented lvlms. **arXiv e-prints**, ,, p. arXiv–2403, 2024.
- LIU, Y. *et al.* **The Truth Becomes Clearer Through Debate! Multi-Agent Systems with Large Language Models Unmask Fake News**, . 2025. Disponível em: <https://arxiv.org/abs/2505.08532>.
- LIU, Y. *et al.* Roberta: A robustly optimized bert pretraining approach. **arXiv preprint arXiv:1907.11692**, ,, 2019.
- LOOMBA, S. *et al.* Measuring the impact of exposure to covid-19 vaccine misinformation on vaccine intent in the uk and us. **medRxiv**, Cold Spring Harbor Laboratory Press,,, 2020. Disponível em: <https://www.medrxiv.org/content/early/2020/10/26/2020.10.22.20217513>.
- LOTH, A.; KAPPES, M.; PAHL, M.-O. **Blessing or curse? A survey on the Impact of Generative AI on Fake News**, . 2024. Disponível em: <https://arxiv.org/abs/2404.03021>.
- LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. **Advances in neural information processing systems**, v. 30,,, 2017.
- LUO, G.; DARRELL, T.; ROHRBACH, A. **NewsCLIPpings: Automatic Generation of Out-of-Context Multimodal Media**, . 2021. Disponível em: <https://arxiv.org/abs/2104.05893>.

- MAATEN, L. Van der; HINTON, G. Visualizing data using t-sne. **Journal of Machine Learning Research**, v. 9, n. 86, p. 2579–2605, 2008. Disponível em: <https://jmlr.org/papers/v9/vandemaaten08a.html>.
- MACEDO, L. Artificial intelligence paradigms and agent-based technologies. *In*: GERMANAKOS, P. *et al.* (Ed.). **Human-Centered AI: An Illustrated Scientific Quest**. Springer, Cham 2025 (Human–Computer Interaction Series). Disponível em: https://doi.org/10.1007/978-3-031-61375-3_3.
- MAHARA, T. *et al.* Deep vs. shallow: A comparative study of machine learning and deep learning approaches for fake health news detection. **IEEE Access**, v. 11,, p. 79330–79340, 2023.
- MANAKUL, P.; LIUSIE, A.; GALES, M. Selfcheckgpt: Zero-resource black-box hallucination detection for generative large language models. *In*: PROCEEDINGS OF THE 2023 CONFERENCE ON EMPIRICAL METHODS IN NATURAL LANGUAGE PROCESSING. 2023. **Anais [...]** [S.l.: s.n.], 2023. p. 9004–9017.
- MARCONDES, F. S. *et al.* Using ollama. *In*: **Natural Language Analytics with Generative Large-Language Models: A Practical Approach with Ollama and Open-Source LLMs**. [S.l.]: Springer 2025. p. 23–35.
- MARTINO, G. D. S. *et al.* Semeval-2020 task 11: Detection of propaganda techniques in news articles. *In*: . 2020. **Anais [...]** [s.n.], 2020. Disponível em: <https://arxiv.org/abs/2009.02696>.
- MEMON, S. A.; CARLEY, K. M. Characterizing covid-19 misinformation communities using a novel twitter dataset. **arXiv preprint arXiv:2008.00791**, ,, 2020.
- MENDELSON, J.; BUDAK, C.; JURGENS, D. Modeling framing in immigration discourse on social media. **arXiv preprint arXiv:2104.06443**, ,, 2021.
- Meta. **Llama-3.1-8B-Instruct**, . 2024. Modelo de linguagem de grande porte ajustado para instruções, disponibilizado pela Meta na plataforma Hugging Face. Disponível em: <https://huggingface.co/meta-llama/Llama-3.1-8B-Instruct>.
- Microsoft. **Phi-4**, . 2024. Modelo de linguagem de grande porte disponibilizado pela Microsoft na plataforma Hugging Face. Disponível em: <https://huggingface.co/microsoft/phi-4>.
- MIRÓ-LLINARES, F.; AGUERRI, J. C. Misinformation about fake news: A systematic critical review of empirical studies on the phenomenon and its status as a ‘threat’. **European Journal of Criminology**, v. 20, n. 1, p. 356–374, 2021. Disponível em: <https://doi.org/10.1177/1477370821994059>.
- MISHIMA, K.; YAMANA, H. A survey on explainable fake news detection. **IEICE Transactions on Information and Systems**, E105.D, n. 7, p. 1249–1257, 2022.
- Mistral AI Team. **Mistral-7B-Instruct-v0.3**, . 2025. Modelo de linguagem de grande porte, disponível na plataforma Hugging Face. Disponível em: <https://huggingface.co/mistralai/Mistral-7B-Instruct-v0.3>.
- MOHSENI, S.; ZAREI, N.; RAGAN, E. D. **A Multidisciplinary Survey and Framework for Design and Evaluation of Explainable AI Systems**, . 2020. Disponível em: <https://arxiv.org/abs/1811.11839>.
- MONTEIRO, R. A. *et al.* Contributions to the study of fake news in portuguese: New corpus and automatic detection results. *In*: COMPUTATIONAL PROCESSING OF THE PORTUGUESE LANGUAGE. 2018. **Anais [...]** [S.l.]: Springer International Publishing, 2018. p. 324–334. ISBN 978-3-319-99722-3.

- MORAIS, J. I. de *et al.* Deciding among fake, satirical, objective and legitimate news: A multi-label classification system. *In: PROCEEDINGS OF THE XV BRAZILIAN SYMPOSIUM ON INFORMATION SYSTEMS*. 2019. **Anais [...]** [S.l.: s.n.], 2019. p. 1–8.
- MORENO, J. a.; BRESSAN, G. Factck.br: a new dataset to study fake news. *In: PROCEEDINGS OF THE 25TH BRAZILLIAN SYMPOSIUM ON MULTIMEDIA AND THE WEB*. 2019, New York, NY, USA. **Anais [...]** New York, NY, USA: Association for Computing Machinery, 2019. p. 525–527. ISBN 9781450367639. Disponível em: <https://doi.org/10.1145/3323503.3361698>.
- NAEEM, S. B.; BHATTI, R. The covid-19 ‘infodemic’: a new front for information professionals. **Health Information & Libraries Journal**, v. 37, n. 3, p. 233–239, 2020. Disponível em: <https://onlinelibrary.wiley.com/doi/abs/10.1111/hir.12311>.
- NAGOUDI, E. M. B. *et al.* **Machine Generation and Detection of Arabic Manipulated and Fake News**, . 2020. Disponível em: <https://arxiv.org/abs/2011.03092>.
- NAN, Q. *et al.* Mdfend: Multi-domain fake news detection. *In: PROCEEDINGS OF THE 30TH ACM INTERNATIONAL CONFERENCE ON INFORMATION & KNOWLEDGE MANAGEMENT*. 2021. **Anais [...]** [S.l.: s.n.], 2021. p. 3343–3347.
- NAN, Q. *et al.* **Improving Fake News Detection of Influential Domain via Domain- and Instance-Level Transfer**, . 2022. Disponível em: <https://arxiv.org/abs/2209.08902>.
- NARANG, S.; CHOWDHERY, A. **Pathways Language Model (PaLM): Scaling to 540 billion parameters for breakthrough performance**, . 2022. Publicado no blog da Google Research. Acessado em 26 de abril de 2025. Disponível em: <https://blog.research.google/2022/04/pathways-language-model-palm-scaling-to.html>.
- NEWMAN, N. *et al.* Reuters Institute for the Study of Journalism **Reuters Institute Digital News Report 2025**. [S.l.], 2025. Disponível em: <https://reutersinstitute.politics.ox.ac.uk/digital-news-report/2025>.
- NEWS, B. **Fake news: Five French election stories debunked**, . 2017. Acessado em 26 de abril de 2025. Disponível em: <https://www.bbc.com/news/world-europe-39265777>.
- NEWS, B. India lynchings: Whatsapp sets new rules after mob killings. **BBC News**, , July 2018. Disponível em: <https://www.bbc.com/news/world-asia-india-44897714>.
- OPENAI *et al.* **GPT-4 Technical Report**, . 2024. Disponível em: <https://arxiv.org/abs/2303.08774>.
- OUSIDHOUM, N.; YUAN, Z.; VLACHOS, A. Varifocal question generation for fact-checking. **arXiv preprint arXiv:2210.12400**, , 2022.
- OUYANG, L. *et al.* Training language models to follow instructions with human feedback. **Advances in neural information processing systems**, v. 35,, p. 27730–27744, 2022.
- PAPAGEORGIOU, E. *et al.* A survey on the use of large language models (llms) in fake news. **Future Internet**, v. 16, n. 8,, 2024. ISSN 1999-5903. Disponível em: <https://www.mdpi.com/1999-5903/16/8/298>.
- PAVLOV, T.; MIRCEVA, G. Covid-19 fake news detection by using bert and roberta models. *In: 2022 45TH JUBILEE INTERNATIONAL CONVENTION ON INFORMATION, COMMUNICATION AND ELECTRONIC TECHNOLOGY (MIPRO)*. 2022. **Anais [...]** [S.l.: s.n.], 2022. p. 312–316.
- PELRINE, K. *et al.* **Towards Reliable Misinformation Mitigation: Generalization, Uncertainty, and GPT-4**, . 2023. Disponível em: <https://arxiv.org/abs/2305.14928>.

PENNYCOOK, G.; RAND, D. G. The psychology of fake news. **Trends in Cognitive Sciences**, v. 25, n. 5, p. 388–402, 2021. ISSN 1364-6613. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1364661321000516>.

PETCH, J.; DI, S.; NELSON, W. Opening the black box: The promise and limitations of explainable machine learning in cardiology. **Canadian Journal of Cardiology**, Elsevier v. 38., p. 204–213, fev. 2022. ISSN 0828-282X. Disponível em: <https://doi.org/10.1016/j.cjca.2021.09.004>.

PISKORSKI, J. *et al.* Semeval-2023 task 3: Detecting the category, the framing, and the persuasion techniques in online news in a multi-lingual setup. *In*: PROCEEDINGS OF THE 17TH INTERNATIONAL WORKSHOP ON SEMANTIC EVALUATION (SEMEVAL-2023). 2023. **Anais [...]** [S.l.: s.n.], 2023. p. 2343–2361.

POPAT, K. *et al.* Declare: Debunking fake news and false claims using evidence-aware deep learning. **arXiv preprint arXiv:1809.06416**, , 2018.

QIAN, S. *et al.* Hierarchical multi-modal contextual attention network for fake news detection. *In*: PROCEEDINGS OF THE 44TH INTERNATIONAL ACM SIGIR CONFERENCE ON RESEARCH AND DEVELOPMENT IN INFORMATION RETRIEVAL. 2021, New York, NY, USA. **Anais [...]** New York, NY, USA: Association for Computing Machinery, 2021. p. 153–162. ISBN 9781450380379. Disponível em: <https://doi.org/10.1145/3404835.3462871>.

QU, Z. *et al.* Qmfnd: A quantum multimodal fusion-based fake news detection model for social media. **Information Fusion**, v. 104., p. 102172, 2024. ISSN 1566-2535. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1566253523004888>.

Qwen Team. **Qwen2.5-14B-Instruct**, . 2024. Modelo de linguagem de grande porte ajustado para instruções, disponível na plataforma Hugging Face. Disponível em: <https://huggingface.co/Qwen/Qwen2.5-14B-Instruct>.

Qwen Team. **Qwen2.5-3B-Instruct**, . 2024. Modelo de linguagem de grande porte ajustado para instruções, disponível na plataforma Hugging Face. Disponível em: <https://huggingface.co/Qwen/Qwen2.5-3B-Instruct>.

RAFFEL, C. *et al.* **Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer**, . 2023. Disponível em: <https://arxiv.org/abs/1910.10683>.

RAHMAN, S.; KHAN, S.; PORIKLI, F. A unified approach for conventional zero-shot, generalized zero-shot, and few-shot learning. **IEEE Transactions on Image Processing**, v. 27, n. 11, p. 5652–5667, 2018.

RAI, N. *et al.* Fake news classification using transformer based enhanced lstm and bert. **International Journal of Cognitive Computing in Engineering**, v. 3., p. 98–105, 2022. ISSN 2666-3074. Disponível em: <https://www.sciencedirect.com/science/article/pii/S2666307422000092>.

RAMÍREZ, S. **FastAPI: A high-performance, easy to learn, fast to code, ready for production**, . 2026. Disponível em: <https://fastapi.tiangolo.com/>.

RASHKIN, H. *et al.* Truth of varying shades: Analyzing language in fake news and political fact-checking. *In*: PROCEEDINGS OF THE 2017 CONFERENCE ON EMPIRICAL METHODS IN NATURAL LANGUAGE PROCESSING. 2017. **Anais [...]** [S.l.: s.n.], 2017. p. 2931–2937.

RATNER, A. *et al.* Snorkel: Rapid training data creation with weak supervision. *In*: PROCEEDINGS OF THE VLDB ENDOWMENT. INTERNATIONAL CONFERENCE ON VERY LARGE DATA BASES. 11 n. 3., 2017. **Anais [...]** [S.l.: s.n.], 2017. p. 269.

RATNER, A. J. *et al.* Data programming: Creating large training sets, quickly. **Advances in neural information processing systems**, v. 29,, 2016.

RODRIGUES, M. D. L. **Dataset Fake News and True News Brazil**, . 2025. Repositório GitHub. Licença CC BY 4.0. Disponível em: <https://github.com/michelleluzrodrigues/Dataset-Fake-news-and-True-news>.

ROUMELIOTIS, K. I.; TSELIKAS, N. D.; NASIOPOULOS, D. K. Fake news detection and classification: A comparative study of convolutional neural networks, large language models, and natural language processing models. **Future Internet**, v. 17, n. 1,, 2025. ISSN 1999-5903. Disponível em: <https://www.mdpi.com/1999-5903/17/1/28>.

RUDIN, C. Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. **Nature Machine Intelligence**, Association for Computing Machinery v. 1,, p. 206–215, maio 2019. ISSN 2522-5839. Disponível em: <https://doi.org/10.1038/s42256-019-0048-x>.

RUFFO, G. *et al.* Studying fake news spreading, polarisation dynamics, and manipulation by bots: A tale of networks and language. **Computer Science Review**, v. 47,, p. 100531, 2023. ISSN 1574-0137. Disponível em: <https://www.sciencedirect.com/science/article/pii/S157401372200065X>.

RUIZ, C. D. **Market-Oriented Disinformation Research**. 1. ed. Routledge, 2025. (Digital Advertising, Disinformation and Fake News on Social Media). ISBN 9781003506676. Disponível em: <https://doi.org/10.4324/9781003506676>.

RUSSELL, S.; NORVIG, P. **Artificial Intelligence, Global Edition**. 4. ed. Pearson Education, 2021. Disponível em: <https://elibrary.pearson.de/book/99.150005/9781292401171>.

SAEED, S. **French authorities investigate Macron fake news complaint**, . 2017. Publicado em POLITICO. Acessado em 26 de abril de 2025. Disponível em: <https://www.politico.eu/article/french-authorities-investigate-macron-fake-news-complaint/>.

SAEED, W.; OMLIN, C. Explainable ai (xai): A systematic meta-survey of current challenges and future opportunities. **Knowledge-Based Systems**, v. 263,, p. 110273, 2023. ISSN 0950-7051. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0950705123000230>.

SALEM, F. K. A. *et al.* Fa-kes: A fake news dataset around the syrian war. *In*: PROCEEDINGS OF THE INTERNATIONAL AAAI CONFERENCE ON WEB AND SOCIAL MEDIA. 13., 2019. **Anais [...]** [S.l.: s.n.], 2019. p. 573–582.

SAMEK, W.; MÜLLER, K.-R. Towards explainable artificial intelligence. *In*: _____. **Explainable AI: Interpreting, Explaining and Visualizing Deep Learning**. Cham: Springer International Publishing, 2019. p. 5–22. ISBN 978-3-030-28954-6. Disponível em: https://doi.org/10.1007/978-3-030-28954-6_1.

SHAHID, F.; ZAMEER, A.; MUNEEB, M. Predictions for covid-19 with deep learning models of lstm, gru and bi-lstm. **Chaos, Solitons & Fractals**, v. 140,, p. 110212, 2020. ISSN 0960-0779. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0960077920306081>.

SHAO, R.; WU, T.; LIU, Z. Detecting and grounding multi-modal media manipulation. *In*: PROCEEDINGS OF THE IEEE/CVF CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR). 2023. **Anais [...]** [S.l.: s.n.], 2023. p. 6904–6913.

SHARIFANI, K.; AMINI, M. Machine learning and deep learning: A review of methods and applications. **World Information Technology and Engineering Journal**, v. 10, n. 7, p. 3897–3904, 2023. Disponível em: <https://ssrn.com/abstract=4458723>.

SHETTY, N. P. *et al.* Disaster assessment from social media using multimodal deep learning. **Multimedia Tools and Applications**, Springer,, 2024. Disponível em: <https://doi.org/10.1007/s11042-024-19818-0>.

SHI, W. *et al.* Replug: Retrieval-augmented black-box language models. **arXiv preprint arXiv:2301.12652**, ,, 2023.

SHU, K. *et al.* defend: Explainable fake news detection. *In: PROCEEDINGS OF THE 25TH ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY & DATA MINING*. 2019. **Anais [...]** [S.l.: s.n.], 2019. p. 395–405.

SHU, K. *et al.* Fakenewsnet: A data repository with news content, social context, and spatiotemporal information for studying fake news on social media. **Big data**, Mary Ann Liebert, Inc., publishers 140 Huguenot Street, 3rd Floor New ... v. 8, n. 3, p. 171–188, 2020.

SHU, K. *et al.* Fake news detection on social media: A data mining perspective. **SIGKDD Explor. Newsl.**, Association for Computing Machinery New York, NY, USA v. 19, n. 1, p. 22–36, set. 2017. ISSN 1931-0145. Disponível em: <https://doi.org/10.1145/3137597.3137600>.

SILVA, F. R. M. da *et al.* Fakenewssetgen: A process to build datasets that support comparison among fake news detection methods. *In: PROCEEDINGS OF THE BRAZILIAN SYMPOSIUM ON MULTIMEDIA AND THE WEB*. 2020. **Anais [...]** [S.l.: s.n.], 2020. p. 241–248.

SILVA, R. M. *et al.* Towards automatically filtering fake news in portuguese. **Expert Systems with Applications**, v. 146,, p. 113199, 2020. ISSN 0957-4174. Disponível em: <http://www.sciencedirect.com/science/article/pii/S0957417420300257>.

SLAWINSKA, M.; MARDINI, P. C. **Navigating the LLM Landscape: A Comparative Analysis of Leading Large Language Models**, . 2025. Publicado no blog da MindsDB. Acessado em 26 de abril de 2025. Disponível em: <https://dev.to/mindsdb/navigating-the-llm-landscape-a-comparative-analysis-of-leading-large-language-models-1ocn>.

SOCIAL, W. A.; MELTWATER. We Are Social **Digital 2026: Brazil**. [S.l.], 2025. Disponível em: <https://datareportal.com/reports/digital-2026-brazil>.

SORENSEN, T. *et al.* Value kaleidoscope: Engaging ai with pluralistic human values, rights, and duties. *In: PROCEEDINGS OF THE AAAI CONFERENCE ON ARTIFICIAL INTELLIGENCE*. 38 n. 18., 2024. **Anais [...]** [S.l.: s.n.], 2024. p. 19937–19947.

SOUZA, M. C. d.; JORGE, A. M. G.; REZENDE, S. O. **Detecção de notícias falsas usando poucos dados positivos rotulados**. 2023. Dissertação (Mestrado) — Universidade de São Paulo 2023.

SU, J.; CARDIE, C.; NAKOV, P. Adapting fake news detection to the era of large language models. **arXiv preprint arXiv:2311.04917**, ,, 2023.

SU, Y. *et al.* **PandaGPT: One Model To Instruction-Follow Them All**, . 2023. Disponível em: <https://arxiv.org/abs/2305.16355>.

SUN, Y. *et al.* **Exploring the Deceptive Power of LLM-Generated Fake News: A Study of Real-World Detection Challenges**, . 2024. Disponível em: <https://arxiv.org/abs/2403.18249>.

SUN, Y. *et al.* Med-mmhl: A multi-modal dataset for detecting human-and llm-generated misinformation in the medical domain. **arXiv preprint arXiv:2306.08871**, ,, 2023.

SWARTZ, J. The world wide web's inventor warns it's in peril on 28th anniversary. **USA Today**, ,, 2017.

TAN, A. C.; GILBERT, D. Ensemble machine learning on gene expression data for cancer classification, . University of Glasgow,, 2003.

TANDOC, E. C.; LIM, Z. W.; LING, R. Defining “fake news”: A typology of scholarly definitions. **Digital Journalism**, v. 6, n. 2, p. 137–153, 2017. Disponível em: <https://doi.org/10.1080/21670811.2017.1360143>.

TAORI, R. *et al.* Alpaca: A strong, replicable instruction-following model. **Stanford Center for Research on Foundation Models**. <https://crfm.stanford.edu/2023/03/13/alpaca.html>, v. 3, n. 6, p. 7, 2023.

TII Team. **Falcon 3 10B Instruct**, . 2024. <https://huggingface.co/tiiuae/Falcon3-10B-Instruct>. Modelo de linguagem de grande porte disponível na plataforma Hugging Face.

TOUVRON, H. *et al.* Llama 2: Open foundation and fine-tuned chat models. **arXiv preprint arXiv:2307.09288**, , 2023.

UPADHYAY, R.; PASI, G.; VIVIANI, M. Leveraging socio-contextual information in bert for fake health news detection in social media. *In*: PROCEEDINGS OF THE 3RD INTERNATIONAL WORKSHOP ON OPEN CHALLENGES IN ONLINE SOCIAL NETWORKS. 2023. **Anais [...]** [S.l.: s.n.], 2023. p. 38–46.

VALENTE, J. C. L. Regulando desinformação e fake news: um panorama internacional das respostas ao problema. **Comunicação Pública [Online]**, v. 14, n. 27,, 2019. Publicado online no dia 13 de dezembro de 2019. Consultado em 25 de abril de 2025. Disponível em: <http://journals.openedition.org/cp/5262>.

VARGAS, F. *et al.* Predicting sentence-level factuality of news and bias of media outlets. *In*: MITKOV, R.; ANGELOVA, G. (Ed.). PROCEEDINGS OF THE 14TH INTERNATIONAL CONFERENCE ON RECENT ADVANCES IN NATURAL LANGUAGE PROCESSING. 2023, Varna, Bulgaria. **Anais [...]** Varna, Bulgaria: INCOMA Ltd., Shoumen, Bulgaria, 2023. p. 1197–1206. Disponível em: <https://aclanthology.org/2023.ranlp-1.127>.

VASWANI, A. *et al.* **Attention Is All You Need**, . 2023. Disponível em: <https://arxiv.org/abs/1706.03762>.

VIDA, I. K. The "great moon hoax" of 1835. **Hungarian Journal of English and American Studies (HJEAS)**, JSTOR,, p. 431–441, 2012.

VYKOPAL, I. *et al.* Generative large language models in automated fact-checking: A survey. **arXiv preprint arXiv:2407.02351**, , 2024.

VYKOPAL, I. *et al.* Disinformation capabilities of large language models. *In*: PROCEEDINGS OF THE 62ND ANNUAL MEETING OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS (VOLUME 1: LONG PAPERS). 2024. **Anais [...]** Association for Computational Linguistics, 2024. p. 14830–14847. Disponível em: <http://dx.doi.org/10.18653/v1/2024.acl-long.793>.

WAN, H. *et al.* Dell: Generating reactions and explanations for llm-based misinformation detection. **arXiv preprint arXiv:2402.10426**, , 2024.

WANG, D. *et al.* Soft-label for multi-domain fake news detection. **IEEE Access**, v. 11,, p. 98596–98606, 2023.

WANG, J. *et al.* Llm-enhanced multimodal detection of fake news. **PLOS ONE**, Public Library of Science v. 19, n. 10, p. 1–21, 10 2024. Disponível em: <https://doi.org/10.1371/journal.pone.0312240>.

WANG, L. *et al.* Multilingual e5 text embeddings: A technical report. **arXiv preprint arXiv:2402.05672**, , 2024.

- WANG, W. Y. "Liar, Liar Pants on Fire": A New Benchmark Dataset for Fake News Detection, . 2017. Disponível em: <https://arxiv.org/abs/1705.00648>.
- WANG, Y. *et al.* LLM-GAN: Construct Generative Adversarial Network Through Large Language Models For Explainable Fake News Detection, . 2024. Disponível em: <https://arxiv.org/abs/2409.01787>.
- WANG, Y. *et al.* Weak supervision for fake news detection via reinforcement learning. *In: PROCEEDINGS OF THE AAAI CONFERENCE ON ARTIFICIAL INTELLIGENCE.* 34 n. 01., 2020. **Anais [...]** [S.l.: s.n.], 2020. p. 516–523.
- WANG, Z. *et al.* Implementing bert and fine-tuned roberta to detect ai generated news by chatgpt. **arXiv preprint arXiv:2306.07401**, ,,, 2023.
- WARDLE, C. "Fake News." It's Complicated, . 2017. Publicado em First Draft. Disponível em: <https://medium.com/1st-draft/fake-news-its-complicated-d0f773766c79>.
- WARDLE, C.; DERAKHSHAN, H. **Information Disorder: Toward an Interdisciplinary Framework for Research and Policy Making**, . 2017. <https://edoc.coe.int/en/media/7495-information-disorder-toward-an-interdisciplinary-framework-for-research-and-policy-making.html>.
- WEI, J. *et al.* Chain-of-thought prompting elicits reasoning in large language models. **Advances in neural information processing systems**, v. 35,, p. 24824–24837, 2022.
- WEI, Z. *et al.* Cross-modal knowledge distillation in multi-modal fake news detection. *In: ICASSP 2022 - 2022 IEEE INTERNATIONAL CONFERENCE ON ACOUSTICS, SPEECH AND SIGNAL PROCESSING (ICASSP).* 2022. **Anais [...]** [S.l.: s.n.], 2022. p. 4733–4737.
- WOLF, T. *et al.* Transformers: State-of-the-art natural language processing. *In: PROCEEDINGS OF THE 2020 CONFERENCE ON EMPIRICAL METHODS IN NATURAL LANGUAGE PROCESSING: SYSTEM DEMONSTRATIONS.* 2020. **Anais [...]** [S.l.: s.n.], 2020. p. 38–45.
- World Wide Web Consortium. W3C **Cross-Origin Resource Sharing (CORS)**. [S.l.], 2020. Disponível em: <https://www.w3.org/TR/2020/SPSD-cors-20200602/>.
- WU, J.; GUO, J.; HOOI, B. Fake news in sheep's clothing: Robust fake news detection against llm-empowered style attacks. *In: PROCEEDINGS OF THE 30TH ACM SIGKDD CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING.* 2024. **Anais [...]** [S.l.: s.n.], 2024. p. 3367–3378.
- WU, L. *et al.* Misinformation in social media: Definition, manipulation, and detection. **SIGKDD Explor. Newsl.**, Association for Computing Machinery New York, NY, USA v. 21, n. 2, p. 80–90, nov. 2019. ISSN 1931-0145. Disponível em: <https://doi.org/10.1145/3373464.3373475>.
- WU, X. *et al.* **Usable XAI: 10 Strategies Towards Exploiting Explainability in the LLM Era**, . 2024. Disponível em: <https://arxiv.org/abs/2403.08946>.
- XUE, J. *et al.* Detecting fake news by exploring the consistency of multimodal data. **Inf. Process. Manage.**, Pergamon Press, Inc. USA v. 58, n. 5,, set. 2021. ISSN 0306-4573. Disponível em: <https://doi.org/10.1016/j.ipm.2021.102610>.
- YAN, F. *et al.* Fmc: Multimodal fake news detection based on multi-granularity feature fusion and contrastive learning. **Alexandria Engineering Journal**, v. 109,, p. 376–393, 2024. ISSN 1110-0168. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1110016824010019>.
- YANG, A. *et al.* Qwen2 technical report. **arXiv preprint arXiv:2407.10671**, ,,, 2024.

YANG YUCHEN WEI, H. W. e. a. W. Survey on explainable ai: From approaches, limitations and applications aspects. **Human-Centric Intelligent Systems**, v. 3,, p. 161–188, 2023. Disponível em: <https://doi.org/10.1007/s44230-023-00038-y>.

YANG, Z. *et al.* A coarse-to-fine cascaded evidence-distillation neural network for explainable fake news detection. **arXiv preprint arXiv:2209.14642**, ,, 2022.

YAO, S. *et al.* React: Synergizing reasoning and acting in language models. *In*: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS (ICLR). 2023. **Anais [...]** [S.l.: s.n.], 2023.

YING, Q. *et al.* Bootstrapping multi-view representations for fake news detection. **Proceedings of the AAAI Conference on Artificial Intelligence**, v. 37, n. 4, p. 5384–5392, Jun. 2023. Disponível em: <https://ojs.aaai.org/index.php/AAAI/article/view/25670>.

YOU, Y. *et al.* Imagenet training in minutes. *In*: PROCEEDINGS OF THE 47TH INTERNATIONAL CONFERENCE ON PARALLEL PROCESSING. 2018. **Anais [...]** [S.l.: s.n.], 2018. p. 1–10.

YU, Y. *et al.* Clinical big data and deep learning: Applications, challenges, and future outlooks. **Big Data Mining and Analytics**, TUP v. 2, n. 4, p. 288–305, 2019.

ZELLERS, R. *et al.* **Defending Against Neural Fake News**, . 2020. Disponível em: <https://arxiv.org/abs/1905.12616>.

ZHANG, X. *et al.* Mining dual emotion for fake news detection. *In*: PROCEEDINGS OF THE WEB CONFERENCE 2021. 2021, New York, NY, USA. **Anais [...]** New York, NY, USA: Association for Computing Machinery, 2021. p. 3465–3476. ISBN 9781450383127. Disponível em: <https://doi.org/10.1145/3442381.3450004>.

ZHANG, X.; GAO, W. Reinforcement retrieval leveraging fine-grained feedback for fact checking news claims with black-box llm. **arXiv preprint arXiv:2404.17283**, ,, 2024.

ZHANG, X.; GAO, W. Towards llm-based fact verification on news claims with a hierarchical step-by-step prompting method. **arXiv preprint arXiv:2310.00305**, ,, 2023.

ZHAO, J. *et al.* Fake news detection by incorporating multi-modal information. *In*: DONG, J.; ZHANG, L.; CHENG, D. (Ed.). PROCEEDINGS OF THE 2ND INTERNATIONAL CONFERENCE ON INTERNET OF THINGS, COMMUNICATION AND INTELLIGENT TECHNOLOGY. 2024, Singapore. **Anais [...]** Singapore: Springer Nature Singapore, 2024. p. 513–521. ISBN 978-981-97-2757-5.

ZHAO, R. *et al.* Verify-and-edit: A knowledge-enhanced chain-of-thought framework. **arXiv preprint arXiv:2305.03268**, ,, 2023.

ZHAO, S. *et al.* The prevalence, features, influencing factors, and solutions for covid-19 vaccine misinformation: systematic review. **JMIR public health and surveillance**, JMIR Publications Inc., Toronto, Canada v. 9, n. 1, p. e40201, 2023.

ZHAO, X. *et al.* Thrust: Adaptively propels large language models with external knowledge. **Advances in Neural Information Processing Systems**, v. 36,, p. 69930–69948, 2023.

ZHOU, X.; ZAFARANI, R. A survey of fake news: Fundamental theories, detection methods, and opportunities. **ACM Comput. Surv.**, Association for Computing Machinery New York, NY, USA v. 53, n. 5,, set. 2020. ISSN 0360-0300. Disponível em: <https://doi.org/10.1145/3395046>.

ZHOU, X. *et al.* Fake news: Fundamental theories, detection strategies and challenges. *In*: PROCEEDINGS OF THE TWELFTH ACM INTERNATIONAL CONFERENCE ON WEB SEARCH AND DATA MINING. 2019, New York, NY, USA. **Anais [...]** New York, NY, USA:

Association for Computing Machinery, 2019. p. 836–837. ISBN 9781450359405. Disponível em: <https://doi.org/10.1145/3289600.3291382>.

ZHU, D. *et al.* **MiniGPT-4: Enhancing Vision-Language Understanding with Advanced Large Language Models**, . 2023. Disponível em: <https://arxiv.org/abs/2304.10592>.

ZHU, J. *et al.* Propagation structure-aware graph transformer for robust and interpretable fake news detection. *In: PROCEEDINGS OF THE 30TH ACM SIGKDD CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING*. 2024, New York, NY, USA. **Anais [...]** New York, NY, USA: Association for Computing Machinery, 2024. p. 4652–4663. ISBN 9798400704901. Disponível em: <https://doi.org/10.1145/3637528.3672024>.

ZHU, P. *et al.* Multimodal fake news detection through intra-modality feature aggregation and inter-modality semantic fusion. **Complex & Intelligent Systems**, Springer v. 10,, p. 5851–5863, 2024. Disponível em: <https://doi.org/10.1007/s40747-024-01473-5>.

ZIDAN, M. *et al.* Multimodal fake news detection: A survey of text and visual content integration methods. **International Journal of Computers and Informatics (Zagazig University)**, v. 7,, Apr. 2025. Disponível em: <https://www.ijci.zu.edu.eg/index.php/ijci/article/view/102>.

ZOU, J.; SCHIEBINGER, L. Ai can be sexist and racist—it's time to make it fair. **Nature**, Springer Nature v. 559, n. 7714, p. 324–326, 2018. Disponível em: <https://doi.org/10.1038/d41586-018-05707-8>.

ZUBIAGA, A. *et al.* Detection and resolution of rumours in social media: A survey. **ACM Comput. Surv.**, Association for Computing Machinery New York, NY, USA v. 51, n. 2,, fev. 2018. ISSN 0360-0300. Disponível em: <https://doi.org/10.1145/3161603>.

ZUCKERMAN, E. **Stop Saying 'Fake News' It's Not Helping**, . 2017. Disponível em Ethanzuckerman.com. Disponível em: <http://www.ethanzuckerman.com/blog/2017/01/30/stop-saying-fake-news-its-not-helping/>.