

Da Exclusividade ao Acesso: Democratizando a Inteligência Artificial nas Ciências da Vida, na Educação e na Sociedade

Pesquisador: Robson Parmezan Bonidia

Universidade Tecnológica Federal do Paraná (UTFPR)

Av. Alberto Carazzai, 1640, Centro 86300-000 — Cornélio Procopio, PR — Brazil

Instituto de Ciências Matemáticas e de Computação — Universidade de São Paulo (USP)

Av. Trab. São Carlense, 400 — Centro, São Carlos—SP, 13566-590

*The Global South Artificial Intelligence for Pandemic, Epidemic, Preparedness & Response
(AI4PEP) Network*

bonidia@utfpr.edu.br

Orientador: André Carlos Ponce de Leon Ferreira de Carvalho

Instituto de Ciências Matemáticas e de Computação — Universidade de São Paulo (USP)

Av. Trab. São Carlense, 400 — Centro, São Carlos—SP, 13566-590

*The Global South Artificial Intelligence for Pandemic, Epidemic, Preparedness & Response
(AI4PEP) Network*

andre@icmc.usp.br

Sumário

Resumo	2
Validação das Informações	3
1 Introdução, Desafios e Motivação	3
2 Problemática e Objetivos	5
3 MathFeature: Democratizando a Representação de Dados Biológicos	7
3.1 Material e Métodos	7
3.2 Resultados, Impacto e Aplicações	9
4 BioAutoML: Democratizando o Aprendizado de Máquina nas Ciências da Vida	10
4.1 Material e Métodos	11
4.1.1 Extração de Características	12
4.1.2 BioAutoML - Seleção e Recomendação	12
4.1.3 Ajuste de Hiperparâmetros do(s) Algoritmo(s) de AM	14

4.2 Resultados, Impacto e Aplicações	14
5 Evidências de Aplicação, Alcance e Impacto das Soluções	16
5.1 MathPIP: Classificação de Peptídeos Pró-Inflamatórios	16
5.2 Análise da Importância de Características em Sequências Não Codificantes	16
5.3 Fatectídeos: Predição de Peptídeos Antivirais	17
5.4 BioDeepFuse: Uma Abordagem Híbrida de Aprendizado Profundo	18
5.5 BioPrediction-RPI: Democratizando a Predição de Interações entre Sequências	18
5.6 Democratizando a IA para a Preparação contra Pandemias	19
5.7 BioPrediction-PPI: Democratizando a Predição de Interações entre Sequências	20
5.8 BioAutoML-FAST: Uma Plataforma de Aprendizado de Máquina	20
6 InteliGente: Democratizando o Letramento em Inteligência Artificial	21
7 Prêmios, Reconhecimentos e Alcance	24
8 Conclusão	27
Agradecimentos	28
Referências	30

Resumo

As ciências da vida constituem uma das áreas de maior relevância científica e social, impulsionadas pela crescente disponibilidade de dados biológicos, como sequências de DNA, RNA e proteínas. Apesar dos avanços significativos em diagnósticos e tratamentos, persistem desafios importantes no monitoramento da saúde, na personalização de terapias, na descoberta de medicamentos e no combate a epidemias e pandemias. A Inteligência Artificial (IA), particularmente o Aprendizado de Máquina (AM), tem se mostrado uma abordagem promissora para enfrentar esses desafios, ao oferecer contribuições relevantes em diferentes campos da área.

No entanto, o uso efetivo do AM permanece limitado por barreiras técnicas que restringem sua adoção em larga escala. O desenvolvimento de modelos robustos exige habilidades em programação, engenharia de características e manipulação de grandes volumes de dados, o que limita sua adoção e amplia desigualdades, especialmente no Sul Global. Essa lacuna compromete a integração dessas tecnologias em contextos com capacidade técnica limitada.

Para enfrentar essas limitações, este trabalho propõe uma abordagem integrada para a democratização da IA, por meio do desenvolvimento de um ecossistema de soluções e letramento educacional para não especialistas, denominado AutoAI Hub, que conecta ciência, tecnologia e sociedade. Esse ecossistema integra soluções complementares, como o MathFeature, que automatiza a extração de características de sequências biológicas para estudos de doenças; o BioAutoML, que viabiliza a construção de pipelines de AM de ponta a ponta; e o InteliGente, voltado à educação e ao uso ético e social da IA.

O AutoAI Hub amplia o acesso a ferramentas avançadas de IA para a análise de dados biológicos e cria novas oportunidades de inovação científica e social. Os resultados dessa pesquisa possuem alto potencial para reduzir significativamente o conhecimento técnico necessário para utilizar pipelines de AM, auxiliando pesquisadores no combate a doenças, principalmente em países de baixa e média renda. Além disso, possibilita que biólogos, médicos, epidemiologistas e outras partes interessadas utilizem amplamente técnicas de IA para melhorar a saúde e o bem-estar de suas comunidades.

Por fim, o presente projeto já recebeu mais de 20 prêmios e reconhecimentos. No campo acadêmico, em um curto período, alcançou mais de 250 citações de pesquisadores de quase 50 países, evidenciando seu alcance e relevância em nível global. Em termos de impacto, as iniciativas, soluções e pesquisas desenvolvidas já atingiram milhares de pessoas, incluindo mais de 100.000 leituras em plataformas científicas e educacionais e mais de 10.000 usuários nas páginas online. De forma geral, estima-se que essas ações tenham gerado impacto direto e indireto em mais de 200.000 pessoas, contribuindo para a democratização do acesso à IA e para a promoção de soluções voltadas ao bem comum.

Palavras-chave: Inteligência Artificial; Aprendizado de Máquina; Democratização; Ciências da Vida; IA para Todos.

Validação das Informações

Para fins de validação das informações apresentadas neste texto, incluindo prêmios, reconhecimentos, notícias, métricas e demais evidências de impacto, recomenda-se a consulta aos sites oficiais do projeto e de suas iniciativas relacionadas, disponíveis em: <https://autoaipandemics.icmc.usp.br/> e <https://inteligentehub.com.br/news.html>. Esses ambientes reúnem documentação complementar, registros públicos e materiais comprobatórios associados aos resultados mencionados ao longo deste documento.

1 Introdução, Desafios e Motivação

A IA, especialmente os algoritmos de AM, desempenha um papel cada vez mais relevante nas ciências da vida, ampliando a capacidade de identificar padrões complexos e integrar informações biológicas, sociais e ambientais ao longo do ciclo de vida (SYROWATKA et al., 2021; FLEURENCE et al., 2025; MATHENY et al., 2025; CHEN, S. et al., 2024). Essas abordagens têm sido aplicadas com sucesso, por exemplo, para o desenvolvimento de novos medicamentos (HUANG et al., 2023), tratamento de doenças infecciosas (HE; LEANSE; FENG, 2021; LIU; LIU; LIU, 2025), monitoramento de pandemias (COMITO; PIZZUTI, 2022) e combate à desinformação (GUPTA et al., 2022; AYOUB; YANG; ZHOU, 2021; PETERS et al., 2025).

De acordo com (XIE; ZHAI; LU, 2025; YE; PANDEY; BAWDEN et al., 2025; KRAEMER et al., 2025), AM tem o potencial de transformar a epidemiologia, a saúde e as ciências

da vida. No entanto, o desenvolvimento de modelos robustos requer habilidades em programação, engenharia de recursos e manipulação de conjuntos de dados em larga escala, competências que não estão amplamente disponíveis entre os profissionais da área (BONIDIA; DOMINGUES et al., 2022; BONIDIA; SANTOS et al., 2022). Essa lacuna contribui para assimetrias no acesso à tecnologia e restringe sua integração em ambientes com capacidade técnica limitada (ROCHA et al., 2025). Além disso, o conteúdo técnico relacionado ao AM é raramente incorporado ao treinamento tradicional em ciências da vida, o que reforça as desigualdades existentes (GOLDSTEIN; LEVASSEUR; MCCLURE, 2020).

Além disso, análises recentes indicam que o desenvolvimento de ferramentas de IA para ciências da vida está altamente concentrado em países de alta renda, enquanto as necessidades estruturais e epidemiológicas do Sul Global recebem atenção limitada (WORLD HEALTH ORGANIZATION, 2023; AYANA et al., 2024; HUSSAIN; BRESNAHAN; ZHUANG, 2025). Um relatório da *Oxford Insights* (OXFORD INSIGHTS, 2025), que avaliou 181 países, identifica diversas nações latino-americanas entre aquelas com as menores pontuações de prontidão para IA, indicando que, sem condições favoráveis, as desigualdades tecnológicas globais provavelmente se aprofundarão.

Da mesma forma, diversas ferramentas de IA são treinadas em conjuntos de dados do Norte Global, produzindo vieses contextuais e reduzindo a precisão em ambientes com recursos limitados (INSIGHTS, 2024). (WORLD HEALTH ORGANIZATION, 2023) alerta que a infraestrutura de dados limitada, a interoperabilidade e a capacidade regulatória comprometem a adoção segura da IA e ampliam as desigualdades digitais. Em conjunto, esses estudos apontam para a necessidade de governança inclusiva e investimento equitativo para reduzir os riscos de aumento das disparidades econômicas e sociais existentes.

Uma alternativa para reduzir esses riscos é o desenvolvimento e a implementação de métodos de Aprendizado de Máquina Automatizado (AutoML, do inglês *Automated Machine Learning*), que podem automatizar etapas importantes na aplicação de algoritmos de AM a conjuntos de dados, oferecendo uma estratégia promissora para democratizar o uso eficaz da IA por não especialistas (KARMAKER et al., 2021; MANGA, 2025). O AutoML tem demonstrado desempenho robusto em diversas áreas, incluindo a curadoria de registros eletrônicos de saúde (MIAO et al., 2018), a identificação de imagens médicas (BORKOWSKI et al., 2019), o diagnóstico de Alzheimer (KARMAKER et al., 2021) e a análise de sequências biológicas (BONIDIA; SANTOS et al., 2022). No contexto de doenças infecciosas, os pesquisadores exploraram o AutoML para modelar a progressão da mortalidade da COVID-19 (HAN et al., 2023), a previsão da COVID-19 (TETTEROO; BARATCHI; HOOS, 2022), a previsão do risco de surtos (ZHANG; RABHI et al., 2022), a previsão da mortalidade da dengue (CHATTOPADHYAY; CHATTOPADHYAY; AIFANTIS, 2021), as respostas à vacina contra a gripe (TOMIC et al., 2019), a previsão de pneumonia fatal (ANAI et al., 2022) e a descoberta e desenvolvimento de medicamentos (GUAN; FU, 2022).

Mesmo assim, a democratização da IA não pode ser compreendida apenas como um desafio tecnológico, mas também como um desafio educacional. A ausência de formação

adequada em IA limita a capacidade de profissionais e estudantes de compreender, aplicar e criticar essas tecnologias, restringindo seu potencial de impacto social (AKGUN; GREENHOW, 2022; GOZZI; COMINI; PERRA, 2024; BONIDIA; SESTITO; CRUZ, 2025a). Assim, além do desenvolvimento de ferramentas acessíveis, torna-se essencial promover iniciativas educacionais que capacitem indivíduos a utilizar a IA de forma ética, crítica e voltada à resolução de problemas reais (UNESCO, 2022; WORLD ECONOMIC FORUM, 2023).

Levando isso em consideração e fundamentado no princípio da democratização da IA (ZOWGHI; BANO, 2024; ROCHA et al., 2025), entendido nesta pesquisa como a garantia de acesso equitativo à IA, independentemente do contexto geográfico ou socioeconômico, foi desenvolvido o AutoAI Hub¹, um ecossistema integrado de soluções computacionais e iniciativas educacionais voltado a não especialistas, conectando ciência, tecnologia e sociedade. O projeto integra a Rede Global Sul de IA para Preparação e Resposta a Pandemias e Epidemias (AI4PEP²), uma colaboração internacional envolvendo 16 países com foco no fortalecimento de sistemas de saúde por meio de soluções de IA lideradas pelo Sul Global.

Diferentemente das abordagens tradicionais, o AutoAI Hub propõe não apenas o desenvolvimento de ferramentas acessíveis, mas também a formação de indivíduos capazes de compreender, aplicar e avaliar criticamente a IA em contextos reais. Nesse sentido, o ecossistema articula soluções complementares, como o MathFeature³, BioAutoML⁴ e o InteliGente⁵, promovendo uma abordagem integrada que une inovação tecnológica, capacitação e impacto social.

Nesse contexto, este trabalho apresenta os resultados de uma agenda de pesquisa voltada à democratização da IA, integrando ferramentas automatizadas de AM e estratégias educacionais. A proposta busca ampliar a acessibilidade, a usabilidade e a eficácia da IA aplicada às ciências da vida e seu letramento ético, responsável e social, especialmente em países de baixa e média renda, contribuindo diretamente para a redução das desigualdades em IA e para a construção de soluções sustentáveis orientadas ao bem comum.

2 Problemática e Objetivos

O principal desafio desta pesquisa consiste no desenvolvimento de uma solução de AM de ponta a ponta, capaz de permitir que usuários com conhecimento limitado em programação desenvolvam aplicações baseadas em IA, especialmente no contexto das Ciências Biológicas. Entretanto, esse domínio apresenta particularidades que dificultam a construção de soluções automatizadas, acessíveis e eficientes. Entre os principais desafios, destacam-se:

- Os algoritmos tradicionais de AM requerem, em sua maioria, dados tabulares e numericamente estruturados como entrada para o processo de treinamento. Contudo,

¹<https://autoaipandemics.icmc.usp.br/>

²<https://ai4pep.org/>

³<https://bonidia.github.io/MathFeature/>

⁴<https://bioautoml.inteligentehub.com.br/>

⁵<https://inteligentehub.com.br/>

dados biológicos, como sequências de DNA, RNA e proteínas, possuem natureza sequencial e não estruturada, tornando necessária uma etapa prévia de transformação desses dados em representações numéricas adequadas. Essa etapa pode ser realizada por meio de centenas de técnicas de extração e representação de características, cada uma capaz de capturar diferentes propriedades biológicas, físico-químicas ou estatísticas das sequências. Nesse contexto, emerge a seguinte questão de pesquisa: *como representar numericamente dados biológicos, especificamente sequências biológicas?*

- O segundo desafio está relacionado à automatização conjunta da seleção das melhores representações numéricas, denominadas neste trabalho descritores de características, e da definição do pipeline de AM mais apropriado para o treinamento dos dados. Esse processo envolve diferentes decisões, incluindo a escolha dos descritores, técnicas de pré-processamento, métodos de seleção de características, algoritmos de aprendizagem e configuração de hiperparâmetros. Assim, a questão central consiste em: *como automatizar a construção e a otimização de pipelines de AM que integrem a seleção de descritores de características, o pré-processamento dos dados e a escolha de modelos preditivos, considerando as particularidades de diferentes problemas biológicos?*
- Por fim, o terceiro desafio consiste em disponibilizar essa solução aos usuários de maneira acessível, transparente, responsável e ética. A simples automatização do desenvolvimento de modelos não garante que seus resultados sejam corretamente interpretados ou utilizados. Além disso, muitos usuários podem não possuir conhecimentos básicos sobre o funcionamento, as limitações, os riscos e as implicações éticas dos sistemas de IA. No qual, surge a última questão de pesquisa: *como promover o uso consciente, crítico, responsável e eticamente orientado da IA por usuários não especialistas?*

Diante disso, as seções seguintes apresentam as soluções desenvolvidas para enfrentar as principais problemáticas anteriormente discutidas, as quais resultaram na criação das seguintes ferramentas, na ordem dos desafios apresentados:

- **MathFeature:** pacote para extração de características de sequências biológicas, reduzindo a dependência de conhecimento especializado no pré-processamento de dados;
- **BioAutoML:** pacote de AM automatizado de ponta a ponta para análise de dados biológicos, incluindo seleção de características, recomendação de algoritmos e ajuste de hiperparâmetros;
- **InteliGente:** iniciativa educacional para promover o letramento em IA, com foco no uso ético e social da tecnologia.

3 MathFeature: Democratizando a Representação de Dados Biológicos

A aplicação de algoritmos de AM a sequências biológicas é limitada pela natureza não estruturada de grande parte desses dados, visto que a maioria dos algoritmos, incluindo aqueles que produzem modelos interpretáveis, trabalha apenas com dados estruturados. Esse problema pode ser contornado por meio de técnicas de extração de características para representar os dados originalmente não estruturados em um formato estruturado. No entanto, as características devem capturar as informações relevantes presentes na sequência biológica, uma vez que o desempenho preditivo do modelo induzido por um algoritmo de AM depende fortemente da representatividade do vetor de características de entrada.

Esses processos frequentemente exigem amplo conhecimento do domínio e são realizados manualmente por um especialista humano, sendo uma das etapas mais demoradas no fluxo de trabalho de AM. A necessidade de um especialista cria desigualdade de conhecimento, pois a complexidade do processo e as habilidades necessárias formam uma barreira, limitando o potencial para pesquisas inovadoras. Considerando isso, um novo pacote de código aberto foi criado, chamado MathFeature(BONIDIA; SAMPAIO et al., 2021a; BONIDIA; DOMINGUES et al., 2022). Este pacote fornece, em um único ambiente, diversos descritores para a extração de características de sequências biológicas.

3.1 Material e Métodos

O MathFeature contém 37 descritores, dos quais 20 são matemáticos. Para o melhor do conhecimento (após uma revisão sistemática - ver Tabela 1), o MathFeature é o primeiro pacote a fornecer um conjunto tão amplo e abrangente de técnicas de extração de características baseadas em descritores matemáticos para DNA, RNA e proteínas.

MathFeature permite que os usuários simplesmente insiram seus dados de sequência, enquanto cuida do processo de representação numérica de sequências biológicas, sem a necessidade de intervenção especializada (ver Figura 1). Essa abordagem democratiza o acesso, tornando métodos avançados de engenharia de características disponíveis para qualquer pesquisador/interessado. Além disso, o MathFeature pode ser executado no console, mas também fornece uma plataforma com interface gráfica de usuário e um servidor web. Cada um dos 5 grupos que representam os descritores matemáticos é:

- **Mapeamento numérico:** Este grupo contém 7 descritores para mapeamento numérico: Voss (conhecido como mapeamento binário), Inteiro, Real, Curva Z, Potencial de interação elétron-íon (EIIP), Números complexos e Número atômico.
- **Fourier:** Este grupo consiste em métodos de extração de características que geram características de sequência com base no processamento de sinais genômicos, uma abordagem amplamente aplicada em diversos problemas de análise de sequências biológicas.

Tabela 1: Descritores calculados pelo MathFeature em comparação com os pacotes de extração de características disponíveis. Esta tabela apresenta a quantidade de descritores do MathFeature que foram implementados pelos pacotes existentes.

Pacotes	Descritores Matemáticos	Descritores Convencionais	Número de Descritores Calculados
<i>MathFeature</i>	20	17	37
PROFEAT	0	2	2
PseAAC	0	2	2
propy	0	5	5
PseKNC-General	0	5	5
SPiCE	0	4	4
ProtrWeb	0	5	5
ProFET	2	3	5
Pse-in-One	0	5	5
repDNA	0	5	5
Rcpi	0	3	3
repRNA	0	5	5
BioSeq-Analysis	0	9	9
iFeature	1	4	5
PyBioMed	0	7	7
Seq2Feature	0	0	0
PyFeat	1	8	9
iLearn	2	13	15




Figura 1: Fluxo de Execução do MathFeature (figura original em inglês). **Etapa 1:** Selecionar a sequência de entrada (DNA/RNA/Proteína — o MathFeature aceita apenas o formato FASTA); **Etapa 2:** Escolher o descritor (matemático ou convencional); **Etapa 3:** É necessário executar cada descritor separadamente; **Etapa 4:** Com os vetores gerados, é possível utilizá-los separadamente ou combiná-los em um único vetor.

- **Representação de Jogo do Caos:** Esta abordagem corresponde a um método de mapeamento de sequências baseado em uma representação geométrica iterativa e independente de escala, amplamente utilizada para a análise de sequências de DNA.
- **Entropia:** Diferentes estudos aplicaram conceitos da teoria da informação para a extração de características de sequência, principalmente a entropia de Shannon. Além disso, a entropia de Tsallis foi explorada com sucesso em diversos outros trabalhos. Este grupo inclui esses dois descritores.
- **Grafos:** Este grupo contém descritores baseados na teoria dos grafos, que têm sido usados com sucesso para representar sequências biológicas em diferentes contextos.

O pacote também fornece descritores bem conhecidos de outros estudos com sequências biológicas, como composição de ácidos nucleicos, composição de dinucleotídeos, composição de trinucleotídeos, composição de pseudo-K-tuplas de nucleotídeos (PseKNC), frequência acumulada de nucleotídeos, k-mer básico, composição de aminoácidos, composição de dipeptídeos, composição de tripeptídeos e frequência de composição de Xmer k-Spaced Ymer (kGap). Também foram implementados dois descritores amplamente conhecidos em estudos de sequências codificadoras, por exemplo, quadros de leitura abertos (ORFs) ou características de codificação e escore de Fickett.

3.2 Resultados, Impacto e Aplicações

O MathFeature foi avaliado em nove estudos de caso agrupados por sequências de proteínas e de DNA/RNA. Nos experimentos, foram considerados quatro problemas relacionados a proteínas e três relacionados a DNA/RNA. Os problemas de classificação em cada caso foram selecionados com base em artigos de áreas distintas. Por exemplo, para moléculas de proteína, utilizaram-se os seguintes conjuntos de dados: (1) proteínas secretadas não clássicas, que, segundo (ZHANG; YU et al., 2020), são importantes para a compreensão dos mecanismos de patogênese de bactérias Gram-positivas; (2) identificação de proteínas antivirais, por exemplo, para o desenvolvimento de novos fármacos antibacterianos (MA-NAVALAN; SHIN; LEE, 2018); (3) peptídeos anticancerígenos, que representam uma nova direção no tratamento do câncer (CHEN, W. et al., 2016; LI et al., 2020); e (4) *protein lysine crotonylation* (ZHAO et al., 2020; WANG et al., 2020).

Nesses estudos, observou-se que a combinação híbrida de descritores matemáticos e convencionais (disponíveis no MathFeature) melhora o desempenho dos modelos, resultando em valores de acurácia e acurácia balanceada variando entre 0,6450 e 0,9300 em todos os problemas. Para moléculas de DNA/RNA, os problemas utilizados foram: (1) SARS-CoV-2 (AFIFY; ZANATY, 2021); (2) detecção de promotores sigma70 para o estudo da dinâmica da expressão gênica (LIN et al., 2017; CASSIANO; SILVA-ROCHA, 2020); e (3) sequências de lncRNA, que podem desempenhar papéis essenciais em processos biológicos, como a regulação transcricional (PISIGNANO; LADOMERY, 2021; MENG et al., 2021). Para esses problemas, obtiveram-se resultados altamente robustos (com valores de acurácia e acurácia balanceada variando entre 0,8594 e 0,9900), tanto ao aplicar apenas descritores matemáticos quanto ao utilizar uma combinação híbrida. Por fim, os resultados demonstraram a relevância dos descritores do MathFeature em diversas aplicações, incluindo dados de humanos, plantas e bactérias.

Após a publicação, o MathFeature tem alcançado reconhecimento científico significativo em escala internacional. Até o momento, a ferramenta já registra mais de 14.000 visualizações e downloads na plataforma Oxford, além de mais de 110 citações, distribuídas por dezenas de países, o que evidencia sua relevância e disseminação global. Quando analisado o conjunto de estudos e publicações que fundamentaram o desenvolvimento do

MathFeature⁶, esse impacto se mostra ainda mais expressivo: são mais de 200 citações.

Além disso, segundo a *Dimensions*⁷, em comparação com outras publicações da mesma área, o MathFeature é altamente citado, recebendo aproximadamente 14 vezes mais citações do que a média. Por fim, estudos que citam e usam o pacote foram publicados em periódicos de destaque na literatura, como *Nucleic Acids Research* (IF: 15,0), *Genome Biology* (IF: 9,2), *Bioinformatics* (IF: 5,5), *Nature Communications* (IF: 18,1), *Briefings in Bioinformatics* (IF: 7,3) e *Genomics* (IF: 3,6).

4 BioAutoML: Democratizando o AM nas Ciências da Vida

Embora o MathFeature tenha representado um avanço importante ao democratizar a extração de características de sequências biológicas, a obtenção dos descritores é apenas uma das etapas necessárias para a construção de modelos preditivos robustos. Uma vez gerados os vetores numéricos, ainda permanecem desafios relevantes, como a seleção das características mais informativas, a escolha do algoritmo mais adequado e o ajuste de seus hiperparâmetros. É nesse contexto que surge o BioAutoML, ampliando a proposta de democratização ao automatizar as etapas subsequentes do pipeline de AM.

Isso é importante porque projetar soluções de AM robustas e confiáveis geralmente requer conhecimentos que não são comumente encontrados em pesquisadores da área de biologia e saúde, causando graves desigualdades (RUBEIS; DUBBALA; METZLER, 2022; ROCHA et al., 2025). Por exemplo, desigualdade de acessibilidade (disparidade em quem pode usar ferramentas poderosas, muitas vezes desfavorecendo aqueles que trabalham em instituições menores ou em regiões com poucos recursos); e desigualdade de conhecimento (a complexidade dos algoritmos de AM e as habilidades necessárias constituem uma barreira, limitando o potencial para pesquisa inovadora). Neste contexto, democratizar a IA implica conceder acessibilidade ao AM para indivíduos que não são especialistas, por exemplo, indivíduos sem formação em ciência de dados, matemática ou informática. Esta democratização deve capacitar diversas partes interessadas com contribuições únicas baseadas na sua aptidão, disponibilidade, dedicação e rapidez, proporcionando oportunidades iguais ao nível global.

Para mitigar essas limitações, conforme citado na introdução, métodos de AM automatizado (AutoML, do inglês *Automated Machine Learning*) estão sendo usados para democratizar o acesso e o uso eficaz de algoritmos de AM por não especialistas. O AutoML tem sido aplicado a dados de sequências biológicas, proporcionando soluções robustas, como auto-BioSeqpy (JING et al., 2020), AutoGenome (LIU; XU et al., 2021), iLearn (CHEN, Z.; ZHAO; LI, F. et al., 2019) e iLearnPlus (CHEN, Z.; ZHAO; LI, C. et al., 2021). No entanto, a maioria delas ainda aplica propostas de AutoML que não automatizam todo o processo, conhecido como AM de ponta a ponta, nem considera as especificidades dos dados de sequência. As duas primeiras dessas ferramentas cobrem apenas a etapa de modelagem de dados. As

⁶<http://lattes.cnpq.br/1572375422051077>

⁷<https://badge.dimensions.ai/details/doi/10.1093/bib/bbab434?domain=https://academic.oup.com>

duas últimas, iLearn e iLearnPlus, incluem mais etapas, mas não automatizam a extração de características de dados não estruturados. No entanto, conforme a *International Data Corporation (IDC)*⁸, até 2025, cerca de 80% dos dados gerados são não estruturados.

Essas limitações motivaram o desenvolvimento do BioAutoML⁹, projetado para facilitar a extração e seleção automática de características de dados sequenciais, considerando uma variedade de aspectos. Além disso, oferece recomendações de algoritmos e ajuste de hiperparâmetros específicos para a classificação multiclasse e binária em contextos biológicos, simplificando significativamente o processo de análise de dados complexos nesse campo.

Como forma de sustentar essa proposta, foram realizadas diferentes revisões sistemáticas da literatura (BONIDIA; SANTOS et al., 2022; ALMEIDA, B. L. de et al., 2026; FLORENTINO; BONIDIA; F DE CARVALHO, 2026), nas quais foram identificados diversos estudos voltados ao desenvolvimento de soluções para a análise de sequências biológicas, incluindo pacotes computacionais, servidores web e conjuntos de ferramentas. Apesar da relevância desses avanços, observou-se que a maioria dessas abordagens ainda depende de conhecimento técnico especializado para sua adequada utilização. Nesse contexto, o BioAutoML distingue-se por oferecer uma solução amplamente automatizada, capaz de integrar e cobrir, de maneira mais abrangente, o espectro da análise de sequências biológicas com AM.

4.1 Material e Métodos

O ciclo de vida de AM envolve diversas escolhas que exigem uma exploração manual significativa, uma tarefa que demanda muito tempo (SCHLEGEL; SATTLER, 2023). Esses desafios tornam-se mais acentuados ao lidar com dados não estruturados (DOMINGOS, 2012; BONIDIA; SANTOS et al., 2022; SINGH; HOODA, 2023). Para mudar esse cenário, BioAutoML utiliza o princípio de AM de ponta a ponta (*end-to-end*), que abrange todo o ciclo de vida de AM, desde o pré-processamento de dados, incluindo o tratamento de dados não estruturados, até a construção do modelo e sua interpretabilidade (FANG et al., 2025; MANGA, 2025).

Com base nisso, BioAutoML é um pacote amigável para classificação binária e multiclasse que permite o uso de engenharia de características automatizada e metalearning, conforme ilustrado pela Figura 2. Seu uso não requer assistência humana especializada. O pacote necessita apenas de um conjunto de treinamento composto por sequências biológicas (arquivos FASTA) para realizar um experimento de AM de ponta a ponta, desde a engenharia de características até a geração do modelo preditivo. Ainda assim, os módulos implementados no pacote BioAutoML podem ser executados de forma independente, ou seja, os usuários podem apenas gerar a melhor representação numérica e enviá-la para outro pacote de geração de modelos de AM, ou podem utilizar características extraídas por outros pacotes para gerar um modelo preditivo. Para isso, o BioAutoML possui dois

⁸<https://www.idc.com/>

⁹<https://github.com/Bonidia/BioAutoML>

componentes, cada um com dois módulos: (1) engenharia de características automatizada (extração e seleção de características) e (2) metalearning (recomendação de algoritmos e ajuste de hiperparâmetros). Nas próximas seções, cada módulo é descrito brevemente.




Figura 2: Componentes implementados no pacote BioAutoML (Figura original em Inglês): (1) Engenharia de Características Automatizada (extração e seleção de características) e (2) Metalearning (recomendação de algoritmos e ajuste de hiperparâmetros).

4.1.1 Extração de Características

Este módulo, que corresponde à primeira etapa da engenharia de características, extrai descritores utilizando o pacote MathFeature (BONIDIA; DOMINGUES et al., 2022), resultando em mais de 15 técnicas para representar numericamente as informações presentes em sequências biológicas.

4.1.2 BioAutoML - Seleção e Recomendação

O segundo módulo realiza a engenharia de características automatizada, selecionando o melhor vetor de características e o algoritmo de AM para induzir modelos preditivos, que também podem ser conjuntos de modelos preditivos, como mostrado na Figura 3. Para isso, utiliza-se a técnica de otimização Bayesiana (FRAZIER, 2018). Essa técnica foi adotada porque existe um grande número de alternativas quanto aos tipos e à quantidade de descritores de características, caracterizando um problema NP-difícil. Este módulo recebe como entrada:

- (1) Todos os descritores de características extraídos pelo primeiro módulo;
- (2) Uma função objetivo, por exemplo, no presente caso, acurácia balanceada para problemas binários e F1-score ponderado para problemas multiclasse;




Figura 3: Ilustração do funcionamento do BioAutoML (Figura original em Inglês): módulo de seleção e recomendação.

- (3) Algoritmos de AM (CatBoost ([PROKHORENKOVA et al., 2018](#)), AdaBoost ([SCHAPIRE, 2013](#)), Random Forest ([LIAW; WIENER et al., 2002](#)) e LightGBM ([KE et al., 2017](#))). Esses classificadores são responsáveis por analisar o potencial das características selecionadas. Esses algoritmos são utilizados para a seleção de características baseada em *wrapper*, empregando diferentes subconjuntos de características como entrada. Esses algoritmos foram escolhidos porque apresentam bom desempenho preditivo e induzem modelos interpretáveis, permitindo compreender o processo interno de tomada de decisão ([BONIDIA; MACHIDA et al., 2020](#)). Além disso, esses algoritmos são amplamente adotados na literatura de bioinformática ([LIU; YU et al., 2020](#); [HANCOCK; KHOSHGOFTAAAR, 2020](#); [HE; DOU et al., 2022](#)).

Para representar o espaço de busca (na seleção de descritores de características e recomendação de algoritmos de AM), utiliza-se um vetor de entrada parcialmente binário, por exemplo, $[1, 0, 1, 0, 0, 1, [2]]$, em que a última posição pode assumir um valor do conjunto $0, 1, 2, 3$, representando cada um dos algoritmos de AM. Nas demais posições, o valor 0 significa que o descritor de característica não foi selecionado para o subconjunto a ser avaliado, enquanto o valor 1 indica que foi selecionado.

Em seguida, por meio da otimização Bayesiana ([BERGSTRA; YAMINS; COX et al., 2013](#)), o BioAutoML seleciona um vetor de características considerando o desempenho preditivo do modelo utilizado no *wrapper*. A otimização Bayesiana foi escolhida com base em estudos da literatura ([FRAZIER, 2018](#); [VICTORIA; MARAGATHAM, 2021](#); [ELSAAYAD; NASSEF; AL-DHAIFALLAH, 2022](#)), que demonstram sua capacidade de economizar tempo e melhorar o desempenho, apresentando vantagens em relação à busca aleatória ([TURNER et al., 2021](#)).

Como pode ser visto na Figura 3, o BioAutoML gera combinações de características e algoritmo(s) de AM até encontrar o melhor par (conjunto de características selecionadas, algoritmo de AM recomendado) a ser enviado ao quarto módulo, o ajuste de hiperparâmetros. Também se adota como critério de parada da otimização o momento em que o desempenho preditivo atinge um platô ou após a avaliação de 50 pares (esse número pode ser alterado pelo usuário).

4.1.3 Ajuste de Hiperparâmetros do(s) Algoritmo(s) de AM

O último módulo corresponde ao ajuste de hiperparâmetros, no qual os usuários podem gerar um modelo preditivo a partir da recomendação do vetor de características e dos algoritmos de AM (entre aqueles cuja implementação está disponível no BioAutoML). Esses algoritmos utilizam o vetor de características para induzir um conjunto de modelos de classificação, cujas saídas serão combinadas por meio de uma abordagem baseada em ensemble. A qualidade dos modelos de classificação é influenciada pelos valores dos hiperparâmetros utilizados nos algoritmos de AM recomendados. Neste trabalho, a otimização Bayesiana também é empregada para ajustar esses hiperparâmetros.

Os hiperparâmetros ajustados para cada algoritmo são definidos com base em sua documentação oficial, por exemplo, no caso do Random Forest (*n_estimators*, *max_features*, *criterion*, *max_depth*, *min_samples_split*, *min_samples_leaf* e *bootstrap*). A otimização é encerrada quando o desempenho preditivo atinge um platô ou após a avaliação de 100 possíveis conjuntos de valores. Além disso, este módulo gera como saída importantes arquivos de análise de desempenho, como melhores características, resultados de desempenho, modelo treinado e importância das características, entre outros.

4.2 Resultados, Impacto e Aplicações

BioAutoML tem alcançado resultados robustos em dezenas de domínios, conforme será apresentado na próxima seção, apresentando casos de sucesso em áreas como SARS-CoV-2, peptídeos anticancerígenos, peptídeos pró-inflamatórios, sequências de HIV-1, proteínas secretadas não clássicas, promotores sigma70, pontos de recombinação, pequenos RNAs não codificantes, longos RNAs não codificantes, RNAs circulares e outros. No entanto, em sua nova versão (BioAutoML-FAST¹⁰ (ALMEIDA, B. L. de et al., 2026), recentemente lançada), ele foi avaliado de forma rigorosa em 60 conjuntos de dados de referência contra a literatura, abrangendo problemas com sequências de nucleotídeos e aminoácidos em tarefas de classificação binária, classificação multiclasse e regressão.

Em cada cenário, BioAutoML identificou automaticamente as melhores combinações entre descritores e algoritmos, com os experimentos sendo repetidos cinco vezes, de modo a mensurar não apenas o desempenho preditivo, mas também a estabilidade dos resultados. A comparação com métodos de referência da literatura foi realizada a partir de 152 métricas de treinamento e 179 métricas de teste, permitindo uma avaliação ampla e robusta da capacidade preditiva e da generalização dos modelos gerados. Os resultados mostraram que o BioAutoML igualou ou superou o estado da arte em 90 das 152 métricas de treinamento e em 87 das 179 métricas de validação externa, evidenciando um desempenho altamente competitivo em uma grande diversidade de tarefas biológicas. Mesmo nos casos em que não alcançou o melhor resultado absoluto, a plataforma manteve um desempenho muito próximo dos métodos de referência: 102 métricas de treinamento e 135 métricas de teste ficaram dentro de uma margem de até 5% em relação aos melhores resultados reportados

¹⁰<https://bioautoml.icmc.usp.br/>

na literatura (tabelas apresentadas no artigo (ALMEIDA, B. L. de et al., 2026), devido à falta de espaço no presente documento).

Esses resultados tornam-se ainda mais relevantes por terem sido obtidos por meio de um pipeline totalmente automatizado e padronizado, sem exigir do usuário conhecimento especializado em engenharia de características, seleção de modelos ou ajuste de hiperparâmetros. Além disso, o BioAutoML tem demonstrado desempenho competitivo, inclusive frente a métodos recentes e sofisticados, entre eles abordagens baseadas em modelos de linguagem para sequências biológicas. Esse conjunto de evidências reforça seu potencial para acelerar pesquisas em ciências da vida e ampliar o acesso à IA por pesquisadores, profissionais e instituições que tradicionalmente enfrentam barreiras técnicas para sua adoção.

Ao automatizar etapas complexas, como a representação numérica das sequências, a seleção de características, a recomendação de algoritmos e o ajuste de hiperparâmetros, o BioAutoML reduz substancialmente a experiência necessária para operar pipelines de AM. Com isso, pesquisadores que atuam em laboratórios menores ou em contextos com acesso limitado a especialistas em ciência de dados podem realizar análises avançadas de dados biológicos sem precisar dominar a programação ou a modelagem computacional. Essa característica permite que biólogos, biomédicos e outros não especialistas concentrem seus esforços na interpretação dos resultados e nas questões científicas do estudo, e não nas barreiras técnicas do processo analítico. Dessa forma, o BioAutoML pode ampliar o acesso a diversas investigações, por exemplo, sobre metabolismo, expressão gênica, função e evolução de genes e proteínas, promovendo inclusão científica e fortalecendo o empenho global em ciência e saúde.

Até o momento, a ferramenta já registra mais de 8.500 visualizações e downloads na plataforma Oxford e soma aproximadamente 50 citações, evidenciando sua rápida circulação e adoção pela comunidade científica. Quando analisado em perspectiva comparativa, segundo a *Dimensions*¹¹, o BioAutoML recebeu cerca de 6,86 vezes mais citações do que a média das publicações de sua área, o que reforça sua relevância e originalidade no campo. Esse alcance também se reflete em sua presença na literatura internacional.

O BioAutoML vem sendo citado, discutido ou utilizado em diferentes contextos científicos, incluindo estudos de revisão, trabalhos metodológicos e pesquisas aplicadas em áreas como bioinformática, AM automatizado, descoberta de fármacos, vacinas, metagenômica, engenharia de características e democratização da IA. Além disso, as métricas do *Google Analytics* indicam que o site de soluções do Hub já ultrapassou 11.000 visitas, com mais de 5.000 usuários ativos nos últimos 12 meses, reforçando o alcance contínuo e o interesse gerado pela proposta. Finalmente, a nova geração da ferramenta, o BioAutoML-FAST¹², amplia ainda mais esse impacto ao consolidar uma plataforma pública e reutilizável para modelos automatizados em sequências biológicas.

¹¹ <https://badge.dimensions.ai/details/doi/10.1093/bib/bbac218?domain=https://academic.oup.com>

¹² <https://bioautoml.icmc.usp.br/>

5 Evidências de Aplicação, Alcance e Impacto das Soluções

Nesta seção, apresenta-se uma seleção de resumos de artigos publicados ou em desenvolvimento do presente grupo de trabalho, reunindo diferentes resultados que demonstram a eficácia, a aplicabilidade e os desdobramentos das soluções apresentadas. Os trabalhos evidenciam como essas tecnologias têm contribuído para avanços na análise de problemas biológicos e para a resolução de problemas em distintos contextos científicos.

Entretanto, esta seleção representa apenas uma parcela do impacto alcançado. A literatura científica reúne dezenas de estudos que utilizam, avaliam ou mencionam essas soluções, conforme pode ser verificado no Google Scholar¹³. Além disso, os milhares de acessos e downloads registrados indicam uma adoção ainda mais ampla, incluindo aplicações que nem sempre resultam em publicações, mas que podem estar apoiando pesquisas, processos de inovação e a resolução de problemas reais da ciência e do mercado.

5.1 MathPIP: Classificação de Peptídeos Pró-Inflamatórios

Peptídeos pró-inflamatórios (PIP, do inglês *Proinflammatory Peptide*) constituem uma parte relevante da resposta inflamatória, sendo frequentemente a primeira reação do sistema imunológico a corpos estranhos, isto é, a infecções indutoras de inflamação, como a COVID-19. Nesse contexto, torna-se essencial dispor de formas confiáveis de classificar e analisar novas instâncias de PIPs. Modelos de AM têm sido amplamente empregados na classificação de sequências biológicas, constituindo a base da maioria dos estudos em extensas bases de dados de informação biológica. No entanto, a maioria dos algoritmos de AM tem dificuldade em lidar diretamente com essas sequências. Dessa forma, características relevantes precisam ser extraídas, tornando a etapa de extração de características uma das mais importantes na aplicação de algoritmos de AM a dados biológicos. Diferentes características têm sido propostas, muitas delas baseadas em conhecimento prévio, como estruturas moleculares. Entretanto, muitas sequências biológicas disponíveis publicamente não vêm acompanhadas desse tipo de informação. Para contornar essa limitação, este estudo propõe investigar o uso de descritores matemáticos para a extração de características de sequências de PIPs. A fim de avaliar a relevância das características obtidas por meio desses descritores, foram realizados experimentos com a aplicação de três algoritmos de AM. Os resultados demonstraram uma acurácia preditiva de 0,7034, valor compatível com os classificadores de PIP atualmente disponíveis.

Trabalho Completo: (CAVALCANTE et al., 2021).

5.2 Análise da Importância de Características em Sequências Não Codificantes

Sequências não codificantes têm ganhado espaço crescente em áreas científicas relacionadas à bioinformática, em razão dos papéis essenciais que desempenham em diferentes

¹³<https://bonidia.intelgentehub.com.br/>

processos biológicos. Elucidar a função dessas regiões não codificantes constitui um desafio relevante, que vem sendo abordado por diversos estudos de AM em diferentes campos de ncRNA, como pequenos RNAs não codificantes (sRNAs) e RNAs circulares (circRNAs). A identificação dessas sequências biológicas pode ser realizada por meio de técnicas de engenharia de características, capazes de evidenciar especificidades em diferentes tipos de problemas envolvendo AM. Nesse contexto, estudos recentes têm se concentrado em métodos computacionais interpretáveis, isto é, na identificação das melhores características com base em análises de importância. Por essa razão, este estudo propõe explorar diferentes descritores de características e o grau de importância envolvido em tarefas de classificação, utilizando dois estudos de caso: (1) predição de sRNAs em bactérias e (2) predição de circRNAs em humanos. Para isso, foi desenvolvido um pipeline geral com vetores híbridos de características, combinando descritores matemáticos e convencionais. Além disso, esses vetores foram gerados com o pacote MathFeature e com técnicas de seleção de características em ambos os estudos de caso. Por fim, os resultados experimentais reportaram alto desempenho preditivo e evidenciaram a relevância da combinação de descritores convencionais e matemáticos em diferentes organismos.

Trabalho Completo: ([ALMEIDA, B. L. S. de et al., 2021](#)).

5.3 Fatectídeos: Predição de Peptídeos Antivirais

Desde o início da humanidade, diferentes tipos de ameaças virais de relevância biológica vêm desafiando a sociedade, incluindo patógenos tropicais, alguns altamente letais ou de caráter pandêmico, como Ebola, H1N1 e Sars-CoV-2. Apesar dos avanços nas pesquisas em saúde, as infecções virais continuam associadas a elevadas taxas de mortalidade. Nesse contexto, seguem em andamento pesquisas e projetos voltados ao desenvolvimento de novos medicamentos antivirais. Consequentemente, fármacos baseados em peptídeos tornaram-se uma alternativa cada vez mais importante de investigação, inclusive no apoio ao desenvolvimento de vacinas. Os peptídeos antivirais (AVPs, do inglês *Antiviral Peptides*) constituem um subconjunto dos peptídeos antimicrobianos (AMPs, do inglês *Antimicrobial Peptides*) e podem atuar como primeira linha de defesa da resposta imune em muitos organismos. Os AVPs podem ser obtidos por diferentes métodos, incluindo métodos computacionais, fontes naturais e fontes biológicas. Um dos métodos ainda relativamente pouco explorados para a predição de peptídeos antivirais é o desenvolvimento de ferramentas baseadas em AM. No entanto, apesar das contribuições já existentes, ainda há oportunidades de aprimoramento em diferentes ferramentas de predição, especialmente no que se refere ao desempenho preditivo. Um dos principais desafios está no tratamento de dados biológicos não estruturados, uma vez que muitos algoritmos operam apenas com dados numéricos. Assim, torna-se necessário traduzir sequências biológicas em vetores numéricos. Com base nisso, este estudo propõe uma ferramenta para a classificação de peptídeos antivirais fundamentada no BioAutoML, capaz de extrair informações de sequências bioló-

gicas e convertê-las em dados numéricos. Essa abordagem busca simplificar essa etapa para biólogos e pesquisadores que desenvolvem diferentes métodos baseados em AVPs, gerando impacto não apenas para a ciência brasileira, mas também para a sociedade e a saúde.

Trabalho Completo: MEDEIROS, Beatriz Leite; INÁCIO, Gabriele de Campos; BONIDIA, Robson Parmezan. Fatectídeos: Prediction of Antiviral Peptides. In: Iniciação Científica - Fatec Ourinhos - Ciência de Dados.

5.4 BioDeepFuse: Uma Abordagem Híbrida de Aprendizado Profundo

A classificação acurada de sequências de RNAs não codificantes (ncRNA) é fundamental para a anotação e a análise avançada do genoma não codificante, um aspecto da genômica que contribui para a compreensão das funções dos ncRNAs e de seus mecanismos regulatórios em diversos processos biológicos. Embora abordagens tradicionais de AM tenham sido empregadas para distinguir ncRNAs, elas frequentemente exigem extensa engenharia de características. Recentemente, algoritmos de aprendizado profundo têm proporcionado avanços na classificação de ncRNAs. Este estudo apresenta o BioDeepFuse, um framework híbrido de aprendizado profundo que integra redes neurais convolucionais (CNN) ou redes bidirecionais de memória de longo e curto prazo (BiLSTM) com características elaboradas manualmente, visando aumentar a acurácia. Esse framework emprega uma combinação de representações baseadas em k-mer one-hot, dicionário de k-mers e técnicas de extração de características para representar as entradas. Utilizando conjuntos de dados de referência e amostras reais de RNA de organismos bacterianos, foi avaliado o desempenho do BioDeepFuse. Os resultados evidenciaram alta acurácia na classificação de ncRNAs, ressaltando a robustez da ferramenta diante dos desafios impostos por dados complexos de sequências de ncRNA. A integração eficaz entre CNN ou BiLSTM e características externas aponta direções promissoras para pesquisas futuras, especialmente no aprimoramento de classificadores de ncRNA e no aprofundamento da compreensão sobre o papel dos ncRNAs em processos celulares e manifestações de doenças. Além de sua aplicação original no contexto de organismos bacterianos, as metodologias e técnicas integradas ao framework podem potencialmente tornar o BioDeepFuse eficaz em domínios mais amplos e diversos.

Trabalho Completo: ([AVILA SANTOS et al., 2024](#)).

5.5 BioPrediction-RPI: Democratizando a Predição de Interações entre Sequências

Algoritmos de AM têm desempenhado papel importante na extração de conhecimento útil a partir de sequências biológicas, especialmente em áreas como saúde, agricultura e meio ambiente. No entanto, a natureza categórica e não estruturada dessas sequências geralmente exige etapas adicionais de engenharia de características antes que um algoritmo de

AM possa ser aplicado de forma eficiente. A incorporação dessas etapas ao algoritmo de AM dá origem a um pipeline de processamento, conhecido como AM de ponta a ponta. Apesar dos excelentes resultados obtidos com a aplicação de AM de ponta a ponta em problemas de biotecnologia, o desempenho alcançado depende, em grande medida, da expertise do usuário nos diferentes componentes do pipeline. Neste trabalho, é proposto um framework baseado em AM de ponta a ponta, denominado BioPrediction-RPI, capaz de identificar interações implícitas entre sequências, como pares de RNA não codificante e proteínas, sem a necessidade de conhecimento especializado em AM de ponta a ponta. Esse framework aplica engenharia de características para representar cada sequência por meio de atributos estruturais e topológicos. Essas características são organizadas em grupos e utilizadas para treinar modelos parciais, cujas decisões são então combinadas em uma decisão final, fornecendo ao usuário um relatório de interpretabilidade. Nos experimentos realizados, o framework desenvolvido mostrou-se competitivo em comparação com diversos modelos criados por especialistas. O BioPrediction-RPI foi avaliado em 12 conjuntos de dados, nos quais apresentou desempenho igual ou superior ao de todas as ferramentas comparadas em 40% a 100% dos casos, dependendo do experimento. Por fim, o BioPrediction-RPI é capaz de ajustar modelos com base em novos dados e alcançar desempenho em nível comparável ao de especialistas em AM, democratizando e ampliando seu acesso para aqueles que atuam nas ciências biológicas.

Trabalho Completo: ([FLORENTINO](#); [BONIDIA](#); [SANCHES et al., 2024](#)).

5.6 Democratizando a IA para a Preparação contra Pandemias

As doenças infecciosas continuam a representar um importante desafio global de saúde, exigindo abordagens inovadoras para prever surtos, detectar variantes, realizar rastreamento de contatos, descobrir novos fármacos e lidar com a desinformação. A IA tem apoiado significativamente os trabalhos nessas áreas, particularmente durante a pandemia de COVID-19. No entanto, os benefícios da IA devem ser distribuídos de forma equitativa, e seu uso deve ser responsável e inclusivo. À medida que diferentes nações implementam regulamentações para a IA, a natureza global dessa tecnologia torna necessária a colaboração internacional para o estabelecimento de diretrizes éticas e marcos de governança. Em resposta a essas necessidades, a Rede Global Sul de Inteligência Artificial para Preparação e Resposta a Pandemias e Epidemias (AI4PEP) lidera um esforço multinacional em 16 países com o objetivo de fortalecer os sistemas de saúde pública por meio de soluções de IA responsáveis e lideradas pelo Sul Global. Este artigo de opinião destaca as iniciativas da AI4PEP na América Latina e no Caribe, examinando os modelos de governança em IA da região e os desafios que eles apresentam. Ao reduzir barreiras à adoção da IA e promover acesso equitativo a inovações em saúde pública baseadas em IA, esta rede capacita pesquisadores, profissionais da saúde e formuladores de políticas públicas a utilizar a IA na preparação e resposta a doenças infecciosas, contribuindo, em última instância, para

melhores desfechos em saúde em países de baixa e média renda.

Trabalho Completo: ([ROCHA et al., 2025](#)).

5.7 BioPrediction-PPI: Democratizando a Predição de Interações entre Sequências

Proteínas são essenciais em processos biológicos, principalmente por meio de suas interações com outras moléculas, incluindo outras proteínas. Essas interações são cruciais para o funcionamento celular e para a manutenção da vida. A predição de interações proteína-proteína (PPIs, do inglês *Protein-Protein Interactions*) é muito importante, embora desafiadora, para a compreensão das funções celulares e das doenças. Este artigo apresenta o BioPrediction-PPI, um novo framework de AM de ponta a ponta para predição de PPIs, automatizando todo o processo, desde a extração de características até a interpretabilidade, sem exigir intervenção manual. O BioPrediction-PPI destaca-se como um dos poucos modelos de ponta a ponta que não dependem de aprendizado profundo, permitindo o uso automatizado de modelos treinados em novos dados. Além disso, oferece gráficos de interpretabilidade para a construção de modelos auditáveis e foi avaliado por meio de experimentos comparativos com 30 estudos anteriores, utilizando 15 conjuntos de dados. Esses gráficos de interpretabilidade também fornecem subsídios valiosos para a avaliação de modelos e o planejamento experimental, favorecendo uma tomada de decisão mais informada. O BioPrediction-PPI demonstrou desempenho competitivo em múltiplos conjuntos de dados, mesmo sem o uso de aprendizado profundo, além de constituir um modelo transparente, do tipo *white-box*, que pode ser facilmente utilizado por biólogos e profissionais sem formação em ciência da computação. O framework proposto tem potencial para acelerar pesquisas em biologia e áreas correlatas ao tornar ferramentas baseadas em IA mais acessíveis.

Trabalho Completo: ([FLORENTINO; BONIDIA; ROCHA et al., 2025](#)).

5.8 BioAutoML-FAST: Uma Plataforma de Aprendizado de Máquina

A predição de propriedades de sequências biológicas tem, tradicionalmente, se baseado em métodos fundamentados em alinhamento, os quais assumem homologia evolutiva e dependem de bases de referência curadas. Isso, por sua vez, limita a escalabilidade e a sensibilidade para conjuntos de dados grandes ou heterogêneos, homólogos distantes, sequências curtas e regiões genômicas em rápida evolução. Embora abordagens de AM ofereçam alternativas livres de alinhamento, sua adoção mais ampla ainda é limitada por: (i) a ausência de modelos de referência padronizados e validados externamente em conjuntos de dados diversos; e (ii) a expertise técnica necessária para engenharia de características, seleção de modelos e avaliação. O aprendizado de máquina automatizado (AutoML) atenua esses desafios ao otimizar sistematicamente representações e modelos com mínima intervenção do usuário. No entanto, a maioria dos frameworks existentes prioriza a construção

de modelos específicos para cada tarefa e carece de mecanismos para preservar modelos treinados como referências persistentes e comparáveis. Neste contexto, é apresentada a BioAutoML-FAST, uma plataforma web de ponta a ponta para análise automatizada por AM de sequências de nucleotídeos e aminoácidos. A plataforma oferece suporte tanto a tarefas de classificação quanto de regressão e automatiza a extração de características, o treinamento de modelos e a avaliação, sem exigir conhecimento prévio do usuário. De forma singular, também atua como um recurso comunitário de benchmarking, hospedando um repositório em contínua expansão de modelos reutilizáveis e padronizados (atualmente 60) para aplicações genômicas, transcriptômicas e proteômicas. Validações extensivas em conjuntos de dados independentes demonstram desempenho comparável ou superior ao de métodos de ponta, incluindo modelos de linguagem de proteínas, como o ESM-2.

Trabalho Completo: ([ALMEIDA, B. L. de et al., 2026](#)).

6 InteliGente: Democratizando o Letramento em Inteligência Artificial

Conforme apresentado, o presente hub desenvolveu e desenvolve diversas soluções que permitem que pessoas sem formação específica utilizem o poder da IA, principalmente nas ciências da vida. No entanto, outra preocupação é o uso responsável, ético e social dessas soluções. Consequentemente, ao analisar o acesso à educação tecnológica em IA em áreas carentes da América Latina, observa-se também uma clara disparidade em comparação com regiões mais desenvolvidas, como o Norte Global ([BERG; SNENE; VELASCO, 2024](#)). Muitas áreas enfrentam problemas com a falta de infraestrutura básica, como acesso estável à internet, dispositivos adequados e pessoal capacitado para dar suporte à integração tecnológica ([BONIDIA; SESTITO; CRUZ, 2025b](#)).

Além disso, barreiras socioeconômicas limitam a capacidade dos usuários de acessar treinamentos e recursos contínuos, aumentando, novamente, a exclusão digital ([AHMED, 2024; CHRISTANTI et al., 2024](#)). Em busca de combater esse outro desafio, foi criada uma iniciativa educacional chamada InteliGente¹⁴, que capacita pessoas a desenvolver e aplicar soluções de IA com impacto social e democratiza o conhecimento sobre o uso responsável para diversas comunidades. Essa iniciativa também visa ensinar estudantes a identificar desafios em suas comunidades que possam ser solucionados por meio da IA. Em vez de somente fornecer conceitos teóricos e práticos, os estudantes são guiados no desenvolvimento de soluções adaptadas ao seu contexto e à sua cultura, utilizando soluções já desenvolvidas pelo hub. Ademais, a iniciativa fomenta uma mentalidade socialmente consciente, muitas vezes negligenciada em programas tradicionais. Portanto, a iniciativa possui os seguintes objetivos:

- Capacitar estudantes em regiões menos desenvolvidas, fornecendo as habilidades

¹⁴<https://inteligentehub.com.br/>

técnicas e teóricas necessárias para desenvolver soluções de IA que abordem desafios locais e globais.

- Desenvolver e disseminar o conhecimento de IA ética, responsável e social mediante dois tipos de materiais: (1) tecnológico e (2) que dispensa o uso de tecnologia, pensado especialmente para territórios que não dispõem desses recursos, chamado de IA desplugada (UEMA et al., 2025).

A iniciativa estrutura-se em três grandes eixos de atuação voltados aos objetivos mencionados anteriormente, entre os quais: (1) Formação de uma nova geração de jovens capazes de compreender e aplicar a IA com domínio técnico e consciência social; (2) Desenvolvimento de materiais didáticos para a democratização do conhecimento básico de IA; (3) Palestras, oficinas e cursos para diferentes públicos.

Na primeira frente da iniciativa, os estudantes são continuamente estimulados a refletir sobre questões de natureza social, ética e política relacionadas ao desenvolvimento e ao uso da IA. Mais do que aprender técnicas ou ferramentas, eles são convidados a analisar criticamente os impactos que uma solução pode gerar em diferentes contextos, considerando aspectos como inclusão, justiça social, autonomia, privacidade, respeito às identidades culturais e redução de desigualdades. Esse processo formativo busca assegurar que a construção de soluções em IA não seja separada de seus efeitos sobre as pessoas, os territórios e as comunidades envolvidas. Para apoiar essa reflexão, a iniciativa desenvolveu um conjunto de materiais próprios, entre os quais se destaca o *InteliGenteCards*, elaborado justamente para orientar discussões e decisões ao longo do processo de criação de projetos. Para fins de exemplificação, algumas delas são apresentadas a seguir:

- Que problema social real sua solução aborda? E quem fica de fora?
- As desigualdades históricas (raça, gênero, classe, território, deficiência, entre outras) poderão ser amplificadas por esta IA?
- A solução respeita o conhecimento local, as práticas tradicionais e as identidades culturais?
- A solução gera oportunidades reais para populações vulneráveis?
- O sistema depende de infraestruturas (Internet, hardware, eletricidade) indisponíveis para populações vulneráveis?
- Esta IA aumenta a dependência tecnológica de empresas estrangeiras ou fortalece a autonomia local?
- Quem não pode utilizar esta IA devido a barreiras linguísticas, técnicas, culturais ou socioeconômicas?
- Protege a privacidade como um direito humano e não somente como um requisito legal?

- O sistema proposto reforça o pensamento crítico ou a confiança cega na IA?

Os estudantes que participam ou já participaram da iniciativa têm desenvolvido inúmeras soluções de impacto social, muitas delas premiadas em âmbito nacional e internacional. Entre elas¹⁵: (1) BioPrediction, (2) Tampinha Mágica, (3) Cartas do Fado, (4) Águeda, (5) BioLens, (6) SynapSpeech, (7) Grace, (8) Dominique e outras. Outro aspecto inovador da iniciativa é o desenvolvimento de materiais didáticos próprios, especialmente por meio de metodologias de IA desplugada. Esse formato permite levar o ensino de IA a contextos com baixa ou nenhuma infraestrutura tecnológica. Entre esses materiais, destacam-se:

- **InteliGenteCards**¹⁶: baralho educacional para facilitar o entendimento e a discussão sobre temas complexos relacionados à IA, ética e impactos sociais. Cada carta foi projetada para ser, ao mesmo tempo, educativa e envolvente, encorajando os participantes a explorar e debater as implicações da IA na sociedade. O baralho é dividido em quatro trilhas: (1) construção de ideias sobre projetos ou soluções com IA; (2) princípios éticos básicos aplicáveis à IA; (3) desenvolvimento de uma solução de IA; e (4) estudos de caso.
- **Ciência de Dados — Fundamentos e Aplicações**¹⁷: elaborado com o propósito de promover o letramento básico em IA, o livro utiliza uma linguagem simples e acessível a leitores de diferentes perfis. Trata-se, até onde se tem conhecimento, da primeira obra em português a abordar todas as etapas do desenvolvimento de IA de maneira clara e descomplicada.
- **ConsCiência**¹⁸: jogo educacional de tabuleiro voltado para o ensino de conceitos fundamentais de IA na educação básica, mesmo em ambientes sem recursos digitais. A dinâmica do jogo combina sorte, perguntas e desafios criativos, estruturados por níveis de dificuldade e sistema de pontuação, favorecendo tanto a competição quanto a colaboração entre os participantes. Essa ferramenta apresenta-se como uma alternativa de baixo custo para apoiar professores e engajar estudantes no debate sobre IA, ampliando o acesso a conhecimentos sobre esta tecnologia emergente.
- **O Livro dos Ratos Pensantes**¹⁹: livro infantil escrito por meio de narrativas que despertam a curiosidade das crianças e revelam os mistérios da IA, seus usos e seus impactos éticos e sociais. A obra foi criada para levar conhecimento desde cedo às futuras gerações, de forma lúdica e acessível. As histórias apresentam as aventuras do ratinho Tico e sua turma, que mergulham em descobertas no fascinante universo da IA, estimulando o pensamento crítico e uma consciência social desde a infância.
- **Japiim Digital**²⁰: Esta iniciativa visa ouvir e compreender as necessidades específi-

¹⁵Ver em <https://inteligentehub.com.br>

¹⁶<https://inteligentehub.com.br/InteliGenteCards.html>

¹⁷<https://bonidia.github.io/cd-fundamentos/intro.html>

¹⁸<https://inteligentehub.com.br/consciencia/>

¹⁹<https://inteligentehub.com.br/book.html>

²⁰<https://japiim.inteligentehub.com.br/>

cas relacionadas à integração da IA em comunidades subalternizadas, com atenção especial às comunidades ribeirinhas, aos povos indígenas, às comunidades quilombolas e às periferias urbanas (favelas). O principal objetivo é ampliar as vozes dessas comunidades e desenvolver o primeiro estudo que retrate genuinamente as suas realidades.

Por meio dessas iniciativas, o InteliGente já tem gerado impacto direto e indireto em centenas de pessoas, seja pela circulação de materiais educativos ou pela realização de formações e palestras. Além das ações presenciais e formativas, sua presença digital também tem ampliado significativamente esse alcance, no qual o perfil oficial da iniciativa no Instagram²¹ já acumula centenas de milhares de impressões, evidenciando o interesse crescente do público e a capacidade do projeto de disseminar conhecimento.

7 Prêmios, Reconhecimentos e Alcance

Ao longo dos anos, esta pesquisa conquistou ampla visibilidade e reconhecimento por meio de publicações científicas, plataformas digitais, materiais educativos, premiações, cobertura na mídia e ações em redes sociais. Entre os principais prêmios e reconhecimentos obtidos, destacam-se:

- **MathFeature e BioAutoML:**

1. **Prêmio Tese Destaque USP 2025**, concedido à melhor tese de doutorado do ano em Ciências Exatas e da Terra pela Universidade de São Paulo;
2. **Google Latin America Research Awards (LARA), 2021**: BioAutoML foi eleito pelo LARA-Google entre as 24 ideias mais promissoras da América Latina (24 projetos premiados, de uma base de 700 inscrições);
3. **AutoAI Hub (Democratizando AM para não especialistas, 2023 e 2025)**, selecionado como um dos projetos mais promissores dentre um total de 221 propostas de 47 países em uma competição global realizada pela *Global South Artificial Intelligence for Pandemic and Epidemic Preparedness and Response Network – AI4PEP*, conquistando um financiamento de aproximadamente 560.000 dólares canadenses;
4. **V Prêmio de Reconhecimento Acadêmico em Direitos Humanos (2025)**, concedido pela Universidade Estadual de Campinas (Unicamp) e pelo Instituto Vladimir Herzog, na categoria Ciências Exatas, Engenharia e Tecnologia – Doutorado;
5. **Menção Honrosa – Prêmio CAPES de Tese (2025)**. Reconhecida como uma das melhores teses de doutorado do Brasil na área de Ciência da Computação e Matemática;

²¹https://www.instagram.com/inteligente_utfpr

6. **IRCAI – UNESCO | Top 10 Soluções Globais de IA para os ODS (2025).** O BioAutoML foi selecionado entre as 10 iniciativas de IA de maior impacto mundial voltadas para os Objetivos de Desenvolvimento Sustentável das Nações Unidas;
7. **Prêmio Helmholtz para Pesquisador Visitante (2023)** - (*Helmholtz Information & Data Science Academy (HIDA)*);
8. **Prêmio de Pesquisa e Treinamento FEMS (2023)** - (*Federation of European Microbiological Societies*);
9. **BioAutoML** foi selecionado para participar do *Prototypes for Humanity 2024*, escolhido entre 2700 inscrições de mais de 100 países;
10. **BioPrediction (uma versão aprimorada do BioAutoML para trabalhar com interações entre sequências biológicas)** foi selecionado para participar do *Prototypes for Humanity 2023*, durante a COP28-Dubai, escolhido entre 3.000 inscritos, de mais de 100 países;
11. **BioAutoML recebeu uma menção honrosa do Prêmio Jovens Bioinformáticos de 2024**, sendo escolhido entre as melhores teses em Bioinformática e Biologia Computacional do Brasil;
12. BioAutoML recebeu o terceiro lugar no **Prêmio Artur Ziviani de Teses (SB-CAS 2024)**, sendo escolhido entre as melhores teses em computação aplicada à saúde;
13. **Finalista entre os 10 melhores - Prêmio Santander X Brasil** - Selecionado entre os 10 melhores projetos universitários (de mais de 200 inscrições) no Brasil na competição nacional de inovação promovida pelo Banco Santander;
14. **Finalista (Concurso de Ideias - Top 15 de 82)**, Falling Walls Lab Brasil 2022, DWIH São Paulo, Fundação Falling Walls, DAAD, Centro Alemão de Pesquisa e Inovação.

• **InteliGente:**

1. **O projeto InteliGente foi premiado como um dos mais transformadores (Internet Aberta e Livre) da América Latina** pelo Fundo Regional para Inovação Digital na América Latina e no Caribe (FRIDA 2024), recebendo um prêmio de 10.000 dólares;
2. **InteliGente foi selecionada para a Coleção Global HundrED 2026**, posicionando-se entre as inovações mais impactantes e escaláveis na área da educação em todo o mundo. O projeto se destacou entre mais de 800 inovações globais avaliadas por 250 especialistas;
3. **InteliGente venceu a 26ª edição do Prêmio Top Educacional Professor Mário Palmério 2025** - Associação Brasileira de Mantenedoras de Ensino Superior. Eleito entre os projetos mais transformadores do Brasil (164 inscritos);

4. **O projeto InteliGente foi selecionado pela Comissão Nacional para a UNESCO** e encaminhado para a fase internacional do Prêmio UNESCO-Rei Hamad Bin Isa Al-Khalifa para o Uso das TIC na Educação 2026;
 5. **InteliGente recebeu o endosso oficial da Sociedade Brasileira de Computação (SBC 2025)**, a mais importante organização de computação do país, que reconheceu sua relevância em IA para a educação e o impacto social;
 6. **Finalista do GESS Education Awards 2024 (Dubai) – Categoria Inovação em Educação**. Selecionado como finalista global em uma das cerimônias de premiação educacional mais prestigiadas do mundo, destacando-se entre mais de 900 inscrições de 60 países.
- **Produção científica de referência:** o presente projeto resultou em publicações em periódicos internacionais de destaque, como *Briefings in Bioinformatics*, *Nucleic Acids Research*, *Computational and Structural Biotechnology Journal* e *Microbial Biotechnology*, que estão entre as maiores revistas da área. Além disso, a produção associada ao projeto inclui mais de **30 outros estudos publicados em periódicos e conferências (resumos e artigos completos)**²². A seguir é apresentada uma lista das principais publicações:
 - **Briefings in Bioinformatics (IF 2020: 11.622):** Feature extraction approaches for biological sequences - a comparative study of mathematical features ([BONIDIA; SAMPAIO et al., 2021b](#));
 - **Nucleic Acids Research (IF 2020: 16.971):** CRISPRloci - comprehensive and accurate annotation of CRISPR–Cas systems ([ALKHNBASHI; MITROFANOV; BONIDIA et al., 2021](#));
 - **Briefings in Bioinformatics (IF 2021: 13.994):** BONIDIA, Robson Parmezan et al. MathFeature - feature extraction package for DNA, RNA, and protein sequences based on mathematical descriptors ([BONIDIA; DOMINGUES et al., 2022](#));
 - **Entropy (IF 2021: 2.738):** Information Theory for Biological Sequence Classification - A Novel Feature Extraction Technique Based on Tsallis Entropy ([BONIDIA; AVILA SANTOS et al., 2022](#));
 - **Briefings in Bioinformatics (IF 2021: 13.994):** BioAutoML - Automated Feature Engineering and Metalearning for the Prediction of Non-Coding RNAs in Bacteria ([BONIDIA; SANTOS et al., 2022](#));
 - **Prêmio Artur Ziviani - Concurso de Teses e Dissertações - 2024** BioAutoML - Democratizing Machine Learning in Life Sciences ([BONIDIA; CARVALHO, 2024](#));
 - **Microbial Biotechnology (IF 2025: 6.700):** Democratising Artificial Intelligence for Pandemic Preparedness and Global Governance in Latin American and Caribbean Countries ([ROCHA et al., 2025](#));

²²<http://lattes.cnpq.br/1572375422051077>

- **Briefings in Bioinformatics (IF 2025: 7.300):** Accessibility in proteins and RNAs interactions prediction with machine learning - are we overlooking non-experts? ([FLORENTINO; BONIDIA; F DE CARVALHO, 2026](#));
- **Preprint - Em revisão - 2026:** BioAutoML-FAST - an automated machine-learning platform for reusable and benchmarked biological sequence models ([ALMEIDA, B. L. de et al., 2026](#));

No total, são mais de 20 prêmios e reconhecimentos, evidenciando a relevância científica, a inovação e a contribuição social. No campo acadêmico, em um curto intervalo de tempo, as iniciativas ultrapassaram 250 citações de pesquisadores de quase 50 países, demonstrando alcance internacional e crescente inserção no debate científico global. Em termos de impacto, as iniciativas e soluções desenvolvidas já alcançaram milhares de pessoas, incluindo mais de 100.000 leituras em plataformas científicas e educacionais e mais de 10.000 usuários em páginas e ambientes digitais. De forma abrangente, estima-se que essas ações tenham gerado impacto direto e indireto em mais de 200.000 pessoas.

Para estimar o impacto, foram considerados dois tipos de alcance: (1) Direto: refere-se às pessoas que participaram ativamente das ações do projeto, como formações, eventos, aquisições de materiais, preenchimento de formulários e acessos registrados em plataformas; (2) Indireto: refere-se às pessoas impactadas de forma ampliada ou secundária, por meio de redes sociais, mídia, multiplicação por educadores, eventos com grande público e prêmios. Finalmente, as soluções, produções e conquistas receberam ampla cobertura midiática, com mais de 50 notícias publicadas em veículos nacionais e internacionais, incluindo Veja, SBC, Olhar Digital, UTFPR, USP, Porvir, Johns Hopkins e IDRC, entre outros.

8 Conclusão

Algoritmos de AM têm demonstrado ampla aplicabilidade nas ciências biológicas, acelerando descobertas, reduzindo custos de pesquisa e aumentando a eficiência científica. Esses avanços beneficiam diretamente a sociedade, a economia e a vida das pessoas. No entanto, sua utilização ainda permanece restrita pela exigência de conhecimento especializado. Nesse contexto, este trabalho, por meio do AutoAI Hub, propõe um ciclo completo para a democratização da IA, abrangendo desde o desenvolvimento de soluções até o letramento ético, social e responsável em seu uso. Seu principal objetivo é permitir que não especialistas utilizem IA, especialmente AM, sem a necessidade de conhecimentos em programação, ciência da computação ou outras áreas técnicas especializadas.

Todas as soluções apresentadas são disponibilizadas gratuitamente a pesquisadores, profissionais da saúde, à indústria farmacêutica, a organizações internacionais de vigilância genômica, a formuladores de políticas públicas e a outras partes interessadas, além de iniciativas educacionais direcionadas à sociedade em geral. Além disso, essas soluções possibilitam uma ampla gama de aplicações, incluindo avaliação de efeitos de fármacos, identificação de atividade terapêutica, apoio ao tratamento de pacientes, desenvolvimento

de vacinas, detecção de novas variantes, monitoramento da evolução genômica, entre outras.

Mais do que propor ferramentas computacionais, esta pesquisa demonstra que a democratização da IA pode ser alcançada por meio de uma abordagem integrada, que articula automação, acessibilidade, formação e responsabilidade social. Ao conectar soluções tecnológicas, evidências científicas e iniciativas educacionais, o presente projeto contribui para transformar a IA de um recurso restrito a especialistas em uma capacidade mais amplamente acessível, orientada à promoção da ciência, da saúde e do bem comum. Por fim, este trabalho não apenas amplia as possibilidades de aplicação do AM na sociedade, mas também reafirma que o futuro da IA precisa ser construído com inclusão, equidade, educação e compromisso social.

Agradecimentos

Este projeto recebeu apoio financeiro de uma variedade de fontes, incluindo o *Canadian International Development Research Centre (IDRC)* sob o Acordo de Subvenção 109981, o *UK government's Foreign, Commonwealth and Development Office*, a Coordenação de Aperfeiçoamento de Pessoal de Nível Superior (CAPES), o *Google Latin America Research Awards (LARA)*, o Prêmio Pesquisador Visitante da Helmholtz, o Prêmio de Pesquisa e Treinamento da *Federation of European Microbiological Societies*, *Spencer Foundation* e o Sabiá Data Lake (Governo do Paraná, Fundação Araucária e IPEC).

Evidências Visuais da Trajetória

Como complemento às evidências apresentadas ao longo deste trabalho, esta seção reúne seis registros visuais que documentam a trajetória científica, educacional e institucional associada ao desenvolvimento do presente projeto.



(a) Premiações e reconhecimentos.



(b) Participação em evento científico.



(c) Apresentação pública dos resultados da pesquisa.



(d) Atividade formativa com estudantes.



(e) Aplicação de materiais com estudantes.



(f) Ampla divulgação dos Projetos.

Declaração de Uso de IA Generativa

Este trabalho contou com o apoio de ferramentas de IA generativa, como ChatGPT, utilizadas para auxiliar na tradução, na revisão textual e no aprimoramento da clareza da escrita. Entretanto, todas as análises dos dados, interpretações, decisões metodológicas e revisões finais foram realizadas pelos autores, que assumem integral responsabilidade pelo conteúdo científico apresentado.

Referências

- AFIFY, H. M.; ZANATY, M. S. Computational predictions for protein sequences of COVID-19 virus via machine learning algorithms. **Medical & biological engineering & computing**, Springer, v. 59, n. 9, p. 1723–1734, 2021.
- AHMED, F. The digital divide and AI in education: Addressing equity and accessibility. **AI EDIFY Journal**, v. 1, n. 2, p. 12–23, 2024.
- AKGUN, S.; GREENHOW, C. Artificial intelligence in education: Addressing ethical challenges in K-12 settings. **AI and Ethics**, Springer, v. 2, n. 3, p. 431–440, 2022.
- ALKHNBASHI, O. S.; MITROFANOV, A.; BONIDIA, R. et al. CRISPRloci: comprehensive and accurate annotation of CRISPR–Cas systems. **Nucleic Acids Research**, v. 49, W1, w125–w130, jun. 2021. ISSN 0305-1048. DOI: [10.1093/nar/gkab456](https://doi.org/10.1093/nar/gkab456).
- ALMEIDA, B. L. S. de et al. Feature importance analysis of non-coding dna/rna sequences based on machine learning approaches. In: SPRINGER. BRAZILIAN Symposium on Bioinformatics. [S.l.: s.n.], 2021. P. 81–92.
- ALMEIDA, B. L. de et al. BioAutoML-FAST: an automated machine-learning platform for reusable and benchmarked biological sequence models. **bioRxiv**, Cold Spring Harbor Laboratory, p. 2026–04, 2026.
- ANAI, S. et al. Deep Learning Models to Predict Fatal Pneumonia Using Chest X-Ray Images. **Canadian Respiratory Journal**, Hindawi, v. 2022, 2022.
- AVILA SANTOS, A. P. et al. BioDeepfuse: a hybrid deep learning approach with integrated feature extraction techniques for enhanced non-coding RNA classification. **RNA biology**, Taylor & Francis, v. 21, n. 1, p. 410–421, 2024.
- AYANA, G. et al. Decolonizing global AI governance: assessment of the state of decolonized AI governance in Sub-Saharan Africa. **Royal Society Open Science**, v. 11, n. 8, p. 231994, 2024. DOI: [10.1098/rsos.231994](https://doi.org/10.1098/rsos.231994). Disponível em: <https://doi.org/10.1098/rsos.231994>.
- AYOUB, J.; YANG, X. J.; ZHOU, F. Combat COVID-19 infodemic using explainable natural language processing models. **Information processing & management**, Elsevier, v. 58, n. 4, p. 102569, 2021.

BERG, J.; SNENE, M.; VELASCO, L. **Mind the AI Divide: Shaping a Global Perspective on the Future of Work**. [S.l.: s.n.], 2024. Acesso em: 26 abril. 2026. Disponível em: <<https://www.ilo.org/publications/major-publications/mind-ai-divide-shaping-global-perspective-future-work>>.

BERGSTRA, J.; YAMINS, D.; COX, D. D. et al. Hyperopt: A python library for optimizing the hyperparameters of machine learning algorithms. In: CITESEER. PROCEEDINGS of the 12th Python in science conference. [S.l.: s.n.], 2013. v. 13, p. 20.

BONIDIA, R.; CARVALHO, A. BioAutoML: Democratizing Machine Learning in Life Sciences. In: ANAIS Estendidos do XXIV Simpósio Brasileiro de Computação Aplicada à Saúde. Goiânia/GO: SBC, 2024. P. 85–90. DOI: [10.5753/sbcas_estendido.2024.2184](https://doi.org/10.5753/sbcas_estendido.2024.2184). Disponível em: <https://sol.sbc.org.br/index.php/sbcas_estendido/article/view/28709>.

BONIDIA, R.; SESTITO, C.; CRUZ, W. **Inteligência Artificial na Educação Básica: Percepções e Desafios dos Professores**. Brasil, 2025. Design: Matheus Victor Martins. Revisão: Gabriela Baumam. Apoio: IDRC e FRIDA LACNIC.

_____. **Relatório de pesquisa inteligência artificial na educação básica: percepções e desafios dos professores**. São Paulo: Instituto Significare, 2025. Disponível em: <<https://significare.rds.land/relatoriodepesquisaiaeducacao>>.

BONIDIA, R. P.; AVILA SANTOS, A. P. et al. Information theory for biological sequence classification: A novel feature extraction technique based on tsallis entropy. **Entropy**, MDPI, v. 24, n. 10, p. 1398, 2022.

BONIDIA, R. P.; DOMINGUES, D. S. et al. MathFeature: feature extraction package for DNA, RNA and protein sequences based on mathematical descriptors. **Briefings in bioinformatics**, Oxford University Press, v. 23, n. 1, bbab434, 2022.

BONIDIA, R. P.; SAMPAIO, L. D. H. et al. Feature extraction approaches for biological sequences: a comparative study of mathematical features. **Briefings in Bioinformatics**, fev. 2021. bbab011. ISSN 1477-4054. DOI: [10.1093/bib/bbab011](https://doi.org/10.1093/bib/bbab011).

_____. **Briefings in Bioinformatics**, fev. 2021. bbab011. ISSN 1477-4054. DOI: [10.1093/bib/bbab011](https://doi.org/10.1093/bib/bbab011). eprint: <https://academic.oup.com/bib/advance-article-pdf/doi/10.1093/bib/bbab011/36254240/bbab011.pdf>. Disponível em: <<https://doi.org/10.1093/bib/bbab011>>.

BONIDIA, R. P.; SANTOS, A. P. A. et al. BioAutoML: automated feature engineering and metalearning to predict noncoding RNAs in bacteria. **Briefings in Bioinformatics**, Oxford University Press, v. 23, n. 4, bbac218, 2022.

BONIDIA, R. P.; MACHIDA, J. S. et al. A Novel Decomposing Model With Evolutionary Algorithms for Feature Selection in Long Non-Coding RNAs. **IEEE Access**, v. 8, p. 181683–181697, 2020. DOI: [10.1109/ACCESS.2020.3028039](https://doi.org/10.1109/ACCESS.2020.3028039).

BORKOWSKI, A. A. et al. Google Auto ML versus Apple Create ML for Histopathologic Cancer Diagnosis; Which Algorithms Are Better? **arXiv preprint arXiv:1903.08057**, 2019.

CASSIANO, M. H. A.; SILVA-ROCHA, R. Benchmarking bacterial promoter prediction tools: Potentialities and limitations. **Msystems**, Am Soc Microbiol, v. 5, n. 4, e00439–20, 2020.

CAVALCANTE, J. P. U. et al. MathPIP: classification of proinflammatory peptides using mathematical descriptors. In: SPRINGER. BRAZILIAN Symposium on Bioinformatics. [S.l.: s.n.], 2021. P. 131–136.

CHATTOPADHYAY, S.; CHATTOPADHYAY, A.; AIFANTIS, E. Predicting Case Fatality of Dengue Epidemic: Statistical Machine Learning Towards a Virtual Doctor. **Journal of Nanotechnology in Diagnosis and Treatment**, v. 7, p. 10–24, 2021.

CHEN, S. et al. Integrating machine learning and artificial intelligence in life-course epidemiology: pathways to innovative public health solutions. **BMC Medicine**, BioMed Central, v. 22, n. 1, p. 354, 2024. DOI: [10.1186/s12916-024-03566-x](https://doi.org/10.1186/s12916-024-03566-x).

CHEN, W. et al. iACP: a sequence-based tool for identifying anticancer peptides. **Oncotarget**, Impact Journals, LLC, v. 7, n. 13, p. 16895, 2016.

CHEN, Z.; ZHAO, P.; LI, C. et al. iLearnPlus: a comprehensive and automated machine-learning platform for nucleic acid and protein sequence analysis, prediction and visualization. **Nucleic Acids Research**, fev. 2021. gkab122. ISSN 0305-1048. DOI: [10.1093/nar/gkab122](https://academic.oup.com/nar/advance-article-pdf/doi/10.1093/nar/gkab122/36415284/gkab122.pdf). eprint: <https://academic.oup.com/nar/advance-article-pdf/doi/10.1093/nar/gkab122/36415284/gkab122.pdf>. Disponível em: <https://doi.org/10.1093/nar/gkab122>.

CHEN, Z.; ZHAO, P.; LI, F. et al. iLearn: an integrated platform and meta-learner for feature engineering, machine-learning analysis and modeling of DNA, RNA and protein sequence data. **Briefings in Bioinformatics**, v. 21, n. 3, p. 1047–1057, abr. 2019. ISSN 1477-4054. DOI: [10.1093/bib/bbz041](https://academic.oup.com/bib/article-pdf/21/3/1047/33227445/bbz041.pdf). eprint: <https://academic.oup.com/bib/article-pdf/21/3/1047/33227445/bbz041.pdf>. Disponível em: <https://doi.org/10.1093/bib/bbz041>.

CHRISTANTI, M. F. et al. The digital divide in education: Bridging gaps in the era of online learning. **Migration Letters**, v. 21, S4, p. 1070–1079, 2024.

COMITO, C.; PIZZUTI, C. Artificial intelligence for forecasting and diagnosing COVID-19 pandemic: A focused review. **Artificial Intelligence in Medicine**, Elsevier, p. 102286, 2022.

DOMINGOS, P. A few useful things to know about machine learning. **Communications of the ACM**, ACM New York, NY, USA, v. 55, n. 10, p. 78–87, 2012.

ELSAAYAD, A. M.; NASSEF, A. M.; AL-DHAIFALLAH, M. Bayesian optimization of multiclass SVM for efficient diagnosis of erythemato-squamous diseases. **Biomedical Signal Processing and Control**, v. 71, p. 103223, 2022. ISSN 1746-8094. DOI: <https://doi.org/10.1016/j.bspc.2021.103223>.

FANG, H. et al. Mlzero: A multi-agent system for end-to-end machine learning automation. **arXiv preprint arXiv:2505.13941**, 2025.

FLEURENCE, R. L. et al. Generative artificial intelligence for health technology assessment: opportunities, challenges, and policy considerations: an ISPOR working group report. **Value in Health**, Elsevier, v. 28, n. 2, p. 175–183, 2025.

FLORENTINO, B. R.; BONIDIA, R. P.; F DE CARVALHO, A. C. Accessibility in proteins and RNAs interactions prediction with machine learning: are we overlooking non-experts? **Briefings in Bioinformatics**, Oxford University Press, v. 27, n. 3, bbag226, 2026.

FLORENTINO, B. R.; BONIDIA, R. P.; ROCHA, U. et al. BioPrediction-PPI: Simplifying the Prediction of Protein-Protein actions through Artificial Intelligence. **bioRxiv**, Cold Spring Harbor Laboratory, p. 2025–11, 2025.

FLORENTINO, B. R.; BONIDIA, R. P.; SANCHES, N. H. et al. BioPrediction-RPI: Democratizing the prediction of interaction between non-coding RNA and protein with end-to-end machine learning. **Computational and Structural Biotechnology Journal**, Elsevier, v. 23, p. 2267–2276, 2024.

FRAZIER, P. I. A tutorial on Bayesian optimization. **arXiv preprint arXiv:1807.02811**, 2018.

GOLDSTEIN, N. D.; LEVASSEUR, M. T.; MCCLURE, L. A. On the Convergence of Epidemiology, Biostatistics, and Data Science. **Harvard Data Science Review**, MIT Press, v. 2, n. 2, 2020. DOI: [10.1162/99608f92.9f0215e6](https://doi.org/10.1162/99608f92.9f0215e6).

GOZZI, N.; COMINI, N.; PERRA, N. Bridging the digital divide: mapping Internet connectivity evolution, inequalities, and resilience in six Brazilian cities. **EPJ Data Science**, Springer Berlin Heidelberg, v. 13, n. 1, p. 69, 2024.

GUAN, S.; FU, N. Class imbalance learning with Bayesian optimization applied in drug discovery. **Scientific Reports**, Nature Publishing Group UK London, v. 12, n. 1, p. 2069, 2022.

GUPTA, A. et al. Combating fake news: Stakeholder interventions and potential solutions. **Ieee Access**, IEEE, v. 10, p. 78268–78289, 2022.

HAN, T. et al. Modeling the progression of COVID-19 deaths using Kalman Filter and AutoML. **Soft Computing**, Springer, v. 27, n. 6, p. 3229–3244, 2023.

HANCOCK, J.; KHOSHGOFTAAR, T. M. CatBoost for Big Data: an Interdisciplinary Review. **Research Square**, 2020.

HE, S.; LEANSE, L. G.; FENG, Y. Artificial intelligence and machine learning assisted drug delivery for effective treatment of infectious diseases. **Advanced Drug Delivery Reviews**, Elsevier, v. 178, p. 113922, 2021.

HE, S.; DOU, L. et al. Review of bioinformatics in Alzheimer's Disease Research. **Computers in Biology and Medicine**, v. 143, p. 105269, 2022. ISSN 0010-4825. DOI: <https://doi.org/10.1016/j.combiomed.2022.105269>.

HUANG, J. et al. Identification of potent antimicrobial peptides via a machine-learning pipeline that mines the entire space of peptide sequences. **Nature Biomedical Engineering**, Nature Publishing Group, p. 1–14, 2023.

HUSSAIN, S. A.; BRESNAHAN, M.; ZHUANG, J. Can artificial intelligence revolutionize healthcare in the Global South? A scoping review of opportunities and challenges. **Digital Health**, v. 11, p. 1–13, 2025. DOI: [10.1177/20552076251348024](https://doi.org/10.1177/20552076251348024). Disponível em: [10.1177/20552076251348024](https://doi.org/10.1177/20552076251348024).

INSIGHTS, O. **Government AI Readiness Index 2024**. London: Oxford Insights, 2024. Authors: Pablo Fuentes Nettel, Emma Hankins, Richard Stirling, Giulia Cirri, Gonzalo Grau, Sulamaan Rahim, Eddie Crampton. Licence: CC BY-SA 4.0. Disponível em: <https://oxfordinsights.com/ai-readiness-index/>.

JING, R. et al. autoBioSeqpy: a deep learning tool for the classification of biological sequences. **Journal of Chemical Information and Modeling**, ACS Publications, v. 60, n. 8, p. 3755–3764, 2020.

KARMAKER, S. K. et al. Automl to date and beyond: Challenges and opportunities. **ACM Computing Surveys (CSUR)**, ACM New York, NY, v. 54, n. 8, p. 1–36, 2021.

KE, G. et al. Lightgbm: A highly efficient gradient boosting decision tree. **Advances in neural information processing systems**, v. 30, 2017.

KRAEMER, M. et al. Artificial intelligence for modelling infectious disease epidemics. **Nature**, Nature Publishing Group, v. 638, n. 8051, p. 623–635, 2025. DOI: [10.1038/s41586-024-08564-w](https://doi.org/10.1038/s41586-024-08564-w).

LI, Q. et al. Prediction of Anticancer Peptides Using a Low-Dimensional Feature Model. **Frontiers in Bioengineering and Biotechnology**, v. 8, p. 892, 2020. ISSN 2296-4185. DOI: [10.3389/fbioe.2020.00892](https://doi.org/10.3389/fbioe.2020.00892). Disponível em: <https://www.frontiersin.org/article/10.3389/fbioe.2020.00892>.

LIAW, A.; WIENER, M. et al. Classification and regression by randomForest. **R news**, v. 2, n. 3, p. 18–22, 2002.

LIN, H. et al. Identifying sigma70 promoters with novel pseudo nucleotide composition. **IEEE/ACM transactions on computational biology and bioinformatics**, IEEE, v. 16, n. 4, p. 1316–1321, 2017.

LIU, D.; XU, C. et al. AutoGenome: an AutoML tool for genomic research. **Artificial Intelligence in the Life Sciences**, Elsevier, v. 1, p. 100017, 2021.

LIU, M.; LIU, Y.; LIU, J. Machine learning for infectious disease risk prediction: a survey. **ACM Computing Surveys**, ACM New York, NY, v. 57, n. 8, p. 1–39, 2025.

LIU, Y.; YU, Z. et al. Prediction of protein crotonylation sites through LightGBM classifier based on SMOTE and elastic net. **Analytical Biochemistry**, v. 609, p. 113903, 2020. ISSN 0003-2697. DOI: <https://doi.org/10.1016/j.ab.2020.113903>.

MANAVALAN, B.; SHIN, T. H.; LEE, G. PVP-SVM: sequence-based prediction of phage virion proteins using a support vector machine. **Frontiers in microbiology**, Frontiers, v. 9, p. 476, 2018.

MANGA, I. AutoML for All: Democratizing Machine Learning Model Building with Minimal Code Interfaces. In: IEEE. 2025 3rd International Conference on Sustainable Computing and Data Communication Systems (ICSCDS). [S.l.: s.n.], 2025. P. 347–352.

MATHENY, M. E. et al. Artificial Intelligence In Health And Health Care: Priorities For Action: Article examines priorities for the uses of artificial intelligence in health and health care. **Health Affairs**, v. 44, n. 2, p. 163–170, 2025.

MENG, J. et al. PlncRNA-HDeep: plant long noncoding RNA prediction using hybrid deep learning based on two encoding styles. **BMC bioinformatics**, BioMed Central, v. 22, n. 3, p. 1–16, 2021.

MIAO, Z. et al. An assessment and cleaning framework for electronic health records data. In: INSTITUTE OF INDUSTRIAL e SYSTEMS ENGINEERS (IISE). IIE Annual Conference. Proceedings. [S.l.: s.n.], 2018. P. 907–912.

OXFORD INSIGHTS. **Government AI Readiness Index 2025**. Acesso em: 14 jul. 2026. 2025. Disponível em: <https://oxfordinsights.com/ai-readiness/government-ai-readiness-index-2025/>.

PETERS, L. E. et al. Public health disinformation, conflict, and disease outbreaks: a global narrative integrative review to guide new directions for health diplomacy. **Global Health Action**, Taylor & Francis, v. 18, n. 1, p. 2562380, 2025.

PISIGNANO, G.; LADOMERY, M. Post-Transcriptional Regulation through Long Non-Coding RNAs (lncRNAs). **Non-Coding RNA**, v. 7, n. 2, 2021. ISSN 2311-553X. DOI: [10.3390/ncrna7020029](https://www.mdpi.com/2311-553X/7/2/29). Disponível em: <https://www.mdpi.com/2311-553X/7/2/29>.

PROKHORENKOVA, L. et al. CatBoost: unbiased boosting with categorical features. In: ADVANCES in neural information processing systems. [S.l.: s.n.], 2018. P. 6638–6648.

ROCHA, U. et al. Democratising Artificial Intelligence for Pandemic Preparedness and Global Governance in Latin American and Caribbean Countries. **Microbial Biotechnology**, Wiley Online Library, v. 18, n. 10, e70256, 2025.

RUBEIS, G.; DUBBALA, K.; METZLER, I. “Democratizing” artificial intelligence in medicine and healthcare: Mapping the uses of an elusive term. **Frontiers in Genetics**, Frontiers, v. 13, p. 902542, 2022.

SCHAPIRE, R. E. Explaining adaboost. In: EMPIRICAL inference. [S.l.]: Springer, 2013. P. 37–52.

SCHLEGEL, M.; SATTLER, K.-U. Management of machine learning lifecycle artifacts: A survey. **ACM SIGMOD Record**, ACM New York, NY, USA, v. 51, n. 4, p. 18–35, 2023.

SINGH, S.; HOODA, S. A study of challenges and limitations to applying machine learning to highly unstructured data. In: IEEE. 2023 7th International Conference On Computing, Communication, Control And Automation (ICCUBEA). [S.l.: s.n.], 2023. P. 1–6.

SYROWATKA, A. et al. Leveraging artificial intelligence for pandemic preparedness and response: a scoping review to identify key use cases. **NPJ digital medicine**, Nature Publishing Group UK London, v. 4, n. 1, p. 96, 2021.

TETTEROO, J.; BARATCHI, M.; HOOS, H. H. Automated Machine Learning for COVID-19 Forecasting. **IEEE Access**, IEEE, v. 10, p. 94718–94737, 2022.

TOMIC, A. et al. SIMON, an automated machine learning system, reveals immune signatures of influenza vaccine responses. **The Journal of Immunology**, American Association of Immunologists, v. 203, n. 3, p. 749–759, 2019.

TURNER, R. et al. Bayesian optimization is superior to random search for machine learning hyperparameter tuning: Analysis of the black-box optimization challenge 2020. In: PMLR. NEURIPS 2020 Competition and Demonstration Track. [S.l.: s.n.], 2021. P. 3–26.

UEMA, M. A. et al. Designing for Meaningful Access: Towards a Framework for AI in Education Unplugged. In: SPRINGER. INTERNATIONAL Conference on Artificial Intelligence in Education. [S.l.: s.n.], 2025. P. 307–320.

UNESCO. **Recommendation on the Ethics of Artificial Intelligence**. Paris, 2022.

VICTORIA, A. H.; MARAGATHAM, G. Automatic tuning of hyperparameters using Bayesian optimization. **Evolving Systems**, Springer, v. 12, n. 1, p. 217–223, 2021.

WANG, R. et al. Characterization and identification of lysine crotonylation sites based on machine learning method on both plant and mammalian. **Scientific reports**, Nature Publishing Group, v. 10, n. 1, p. 1–12, 2020.

WORLD ECONOMIC FORUM. **The AI Divide between the Global North and the Global South**. Jan. 2023. Disponível em: <https://www.weforum.org/stories/2023/01/davos23-ai-divide-global-north-global-south/>.

WORLD HEALTH ORGANIZATION. **Regulatory considerations on artificial intelligence for health**. Geneva: World Health Organization, 2023. Licence: CC BY-NC-SA 3.0 IGO. Disponível em: <https://www.who.int/publications/i/item/9789240071091>.

XIE, Y.; ZHAI, Y.; LU, G. Evolution of artificial intelligence in healthcare: a 30-year bibliometric study. **Frontiers in Medicine**, Frontiers Media SA, v. 11, p. 1505692, 2025.

YE, Y.; PANDEY, A.; BAWDEN, C. et al. Integrating artificial intelligence with mechanistic epidemiological modeling: a scoping review of opportunities and challenges. **Nature Communications**, Nature Publishing Group, v. 16, n. 581, p. 1–15, 2025. DOI: [10.1038/s41467-024-55461-x](https://doi.org/10.1038/s41467-024-55461-x).

ZHANG, T.; RABHI, F. et al. Use of automated machine learning for an outbreak risk prediction tool. **Informatics in Medicine Unlocked**, Elsevier, v. 34, p. 101121, 2022.

ZHANG, Y.; YU, S. et al. PeNGaRoo, a combined gradient boosting and ensemble learning framework for predicting non-classical secreted proteins. **Bioinformatics**, Oxford University Press, v. 36, n. 3, p. 704–712, 2020.

ZHAO, Y. et al. Identification of Protein Lysine Crotonylation Sites by a Deep Learning Framework With Convolutional Neural Networks. **IEEE Access**, v. 8, p. 14244–14252, 2020. DOI: [10.1109/ACCESS.2020.2966592](https://doi.org/10.1109/ACCESS.2020.2966592).

ZOWGHI, D.; BANO, M. AI for all: Diversity and Inclusion in AI. **AI and Ethics**, Springer, v. 4, n. 4, p. 873–876, 2024.